



دانشگاه تهران
دانشکده ریاضی، آمار و علوم کامپیوتر

پایان نامه برای دریافت درجه کارشناسی ارشد
در رشته علوم کامپیوتر

استفاده از شبکه‌های عصبی ضربه‌ای جهت بازشناسی الگو

نگارش
نیما محمدی

استاد راهنما
دکتر محمد گنج‌تابش

شهریور ۱۳۹۵

چکیده

توانایی خارق‌العاده‌ی مغز در پردازش حجم بالایی از اطلاعات به صورت موازی و ساختار و سازمانش آن را بدون شک به پیچیده‌ترین ارگان شناخته شده در گیتی تبدیل کرده است. با وجود شباهت‌های آناتومی و فیزیولوژی مغز انسان، و با در نظر گرفتن عملکرد پیمانه‌ای مغز، مدارات محلی قشرهای گوناگون مغز تا حد زیادی به صورت تصادفی تشکیل شده است. گواه تشکیل این مدارات تصادفی عدم امکان در بر گرفتن توصیف نجومی اتصالات مغز در ژنوم است که ما را به بررسی امکان‌پذیری مشارکت شبکه‌های تصادفی در پردازش اطلاعات و توانمندی آنها سوق می‌دهد. از این روی در این تحقیق به توانایی بازشناسی الگو با بهره‌گیری از محاسبات انباره‌ای پرداخته می‌شود. ماشین حالت مایع که نمود محاسبات انباره‌ای بر مبنای مکانیسم نورون‌های مغز است اخیراً توجه زیادی را به خود جلب کرده است تا حدی که هم اکنون برای برخی از کاربردهای مهندسی نیز پیشنهاد می‌شود. ماشین‌های حالت مایع محرک ورودی را به فضایی با ابعاد بالاتر نگاشت می‌دهند که به موجب آن تفکیک الگوهای زمانی فضایی را ساده‌تر می‌نمایند؛ همانند چیزی که به موجب کرنل‌ها در ماشین‌های بردار پشتیبانی روی می‌دهد، با این تفاوت که ماشین حالت مایع از نظر زیستی انطباق بیشتری دارد. در این تحقیق با بررسی مکانیسم‌های مختلف اتصالات سیناپسی به واکاوی تأثیر توپولوژی شبکه روی عملکرد ماشین حالت مایع می‌پردازیم. در اینجا ارائه‌ی روش جدیدی برای نمایش حالت فیلتر مایع که به امکان تمایز قابل قبول بین نمونه‌ها بیانجامد ارائه شده است و همچنین معیاری جدید برای سنجش توانایی تفکیک ذاتی ماشین حالت مایع عرضه می‌شود.

کلمات کلیدی:

محاسبات انباره‌ای- ماشین حالت مایع- شبکه‌ی عصبی ضربه‌ای- بازشناسی الگوی بصری

بدینوسید از استاد گرامی

دکتر محمد گنج‌تابش

که بار اهنمایی‌های بی‌چشمداشتشان من را در تدوین این پایان‌نامه بسیار کمک کرده‌اند

سپاس‌گذاری و تشکر فراوان می‌نمایم.

همچنین از دوستان عزیزم سعید رضا خردیشه و میلاد مظفری
که مرادیش‌بردا این تحقیق کمک کردند نهایت تشکر را دارم.

فهرست مطالب

آ	چکیده
ب	سپاس‌گزاری
۱	فصل ۱: مقدمه‌ای بر دستگاه عصبی
۱	۱.۱ مقدمه
۲	۲.۱ فیزیولوژی نورون
۳	۱.۲.۱ جسم سلولی (سوما)
۴	۲.۲.۱ غشای نورونی و کانال‌های یونی
۵	۳.۲.۱ دارینه
۵	۴.۲.۱ آکسون
۶	۵.۲.۱ سیناپس
۷	۳.۱ انواع نورون
۹	۴.۱ قانون هب
۹	۱.۴.۱ یادگیری وابسته به زمان ضربه
۱۱	فصل ۲: دستگاه بینایی انسان
۱۱	۱.۲ مقدمه
۱۲	۲.۲ شبکه
۱۴	۱.۲.۲ گیرنده‌های نوری
۱۵	۲.۲.۲ سلول‌های گانگلیون
۱۷	۳.۲.۲ هسته‌ی زانویی جانبی
۱۸	۴.۲.۲ ستون‌های جهت‌گیری و میدان تاثیر V1
۲۰	۳.۲ خط‌سیر بینایی

۴.۲	ساختر قشر بینایی مغز	۲۱
۱.۴.۲	ناحیه V1	۲۳
۵.۲	سطوح بالاتر بینایی	۲۶
۱.۵.۲	ناحیه V2	۲۷
۲.۵.۲	ناحیه V4	۲۸
۳.۵.۲	قشر IT	۲۹

فصل ۳: مدل‌های عصبی

۱.۳	مقدمه	۳۰
۲.۳	شبکه‌های عصبی ضربه‌ای	۳۱
۱.۲.۳	تاریخچه مدل‌سازی نورونی	۳۱
۲.۲.۳	مدل‌های نورونی	۳۲
۳.۲.۳	یادگیری وابسته به زمان ضربه	۳۳
۳.۳	یادگیری بدون نظارت ویژگی‌های بصری توسط STDP	۳۵
۴.۳	ماشین حالت مایع	۳۷
۱.۴.۳	پیش‌زمینه	۳۸
۲.۴.۳	معماری	۴۰
۳.۴.۳	شبکه‌های عصبی درون‌رایانه‌ای	۴۲
۴.۴.۳	شبکه‌های عصبی درون‌کشتگاهی	۴۳
۵.۳	مسئله‌ی تشخیص اشیا	۴۴
۱.۵.۳	فرآیند محاسباتی تشخیص اشیا	۴۵
۶.۳	مدل‌های ارائه شده برای مسیر اصلی دستگاه بینایی	۴۷
۱.۶.۳	مدل‌های عصب‌زیست‌شناختی	۴۷
۲.۶.۳	مدل‌های الهام گرفته از مسیر بینایی	۴۷
۳.۶.۳	مدل‌های دارای انطباق زیستی	۵۰

فصل ۴: مدل پیشنهادی و کارهای صورت گرفته

۱.۴	دادگان استفاده شده	۵۲
۲.۴	شبکه سلسله مراتبی	۵۳
۱.۲.۴	لایه‌های شبکه‌ی سلسله مراتبی	۵۴

۵۶.....	۲.۲.۴ مدل STDP برای شبکه‌ی سلسله مراتبی
۵۶.....	۳.۲.۴ مدل نورونی و سیناپسی
۵۶.....	۴.۲.۴ پارامترها و عملکرد شبکه‌ی سلسله مراتبی
۵۸.....	۳.۴ ماشین حالت مایع
۵۸.....	۱.۳.۴ مدل نورونی
۵۹.....	۲.۳.۴ سیناپس‌های دینامیک
۶۰.....	۳.۳.۴ لایه‌ی قرائت
۶۱.....	۴.۳.۴ توپولوژی اتصالات
۶۵.....	۴.۴ نتایج
۶۵.....	۱.۴.۴ میزان تفکیک‌پذیری
۶۹.....	۵.۴ نتایج
۶۹.....	۱.۵.۴ میزان تفکیک‌پذیری
۷۰.....	۲.۵.۴ آنالیز افتراقی خطی
۷۱.....	۳.۵.۴ ماشین بردار پشتیبان
۷۳.....	۴.۵.۴ نتیجه‌گیری

فصل ۵: نتیجه‌گیری و پیشنهاد کارهای آینده ۷۴

کتاب‌نامه ۷۶

واژه‌نامه فارسی به انگلیسی ۸۰

پیوست‌آ: پیاده‌سازی ۸۹

۸۹.....	۱.آ استخراج ویژگی‌های بصری با STDP
۹۰.....	۱.۱.آ کلاس Gabor
۹۱.....	۲.۱.آ کلاس GaborLayer
۹۱.....	۳.۱.آ کلاس Kernel
۹۲.....	۴.۱.آ کلاس Network

چکیده انگلیسی ۹۵

فهرست تصاویر

شکل ۱.۱:	سوما، آکسون و دارینه ها	۲.....
شکل ۲.۱:	انواع نورون ها (تک قطبی، دوقطبی و چندقطبی)	۸.....
شکل ۱.۲:	ساختار چشم انسان	۱۲.....
شکل ۲.۲:	گیرنده های نوری	۱۴.....
شکل ۳.۲:	سه دسته کلاس نورونی در شبکه	۱۶.....
شکل ۴.۲:	پاسخ سلول های گانگلیون	۱۷.....
شکل ۵.۲:	میدان تاثیر سلول های ساده	۱۸.....
شکل ۶.۲:	تفاوت پاسخ سلول های ساده و پیچیده	۱۹.....
شکل ۷.۲:	محل پردازش بخش های مختلف میدان دید در قشر بینایی مغز	۲۰.....
شکل ۸.۲:	قشر مغز و لوب های مختلف آن	۲۲.....
شکل ۹.۲:	بخش های اصلی قشر بینایی	۲۳.....
شکل ۱۰.۲:	تقسیم بندی Brodmann	۲۴.....
شکل ۱۱.۲:	میدان تاثیر یک سلول ساده در V1	۲۵.....
شکل ۱۲.۲:	اتصال سلول های LGN به سلول های ساده و تشکیل میدان تاثیر	۲۶.....
شکل ۱۳.۲:	چیدمان نورون های V1 با جهت گیری های متفاوت	۲۷.....
شکل ۱۴.۲:	قشر اولیه بینایی (به رنگ طوسی) و نواحی فرامخطط شامل V2-V5	۲۸.....
شکل ۱۵.۲:	نواحی بالاتر قشر بینایی و دو گذرگاه شکمی و پشتی	۲۹.....
شکل ۱.۳:	یادگیری وابسته به زمان ضربه	۳۴.....
شکل ۲.۳:	ساختار پیش خور مدل یادگیری ویژگی های بصری	۳۶.....
شکل ۳.۳:	از هم باز کردن نمایش شی	۴۶.....
شکل ۴.۳:	ساختار لایه ای Neocognitron [۴۲]	۴۸.....
شکل ۵.۳:	اشتراک وزنی	۴۹.....

شکل ۱.۴:	نمونه تصاویر ورودی	۵۳.....
شکل ۲.۴:	نمونه میدان‌های تاثیر شبکه‌ی سلسله مراتبی	۵۷.....
شکل ۳.۴:	اتصالات در توپولوژی Maas	۶۲.....
شکل ۴.۴:	مشبک‌های استفاده شده برای ساخت شبکه‌های دنیای کوچک	۶۴.....
شکل ۵.۴:	اتصالات در توپولوژی دنیای کوچک	۶۵.....
شکل ۶.۴:	تعداد نوروهای فعال برای مدل‌های اتصال	۶۸.....
شکل ۷.۴:	میزان تفکیک‌پذیری برای مدل‌های اتصال	۷۰.....
شکل ۸.۴:	عملکرد طبقه‌بند LDA برای مدل‌های اتصال	۷۱.....
شکل ۹.۴:	عملکرد طبقه‌بند SVM برای مدل‌های اتصال	۷۲.....

فهرست جداول

جدول ۱.۴:	تعداد نمونه‌های ورودی	۵۳.....
جدول ۲.۴:	پارامترهای شبکه‌ی سلسله مراتبی و مقادیر انتخاب شده	۵۸.....
جدول ۳.۴:	مقادیر سه پارامتر مورد آزمایش برای شبکه‌ی سلسله‌مراتبی	۵۸.....
جدول ۴.۴:	بهترین عملکرد مدل‌های اتصال	۷۳.....

فصل ۱

مقدمه‌ای بر دستگاه عصبی

۱.۱ مقدمه

در این فصل به مروری کوتاه بر اجزای تشکیل دهنده‌ی دستگاه عصبی^۱ می‌پردازیم که بواقع با داشتن مسئولیت ادراک و کنترل دیگر اعضای بدن، می‌توان آن را مهمترین بخش از بدن موجودات زنده نامید. دستگاه عصبی تحت یک فرآیند فرگشت^۲ به چنان سطحی از تکامل رسیده است که به راستی آن را پیچیده‌ترین عنصر در جهان هستی معرفی می‌کنند. از خواص ویژه‌ی دستگاه عصبی می‌توان به تاثیرپذیری از محرک‌های خارجی، ایجاد یک جریان عصبی که نمایانگر تاثیر محرک می‌باشد و هدایت جریان عصبی از یک نقطه از دستگاه به نقاط دیگر نام برد.

دستگاه عصبی را می‌توان در سطوح مختلف، متناسب با اندازه و پیچیدگی عملکردشان، بررسی کرد. نورون^۳ اصلی‌ترین یاخته‌ی عصبی است و وظیفه‌ی انتقال اطلاعات عصبی را برعهده دارد. هر نورون تنها یک آکسون^۴ و چندین دارینه^۵ دارد که از طریق دارینه‌ها سیگنال را از نورون پیش‌سیناپسی دریافت و بعد از تجمع در جسم یاخته‌ای^۶ از طریق آکسون به نورون پس‌سیناپسی منتقل می‌کند. سیگنالی که از طریق آکسون مخابره می‌گردد منجر به ترشح یکسری مواد شیمیایی خاص، تحت عنوان

^۱ Nervous System


^۲ Evolutionary Process

^۳ Neuron

^۴ Axon

^۵ Dendrite

^۶ Soma



شکل ۱.۱: سوما، آکسون و دارینه‌ها

پیام‌رسان عصبی^۷، از طریق اتصال سیناپسی می‌شود که می‌تواند به برانگیختن^۸ یا مهار^۹ نورون‌های دریافت‌کننده‌ی سیگنال منتهی شود.

۲.۱ فیزیولوژی نورون

همانگونه که گفته شد، نورون‌ها واحدهای سازنده‌ی سیستم عصبی می‌باشند. تعداد نورون‌ها در گونه‌های مختلف جانوری متفاوت است و از چند نورون در کرم، ۱۰۰ هزار نورون در مگس و ۷۵ میلیون نورون در مغز موش متغیر است. در مغز انسان حدود ۱۰۰ بیلیون سلول عصبی یا نورون وجود دارد که هر کدام به طور متوسط به ۱۰ هزار نورون دیگر متصل است. پس در مجموع چیزی در حدود یک تریلیون اتصال سیناپسی وجود دارد.

اغلب نورون‌ها ساختاری به نسبت مشابه دارند اما با این حال عملکرد و وظایف نورون‌ها می‌تواند بسیار متفاوت باشد. نورون‌ها در اندازه، شکل و موقعیت قرارگیری با یکدیگر تفاوت دارند که تمام اینها وابسته به کاری است که یک نورون باید به طور مشخص انجام دهد. موارد مختلفی در تمایز نورون‌ها از دیگر سلول‌ها نقش دارد؛ از جمله اینکه آنها تقسیم نمی‌شوند و در طول عمر باقی مانده و نمی‌توانند جایگزین شوند. با وجود اینکه تقریباً تمام سلول‌های بدن به صورت شیمیایی با هم ارتباط دارند، می‌توان با اغماض گفت که تنها سلول‌های عصبی هستند که ارتباط الکتریکی دارند. مزیت

Neurotransmitter^۷
Excitation^۸
Inhibition^۹

ارتباط الکتروشیمیایی سرعت بسیار بالای آن است که امکان عمل و عکس‌العمل سریع را فراهم می‌کند.

عموما نورون به صورت سلولی مشاهده می‌شود که از دو قطب «ورودی» و «خروجی» تشکیل شده است. نورون‌ها از محیط خارج از خود، سیگنال‌هایی تحت قالب پالس‌های شیمیایی دریافت می‌کنند که منجر به تغییر حالت جاری آنها می‌شود. اگر تحت تاثیر این محرک‌های خارجی، شرایط بخصوصی در نورون برآورده شود، در مقابل سیگنالی از نورون به سمت خارج (سلول‌های عصبی یا ماهیچه‌ای) هدایت می‌شود. در ادامه با ساز و کار این مکانیسم و بخش‌های تشکیل دهنده‌ی نورون آشنا خواهیم شد.

۱.۲.۱ جسم سلولی (سوما)

بخش هسته‌دار نورون، جسم سلولی یا سوما خوانده می‌شود. شکل و اندازه‌ی جسم سلولی در نورون‌های مختلف متفاوت بوده و به اشکال مدور، بیضی، هرمی، دوزنقه‌ای و ستاره‌ای مشاهده شده است. قطر جسم سلولی نیز از چند میکرون تا چند صد میکرون می‌تواند متفاوت باشد. نورون بدون سوما وجود ندارد، اما به طور استثنا نورون‌هایی داریم که دارینه یا آکسون ندارند. جسم سلولی نورون را پریکاریون^{۱۰} نیز می‌نامند و به واقع کارخانه‌ی نورون محسوب می‌گردد زیرا پروتئین‌های لازم برای بخش‌های مختلف سلول توسط آن تولید می‌شود. سیتوپلاسم^{۱۱} و هسته^{۱۲} اجزای تشکیل دهنده‌ی سوما می‌باشند.

سیتوپلاسم سلول‌های عصبی را نوروپلاسم^{۱۳} می‌گویند که شامل شبکه‌ی آندوپلاسمی^{۱۴}، میتوکندری^{۱۵}، دستگاه گلژی^{۱۶} و دانه‌های لیزوزوم^{۱۷} بوده و وظایفی از جمله پروتئین‌سازی، فراهم کردن انرژی لازم برای سلول، غشاسازی و بسته‌بندی ترشحات نورونی را دارد.

هسته اما شاید مهمترین بخش سوما در نورون باشد. هسته‌ی نورون، معمار و بایگان سلول قلمداد

Perikaryon^{۱۰}

Cytoplasm^{۱۱}

Nucleus^{۱۲}

Neuropilasm^{۱۳}

Endoplasmic Reticulum^{۱۴}

Mitochondria^{۱۵}

Golgi Apparatus^{۱۶}

Lysosome^{۱۷}

می‌شود. به عنوان بایگان، شامل ژن‌های تشکیل دهنده‌ی DNA ای است که تاریخچه سلول را در خود نگه داشته و اطلاعات مبنای ساخت پروتئین‌های مشخصه آن سلول را تعیین می‌کند. به عنوان معمار، RNA را از روی DNA سنتز کرده و از طریق حفره‌ها به سیتوپلاسم می‌فرستد تا برای سنتز پروتئین استفاده گردد.

۲.۲.۱ غشای نورونی و کانال‌های یونی

به اتم‌هایی که بار الکتریکی داشته باشند یون گفته می‌شود. این بار می‌تواند مثبت یا منفی باشد و بسته به آن، بین یون‌ها رانش و ربایش بوقوع می‌پیوندد. در خارج از غشای نورون‌ها، یون‌های مختلف به وفور یافت می‌شود که اهم آنها عبارت است از سدیم (Na^+)، پتاسیم (K^+)، کلسیم (Ca^{++}) و کلرید (Cl^-). غشای نورون که از چربی تشکیل شده است مانع از شار آزاد یون‌ها شده و بدین ترتیب داخل نورون عموماً شاهد اختلاف پتانسیلی با خارج آن است. با این حال یکسری کانال یونی روی سطح غشا وجود دارد که کنترل جریان یون‌ها به داخل و خارج نورون را میسر می‌سازند. نورون‌ها همیشه به دنبال رساندن این اختلاف پتانسیل به یک مقدار تعادل^{۱۸} هستند. وقتی نورون در حالت استراحت است، داخل نورون نسبت به خارج آن مقدار منفی دارد.

کانال‌های یونی می‌توانند به صورت انتخابی بعضی از یون‌ها را به داخل یا خارج راه بدهند. در حالت استراحت، یون‌های پتاسیم به راحتی از غشا عبور می‌کنند اما یون‌های کلرید و سدیم به سختی امکان عبور دارند. برخی از کانال‌ها صرفاً بار مثبت، بعضی فقط بار منفی و برخی هم هر دو را برای سلول کنترل می‌کنند. بر اساس نوع کنترل، درگاه‌ها به دسته‌های زیر تقسیم‌بندی شده‌اند:

- **درگاه ولتاژی^{۱۹}:** این نوع درگاه تنها به اختلاف پتانسیل غشای نورون پاسخگو می‌باشد و بسته به اختلاف پتانسیل در هر لحظه، میزان عبور یون‌ها را کنترل می‌کند تا اختلاف پتانسیل به نقطه‌ی تعادل برسد.

- **درگاه شیمیایی^{۲۰}:** این کانال‌ها توسط لیگاندها کنترل شده و در صورت برخورد با مواد شیمیایی خاصی، باز می‌شوند. این مواد شیمیایی ممکن است از طریق سلول‌های دیگر یا ترشح

Equilibrium Point^{۱۸}Voltage-Sensitive^{۱۹}Ligand-Gated^{۲۰}

غدد درون‌ریز به نورون برسند.

• **درگاه مکانیکی^{۲۱}:** در پاسخ به تغییر شکل فیزیکی در گیرنده‌های حسی مانند لمس یا فشار تغییر حالت می‌دهند.

خواهیم دید که شرایط خاصی برای نورون رخ می‌دهد که اختلاف پتانسیل نورون را بیش از اندازه افزایش می‌دهد. در این صورت درگاه‌های ولتاژی برای رهایی از این وضعیت، خیلی سریع اقدام به باز و بسته شدن می‌کنند که به موجب آن یک شوک الکتروشیمیایی در سراسر سلول انتشار می‌یابد. این شوک که به آن ضربه یا اسپایک^{۲۲} گفته می‌شود به موجب وجود اتصالات نورونی، به سلول‌های عصبی دیگر نیز از طریق درگاه‌های شیمیایی انتقال پیدا می‌کند.

۳.۲.۱ دارینه

اکثر نورون‌ها یک بخش مشابه درخت دارند که به آن دارینه اطلاق می‌شود. مسئولیت دارینه دریافت اطلاعات از دیگر نورون‌ها است. دارینه‌ها به صورت زوائد متعدد، کوتاه و شاخه‌شاخه‌ای که از بدنه‌ی سلول گسترش یافته‌اند پیدا می‌شوند. در درون دارینه‌ها، میتوکندری، شبکه آندوپلاسمی، ریبوزوم‌ها و سایر ضمایم سیتوپلاسمی نورون‌ها یافت می‌شود. سطح خارجی دارینه‌ها دارای گیرنده‌های غشائی است که اطلاعات را از نورون‌های دیگر دریافت می‌کند.

۴.۲.۱ آکسون

علاوه بر زوائد کوتاهی که از پریکاریون خارج شده و دارینه نام داشتند، زائده‌ی بلندی با نام آکسون یا آسه خارج می‌شود. طول بلند این رشته امکان انتقال سریع سیگنال‌ها به فواصل بیشتر را می‌دهد. آکسون که می‌توان آن را به عنوان خروجی نورون در نظر گرفت، می‌تواند ضربه‌ها را به مقاصد به کوتاهی ۰/۱ میلی‌متر یا به بلندی ۲ متر برساند.

آکسون‌ها بر حسب میلین^{۲۳} بودن یا نبودن به دو دسته تقسیم می‌شوند. میلین یک لایه‌ی چربی است که آکسون را پوشانده و با عایق کردن آن و افزایش نارسانایی، سرعت انتقال پیام‌های الکتریکی

Mechanically Gated^{۲۱}

Spike^{۲۲}

Myelin^{۲۳}

در طول آکسون را افزایش می‌دهد. با این حال همه‌ی درازای آکسون از میلین پوشانده نشده و در فواصل برابر بخش‌هایی با نام گره رانویه^{۲۴} وجود دارند که پوشش میلین ندارند. گره‌های رانویه باعث می‌شوند که بار الکتریکی در نواحی بدون میلین القا شود و به جای اینکه بار الکتریکی کل مسیر آکسون را بپیماید، به صورت القایی نواحی آزاد را عبور کرده و انتقال سیگنال با سرعت به مراتب بالاتری صورت پذیرد. میلین در دستگاه اعصاب پیرامونی^{۲۵} بوسیله‌ی سلول‌های شوآن^{۲۶} و در دستگاه اعصاب مرکزی^{۲۷} توسط یک نوع بافت همبند عصبی به نام اولیگودندروگلیا^{۲۸} تشکیل می‌شود.

۵.۲.۱ سیناپس

سیناپس^{۲۹} یا همایه، یک ساختار در پایانه‌ی آکسون یک نورون (پیش‌سیناپسی) است که از طریق آن سیگنال به دارینه‌ی یک نورون دیگر (پس‌سیناپسی) منتقل می‌گردد. در اثر سیگنال رسیده از طریق سیناپس، نورون پس‌سیناپسی می‌تواند برانگیخته (افزایش اختلاف پتانسیل) یا مهار (کاهش اختلاف پتانسیل) شود که به نوعی نمود پردازش اطلاعات در مغز است.

سیناپس‌ها محل نمود شکل‌پذیری عصبی^{۳۰} و یادگیری هستند. به عبارتی خواص فیزیکی و شیمیایی سیناپس که شدت و قدرت سیگنال ارسال شده به نورون پس‌سیناپسی را مشخص می‌کند امکان تغییر دارد. این تغییرات ممکن است باعث کاهش یا افزایش پتانسیل القایی در نورون شده و به موجب آن فرکانس ضربه‌ها در نورون پس‌سیناپسی کمتر یا بیشتر شود. در واقع طبق نظر محققان علوم اعصاب، عمده‌ی یادگیری^{۳۱} مغز به جهت تنظیم «اثر^{۳۲}» ساختار سیناپسی (یا «وزن» در ادبیات علوم اعصاب محاسباتی) صورت می‌گیرد.

سیناپس‌ها می‌توانند در دو نوع دسته‌بندی گردند: الکتریکی و شیمیایی که با اینکه تعداد سیناپس الکتریکی کمتر است، ولی این نوع سیناپس در هر سیستم عصبی یافت می‌شود و اجازه‌ی جریان

^{۲۴} Nodes of Ranvier

^{۲۵} Peripheral Nervous System

^{۲۶} Schwann Cells

^{۲۷} Central Nervous System

^{۲۸} Oligodendrocyte

^{۲۹} Synapse

^{۳۰} Neuroplasticity

^{۳۱} Learning

^{۳۲} Synaptic Efficacy

مستقیم و منفعل الکتریکی را می‌دهد.

• **سیناپس الکتریکی:** در این نوع سیناپس، پایانه‌های پیش سیناپسی مستقیماً به پایانه‌های پس سیناپسی متصل هستند. یون‌ها و مولکول‌های کوچک عبور داده شده و در نتیجه تغییرات الکتریکی تقریباً بلافاصله به نورون پس سیناپسی منتقل می‌گردد. یون‌ها به طور کلی به هر دو جهت این اتصالات می‌توانند جریان داشته باشند. با این وجود، اتصالات الکتریکی که تنها در یک جهت انتقال صورت دهند وجود دارد، به این سیناپس‌ها عموماً اتصالات یکسوساز^{۳۳} می‌گویند که استفاده آنها در همزمان‌سازی^{۳۴} ضربه‌های نورون‌ها می‌باشد.

• **سیناپس شیمیایی:** این اتصالات پیچیده‌تر بوده و فاصله‌ی بین پایانه‌های پیش و پس سیناپسی به مراتب بزرگتر است. همچنین انتقال نه به صورت الکتریکی، بلکه به صورت شیمیایی و به وسیله‌ی پیام‌رسان‌های عصبی است. این مواد شیمیایی در کیسه‌هایی موسوم به کیسه‌های سیناپسی^{۳۵} در محل سیناپس‌های شیمیایی قرار دارند، با برخورد ضربه‌های آتش شده از نورون پیش سیناپسی به آنها، کیسه‌ها پاره شده و مواد داخل آنها آزاد می‌شود. حال اگر در آن محل، دریچه‌ای باشد که با ماده‌ی آزاد شده باز گردد، نورون پس سیناپسی از ضربه‌ی دریافت شده متأثر می‌شود. انواع مختلف این پیام‌رسان‌ها شناسایی شده‌اند که بسته به نوع آن (اسیدآمین، پپتید و مونوآمین)، شدت و اثر تقسیم‌بندی شده‌اند.

۳.۱ انواع نورون

همانگونه که گفته شد، با وجود شباهت‌های ساز و کار نورون‌ها، انواع مختلفی از نظر شکل و اندازه در بخش‌های مختلف دستگاه عصبی و گونه‌های مختلف جانوری شناسایی شده‌اند. نورون‌ها را می‌توان به طور کلی در سه دسته‌ی ذیل قرار داد:


• **نورون تک‌قطبی^{۳۶}:** این گونه از نورون‌ها صرفاً یک دنباله (آکسون) دارند که از سوما گسترش پیدا می‌کند. این نورون‌ها می‌توانند بسته به محیط، شاخه داده و آکسون یا دارینه

^{۳۳} Rectifying Junctions

^{۳۴} Synchronization

^{۳۵} Synaptic Vesicles

^{۳۶} Unipolar



شکل ۲۰۱: انواع نورون‌ها (تک‌قطبی، دوقطبی و چندقطبی)

تشکیل دهند. این نورون‌ها بیشتر در حشرات یافت می‌شود که سوما در پیرامون مغز قرار گرفته و از نظر الکتریکی غیرفعال هستند. در این نورون‌ها، عموماً یک رشته نئوریت^{۳۷} از سوما به مغز می‌رود که البته ممکن است به شاخه‌های فراوانی بیانجامد و اتصالات بسیار پیچیده‌ای با نئوریت‌های دیگر برقرار کند.

• **نورون دوقطبی^{۳۸}:** این گونه از نورون‌ها دارای دو دنباله از سوما که یکی آکسون و دیگری دارینه است می‌باشد. این نورون‌ها عموماً در عملکردهای حسی، مانند بویایی، شنوایی، لامسه و بینایی دیده می‌شوند. مثال معمول آن، نورون‌های دوقطبی در شبکیه‌ی چشم یا فراوانی آنها در مسیر وایران سیگنال‌های حرکتی به عضله‌های حرکتی است.

• **نورون چندقطبی^{۳۹}:** این نورون‌ها دارای یک آکسون و همچنین تعدادی دارینه هستند. اکثر نورون‌های مغز بخصوص نورون‌های حرکتی و نورون‌های میانی از این دسته هستند.

۴.۱ قانون هب

نقش اساسی شکل‌پذیری^{۴۰} در میانجیگری در اتصالات و فعالیت شبکه‌ی نورونی به صورت مفهومی در قالب نظریه‌ی هب^{۴۱} بیان می‌شود. دونالد هب ادعا می‌نمود که از طریق مکانیسمی زیست‌فیزیکی، نورون‌ها در قالب رد عصبی^{۴۲} سازمان پیدا می‌کنند؛ ساختارهای عصبی که امکان ذخیره‌ی رد حافظه را دارند. شاید نقل قول زیر [۱] از هب بهترین توضیح برای ادعای او باشد:

“فرض کنید ماندگاری یا تکرار یک فعالیت ارتعاشی به القای تغییرات پایای سلولی منجر شود که به پایداری آن بیافزاید. زمانی که آکسون سلول A به اندازه‌ی کافی نزدیک باشد که به برانگیختن سلول B منجر شده و به صورت مداوم یا مکرر در آتش کردن آن نقش داشته باشد، یک فرآیند رشد یا تغییرات متابولیک در یک یا هر دو سلول رخ می‌دهد که در نتیجه‌ی آن بازده A به عنوان یکی از سلول‌های آتش‌کننده‌ی B افزایش می‌یابد.”

در علوم اعصاب به چنین اتصالی، «سیناپس هب» گفته می‌شود. این ادعا پشتیبانی تجربی قابل‌توجهی را کسب کرد، بخصوص با کشف تقویت بلند مدت^{۴۳} (LTP) و تضعیف بلند مدت^{۴۴} (LTD) که اولین بار در هیپوکمپوس^{۴۵} یافت شده [۲] و بعدها در نواحی دیگری مانند آمیگدال^{۴۶} و نئوکشر^{۴۷} نیز مشاهده شد. در علوم شناختی و علوم اعصاب محاسباتی این طرح پیشنهادی تحت عنوان «قاعده‌ی هب» شناخته شده و الگوریتم‌های یادگیری برای تنظیم وزن‌های اتصالات بر مبنای آن ارائه شده است.

۱.۴.۱ یادگیری وابسته به زمان ضربه

یادگیری وابسته به زمان ضربه^{۴۸} (STDP) یک مصداق مشخص از ادعای هب است که میزان تغییرات سیناپسی را به ترتیب زمانی پتانسل‌های عمل (ضربه‌ها) ربط می‌دهد. STDP اولین بار بواسطه‌ی

^{۴۰} Plasticity
^{۴۱} Hebbian theory
^{۴۲} Engram
^{۴۳} Long-term potentiation
^{۴۴} Long-term depression
^{۴۵} Hippocampus
^{۴۶} Amygdala
^{۴۷} Neocortex
^{۴۸} Spike-timing dependent plasticity

مشاهدات تجربی لوی و ستیوارد [۳] که منجر به مطالعات نظری گردید به منصفه ظهور رسید. STDP در شکل کاملش توسط مارکرام و همکارانش [۴] در شبکه‌های قشری و به طور همزمان توسط بل و همکارانش [۵] در ساختار مخچه‌مانند ماهی الکتریکی تبیین شد.

هم اکنون STDP در سیناپس‌های برانگیزاننده از گستره‌ی وسیعی از مدارات عصبی مانند قشر بینایی، هیپوکمپوس، هسته‌ی پشتی حلزونی^{۴۹}، دستگاه بویایی ملخ و... مشاهده شده است.

برجسته‌ترین مشخصه‌ی STDP در وابسته بودن تغییرات سیناپسی به ترتیب زمانی زوج‌های ضربه‌ی پیش و پس‌سیناپسی است. به استثنای مواردی مانند ساختار مخچه‌مانند ماهی الکتریکی، اکثر مشاهدات تجربی نشان داده‌اند که وقتی یک ضربه‌ی پیش‌سیناپسی مقدم بر ضربه‌ی پس‌سیناپسی می‌شود، سیناپس تقویت می‌شود و در مقابل وقتی ترتیب زمانی معکوس باشد، سیناپس تضعیف خواهد شد. از این جهت STDP بر رابطه‌ی علیّ میان نورون‌ها می‌افزاید. این مشاهدات موجب شده تا مدل‌های مبتنی بر زوج STDP ارائه گردد که تغییرات سیناپسی را بر اساس فاصله‌ی زمانی بین زوج‌های ضربه‌ی پیش و سیناپسی بیان می‌کنند. این دسته از مدل‌ها توانایی ساماندهی عملکردی مدارات عصبی را داشته و رخدادهای بسیاری، به مانند تشکیل میدان‌های تاثیر^{۵۰}، رشد میزان‌سازی جهت^{۵۱} و گزینندگی مسیر^{۵۲} در قشر بینایی، تشکیل سلول‌های مکان^{۵۳} در هیپوکمپوس و یادگیری دنباله‌های زمانی را توضیح می‌دهد.

در فصول بعدی به ابعاد بیشتری از مکانیسم STDP پرداخته و سازوکار آن را با بیان مدل ریاضیاتی مطرح می‌کنیم.

^{۴۹} Dorsal cochlear nucleus^{۵۰} Formation of receptive fields^{۵۱} Development of orientation tuning^{۵۲} Direction selectivity^{۵۳} Place cells

فصل ۲


دستگاه بینایی انسان

۱.۲ مقدمه

بینایی را شاید بدون اغراق مهم‌ترین حس بشر و اغلب موجودات زنده دانست. توسط بینایی است که ما امکان لذت بردن از غروب آفتاب یا یک اثر هنری، شناختن چهره‌ی آشنای یک فرد در خیابان یا تشخیص کج بودن یک تابلو روی دیوار را پیدا می‌کنیم. اینکه ما به راحتی امکان تشخیص تغییرات بسیار جزئی رنگ یا شکل را تحت وضعیت‌های روشنایی متفاوت داریم به راستی امری شگفت‌انگیز است. در واقع اینکه اینقدر بدون زحمت و به سادگی این وظایف را صورت می‌دهیم، ممکن است پیچیدگی آن را نهان کرده و پندار اشتباه ساده بودن مبنای این عملکرد را بوجود بیاورد. این در حالی است که بخش بزرگی از مغز، چیزی حدود ۵۳٪ آن، در پردازش بصری نقش دارد.

نگاهی دقیق‌تر بر مراحل اولیه‌ی دستگاه بینایی می‌تواند تا حد زیادی به درک ما از مشکلات و پیچیدگی وظایف آن کمک کند. نوری که بر شبکه‌ی چشم^۱ تابیده می‌شود، یک آرایه از گیرنده‌های نوری^۲ را تحریک می‌کند؛ چیزی شبیه آنچه با پیکسل‌های یک دوربین دیجیتال صورت می‌گیرد. بر اساس یک توزیع همیشه در حال تغییر از شدت نور اندازه‌گیری شده، مغز می‌بایست ویژگی‌های ناورد^۳ و غیرحساس به جهان خارج، همانند اشیای مختلف در فواصل و زوایای گوناگون که بعضاً ممکن

^۱ Retina
^۲ Photoreceptors
^۳ Invariant



شکل ۱۰۲: ساختار چشم انسان

است تار شده^۴ یا نمای آنها توسط چیز دیگری مسدود شده^۵ باشد، را استخراج کند. حتی گام‌های ابتدایی از این فرآیند مانند کنتراست، تشکیل لبه‌ها و خطوط، تشخیص گوشه‌ها و نقاط تقاطع و نمایش کیفی سطوح، اموری هستند که به هیچ عنوان نمی‌توان آنها را پیش‌پا افتاده خواند. تلاش‌ها و مطالعات اولیه که در بینایی ماشین^۶ صورت گرفته به واقع بر دشواری حتی ساده‌ترین امور در سیستم‌های بینایی صحنه می‌گذارد.

فهم دستگاه بینایی با درون‌نگری^۷ مقدور نیست. علوم تجربی مانند روان‌فیزیک^۸ در علوم اعصاب رفتاری و فیزیولوژی تا حد زیادی دانش ما را از فرآیندهای اساسی و بنیادین به پیش برده است. روش‌های مدل‌سازی محاسباتی^۹ نیز از طرفی به تجمیع یافته‌های گوناگون از تخصص‌های مختلف و یکپارچه کردن آنها در یک چارچوب واحد کمک می‌کند.

۲.۲ شبکه

ادراک بینایی از شبکه‌ی چشم آغاز می‌شود. پرتوهای منعکس شده از یک جسم با عبور از عدسی به شبکه می‌رسند و طرحی را در پشت چشم ترسیم می‌کنند که توسط گیرنده‌های حسی به سیگنال‌های

^۴Obscured

^۵Occluded

^۶Computer Vision

^۷Introspection


^۸Psychophysics

^۹Computational Modeling

الکتریکی تبدیل خواهند شد که ارسال آنها به مراکز بالاتر در مغز خط سیر بینایی را آغاز می‌کند. مطالعه‌ی شبکه به دو دلیل اصلی از اهمیت بسیاری برخوردار است. نخست اینکه نقش بلامنازعی در کمک به درک انتقال اطلاعات حسی و همچنین به عنوان یکی از مراحل اصلی بینایی دارد. از همین رو گیرنده‌های نوری در شبکه‌ی چشم از نظر حجم مطالعه‌ی صورت گرفته روی آنها شاید یکی از شناخته شده‌ترین سلول‌های حسی محسوب می‌شوند. دوم اینکه برخلاف سایر عناصر حسی مانند گیرنده‌های لامسه یا ساختار حلزونی در گوش، شبکه عضوی جانبی نبوده و بلکه بخشی از دستگاه عصبی مرکزی محسوب می‌گردد. شباهت ساختاری سیناپس‌های شیمیایی شبکه به عناصر دیگر تشکیل دهنده‌ی دستگاه عصبی مرکزی و سادگی نسبی ساز و کار آن نیز از عوامل انگیزش مطالعه‌ی آنها محسوب می‌شود.

نور بازتاب شده از محیط پیرامون از طریق عدسی^{۱۰} و قرنیه^{۱۱} متمرکز شده و بعد از عبور از مایع زجاجیه^{۱۲} که فضای حفره چشم را پر کرده و شکل کروی چشم را حفظ می‌کند به گیرنده‌های نوری در شبکه می‌رسد. شبکه در جلوی یک لایه از سلول‌های اپیتلیوم رنگدانه‌دار^{۱۳} که پشت چشم را پوشانده‌اند قرار دارد. سلول‌های بافت اپیتلیوم که رنگدانه‌ی سیاه بسیاری دارند، هر نوری که به شبکه برخورد نکرده را جذب می‌کنند. این لایه از انعکاس نور به پشت چشم و بازتاب آن که می‌تواند باعث کاهش وضوح تصویر شود جلوگیری می‌کند. شبکه داخلی‌ترین لایه‌ی چشم بوده و از سلول‌های گیرنده‌ی نوری (مخروطی^{۱۴} و استوانه‌ای^{۱۵}) تشکیل شده است. شبکه بسیار نازک بوده (حدود نیم میلی‌متر) و حدود ۷۵٪ سطح کره‌ی چشم را می‌پوشاند. لکه‌ی زرد^{۱۶} بخشی از شبکه است که در امتداد محور نوری کره‌ی چشم در راستای مردمک و در نزدیکی مرکز شبکه قرار داشته و بیشترین حساسیت به نور را دارد و در دقت و تیزبینی چشم نقش مهمی ایفا می‌کند. گودی مرکزی^{۱۷} که بیشترین تراکم سلول‌های مخروطی چشم را دارد در لکه‌ی زرد قرار گرفته است. خروج عصب بینایی قسمتی از شبکه را تشکیل می‌دهد که فاقد گیرنده‌های نوروی هست و در نتیجه این بخش که تحت عنوان

Lens^{۱۰}Cornea^{۱۱}Vitreous body^{۱۲}Pigment epithelial cells^{۱۳}Cone cell^{۱۴}Rod cell^{۱۵}Macula^{۱۶}Fovea^{۱۷}



شکل ۲.۲: چپ: برش مماس از گودی مرکزی که چینش گیرنده‌های مخروطی عادی شش ضلعی را نشان می‌دهد. [۶] راست: نمای عمودی گیرنده‌های نوری [۷]

نقطه کور^{۱۸} شناخته می‌شود فاقد بینایی است.

۱.۲.۲ گیرنده‌های نوری

شبکیه در چشم انسان از دو نوع سلول تشکیل شده است: استوانه‌ای و مخروطی. سلول‌های مخروطی مخصوص دید در روز^{۱۹} بوده و در نور قوی بیشتر فعال می‌شوند. در مقابل سلول‌های استوانه‌ای مخصوص دید در شب^{۲۰} بوده و بیشتر در نور ضعیف تحریک شده و توانایی دیدن در تاریکی را فراهم می‌کنند. سلول‌های استوانه‌ای به رنگ‌ها حساسیت نشان نمی‌دهند و به همین جهت بینایی در تاریکی به صورت طیفی از خاکستری درک می‌شود. افرادی که سلول‌های مخروطی چشم‌شان را از دست می‌دهند نابینا محسوب می‌گردند در حالی که آسیب به سلول‌های استوانه‌ای منجر به شب‌کور^{۲۱} می‌شود. همچنین بیشترین تمرکز سلول‌های مخروطی در لکه‌ی زرد است، در حالی که بیشترین تمرکز سلول‌های استوانه‌ای در بخش‌های پیرامونی شبکیه است. در انسان سه گونه سلول مخروطی وجود دارد که هر کدام از آنها رگنده‌های متفاوتی داشته و به طول موج مختلف (ولی دارای همپوشانی) از طیف نور، متناظر با رنگ‌های قرمز، سبز و آبی، واکنش نشان می‌دهند.

^{۱۸} Blind spot

^{۱۹} Photopic

^{۲۰} Scotopic


^{۲۱} Nyctalopia

۲.۲.۲ سلول‌های گانگلیون

سلول‌های گانگلیون^{۲۲} (یا عقده‌ای) خروجی شبکیه‌ی چشم محسوب می‌شوند. کل دنیای تصویری که ما درک می‌کنیم در الگوهای آتش سلول‌های گانگلیون کد می‌شود. سلول‌های گانگلیون ورودی خود را از نورون‌های بینابینی در شبکیه دریافت کرده و آکسون آنها از طریق عصب باصره^{۲۳} به بخش‌های بالاتر در مغز، به خصوص هسته‌ی زانویی جانبی^{۲۴} منتقل می‌شود. بین گیرنده‌های نوری و سلول‌های گانگلیون سه گروه نورون بینابینی^{۲۵} وجود دارند: سلول‌های دوقطبی^{۲۶}، سلول‌های افقی^{۲۷} و سلول‌های آماکرین^{۲۸}. این سلول‌ها صرفاً سیگنال الکتریکی حاصل از تحریک گیرنده‌های نوری را منتقل نمی‌کنند، بلکه به گونه‌ای سیگنال‌های چند گیرنده‌ی نوری را با هم ترکیب می‌کنند که پاسخ الکتریکی به طور دقیق به طرح‌های فضایی و زمانی تحریک کننده‌ی نور وابسته و متکی باشد.

یافته‌های ارزشمند هارتلاین و گرانت^[۹] که در سال ۱۹۶۷ جایزه‌ی نوبل را برای آنها به ارمغان آورد، بر اساس ثبت الکتریکی پاسخ تک نورون‌های گانگلیون نشان داد که پاسخ نورون‌های گانگلیون به یک ناحیه خاص از شبکیه که میدان تاثیر^{۲۹} (RF) نام دارد وابسته است. سازمان RF یک سلول گانگلیون سه ویژگی دارد: مدور بودن^{۳۰}: میدان تاثیر این سلول‌ها تقریباً مدور هستند. ساختار متضاد مرکز-اطراف^{۳۱}: میدان تاثیر به دو بخش مدور مرکزی و حلقه‌ی محیطی تقسیم می‌شود. این زیرمیدان‌ها^{۳۲} با هم در تضاد بوده و تخاصم دارند؛ به این معنی که نور در حلقه‌ی محیطی در پاسخ سلول، اثر متمم نسبت به تاباندن نور در بخش مرکزی دارد. خط‌سیرهای موازی داخل و خارج^{۳۳}: دو نوع مختلف سلول گانگلیون داریم، سلول‌های «مرکز روشن - محیط خاموش» که به نقطه روشن با حلقه‌ی تاریک در دور بهترین پاسخ را داده و سلول‌های «مرکز خاموش - محیط روشن» که به عکس این محرک (نقطه‌ی تاریک با حلقه‌ی روشن) بهترین پاسخ را می‌دهد. این دو خط‌سیر موازی هستند؛

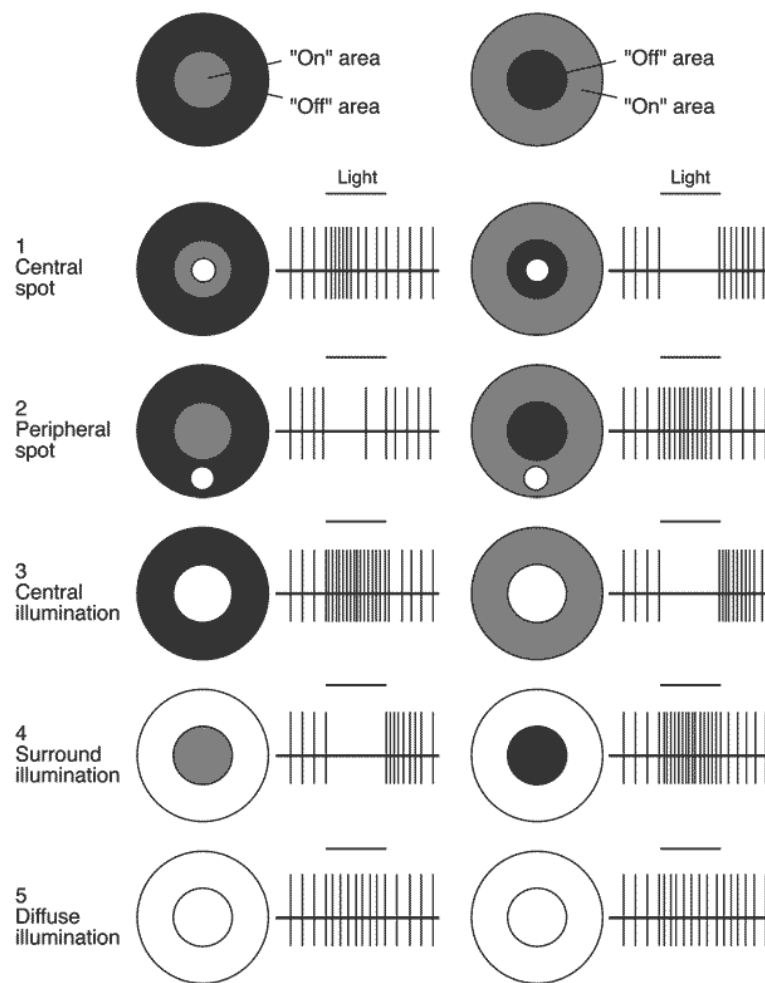
Ganglion cells^{۲۲}Optic nerve^{۲۳}Lateral geniculate nucleus^{۲۴}Interneurons^{۲۵}Bipolar cells^{۲۶}Horizontal cells^{۲۷}Amacrine cells^{۲۸}Receptive field^{۲۹}Circularity^{۳۰}Antagonistic center-surround organization^{۳۱}Subfields^{۳۲}Parallel on- and off-pathways^{۳۳}



شکل ۳.۲: سه دسته کلاس نورونی در شبکیه: گیرنده‌های نوری (استوانه‌ای و مخروطی) در لایه هسته خارجی قرار گرفته‌اند. نورون‌های بینایی (دوقطبی، افقی و آمکرین) در لایه میانی و سلول‌های گانگلیون در لایه گانگلیون قرار دارند. گیرنده‌های نوری، سلول‌های دوقطبی و افقی با هم در لایه شبکه‌وار خارجی ارتباط سیناپسی برقرار می‌کنند. سلول‌های دوقطبی، آمکرین و گانگلیون نیز در لایه شبکه‌وار داخلی با هم ارتباط دارند. اطلاعات به صورت عمودی از گیرنده‌های نوری به سلول‌های دوقطبی و بعد به گانگلیون رفته و همچنین به صورت جانبی از طریق سلول‌های افقی در لایه شبکه‌وار خارجی و سلول‌های آمکرین در لایه شبکه‌وار داخلی جریان پیدا می‌کنند. [۸]

به این معنی که تقریباً به تعداد مساوی سلول مرکز روشن - محیط خاموش و مرکز خاموش - محیط روشن داشته و هر گیرنده‌ی نوری خروجی را به هر دو خط‌سیر می‌فرستد. در هر دو نوع سلول، پاسخی که با تابش به مرکز ایجاد می‌شود پاسخی را که در اثر تابش نور به محیط ایجاد می‌گردد را به طور کامل از بین می‌برد.

اندازه‌ی میدان تاثیر سلول‌های گانگلیون یکنواخت نیست، بلکه بسته به فاصله از گودی مرکزی تغییر می‌یابد. در گودی مرکزی، مراکز میدان تاثیر قطری حدود چند دقیقه قوس دارند در حالی که در نواحی جانبی قرار گرفته در حواشی، میدان تاثیر حتی به بزرگی ۵ درجه نیز می‌رسد. هر درجه برابر ۶۰ دقیقه بوده و معادل حدود ۰/۲۵ میلی‌متر است.




شکل ۴.۲: سلول‌های گانگلیون در حالت بهینه به کنتراست در میدان تاثیرشان پاسخ می‌دهند. [۸]

۳.۲.۲ هسته‌ی زانویی جانبی

هسته‌ی زانویی جانبی (LGN^{34}) مقصد اصلی سلول‌های گانگلیون است. LGN یک زیرساختار از تالاموس^{۳۵} (نه‌نج) می‌باشد. هر نیمکره از مغز دارای یک LGN می‌باشد. LGN یک ساختار پیچیده‌ی ۶ لایه‌ای بوده و تعداد نورون آن تقریباً برابر تعداد کل سلول‌های گانگلیون است (حدود ۱/۵ تا ۱/۸ میلیون سلول). تالاموس وظیفه‌ی هماهنگی بین گیرنده‌های حسی و قشر مغز را داشته و با تقویت سیگنال‌های ورودی، آنها را به نواحی مختلف مغز رله می‌کند.

^{۳۴}Lateral Geniculate Nucleus
^{۳۵}Thalamus



شکل ۵.۲: ترسیمی از میدان تاثیر سلول‌های ساده. نواحی روشن نمایانگر زیرمیدان‌های تحریکی و نواحی تاریک زیرمیدان‌های مهارای را نشان می‌دهند. میدان تاثیر سلول‌های درون‌جاننداری به این منظمی نبوده ولی همین ساختار ابتدایی را دارد. سلول‌های ساده قادر به تشخیص خط در یک جهت، اندازه و محل مشخص هستند.

۴.۲.۲ ستون‌های جهت‌گیری و میدان تاثیر V1

در شبکه و همچنین LGN میدان تاثیر سلول‌ها مدور بود. در قشر بینایی اولیه^{۳۶} یک تفاوت عمده در میدان‌های تاثیر صورت می‌گیرد: اکثر سلول‌ها میدان‌های تاثیری کشیده داشته و بهترین پاسخ را به خطوط، میله^{۳۷} یا یکسری میله^{۳۸} که در یک جهت مرجح قرار گرفته‌اند می‌دهند. این یافته‌ها در نتیجه‌ی تحقیق پیشگامی است که برای دیوید هابل و تورستن ویزل جایزه‌ی نوبل را در سال ۱۹۸۱ به ارمغان آورد [۱۰].

بر اساس یافته‌های هابل و ویزل، سلول‌ها به دو دسته‌ی اصلی ساده و پیچیده تقسیم می‌شوند. سلول‌های ساده دو یا سه زیرمیدان کشیده‌ی جدا با پاسخ‌های روشن و خاموش متناوب داشته و یک محور جهت^{۳۹} مشخص دارند. موثرترین محرک برای آنها، الگویی از تکه‌های روشن و خاموش است که با زیرمیدان‌های میدان تاثیر تلاقی کند؛ برای مثال یک خط یا میله در یک جهت مشخص. همان محرک با جهتی متعامد یا حتی مورب بدون پاسخ بوده یا صرفاً منجر به پاسخی کوچک می‌شود. چنین محرکی برای یک سلول ساده‌ی دیگر با میدان تاثیر در همان موقعیت، بیشترین پاسخ را زمانی می‌دهد که جهت ارجح خودش را داشته باشد. بنابراین هر نقطه از میدان بینایی به صورت موازی توسط سلول‌های ساده که هر کدام جهت مرجح خود را دارند تحلیل می‌شود. جهت‌های ارجح در فواصل گسترده‌ی حدود ۱۰° قرار داشته و بنابراین حدود ۱۸ جهت مختلف در گستره‌ی ۱۸۰° داریم.


سلول‌های پیچیده یک جهت ارجح و همچنین میدان تاثیر بزرگتر دارند که، برخلاف سلول‌های

^{۳۶} Primary visual cortex

^{۳۷} Bar

^{۳۸} Gratings

^{۳۹} Axis of orientation



شکل ۶.۲: تفاوت پاسخ سلول‌های ساده و پیچیده

ساده، نمی‌توان آن را به زیرمیدان‌های روشن و خاموش متمایز تقسیم کرد. این سلول‌ها همانند سلول‌های ساده به یک جهت خاص پاسخ می‌دهند ولی برخلاف آنها حساسیت کمتری نسبت به اندازه و محل قرارگرفتن محرک دارند. به عبارت دیگر، سلول‌های پیچیده حساس به زاویه و غیرحساس به اندازه و محل محرک می‌باشند. خصوصیات سلول‌های پیچیده از عمل ادغام^{۴۰} کردن سلول‌های ساده با موقعیت میدان تاثیر متفاوت، ولی با جهت یکسان بدست می‌آید.

سلول‌های ساده و پیچیده در ستون‌های جهت‌گیری عمودی سازمان یافته‌اند. سلول‌های ساده و پیچیده در هر ستون، محور جهت یکسان داشته و میدان تاثیر آنها تقریباً در موقعیت مشابه است. هر ستون جهت‌گیری از سطح خارجی قشر شروع شده و تا ماده‌ی سفید ادامه می‌یابد و همه‌ی لایه‌های قشری را دربرمی‌گیرد. بنابراین یک جهت خاص در یک نقطه‌ی مشخص از میدان بینایی توسط سلول‌های ساده و پیچیده از سطوح مختلف انتزاعی در لایه‌های مختلف یک ستون جهت‌گیری صورت می‌گیرد. خط‌سیر بینایی پس از قشر بینایی اولیه به دو مسیر پشتی^{۴۱} و شکمی^{۴۲} تقسیم می‌شود. در طول هر کدام از این خطوط سیر، مغز به اطلاعات خاصی از تصویر دست پیدا می‌کند. مسیر پشتی برای یافتن کجایی^{۴۳} شی و مسیر شکمی برای یافتن چیستی^{۴۴} شی است.


^{۴۰} Pooling

^{۴۱} Dorsal stream

^{۴۲} Ventral stream

^{۴۳} Where pathway

^{۴۴} What pathway



شکل ۷.۲: محل پردازش بخش‌های مختلف میدان دید در قشر بینایی مغز

۳.۲ خط‌سیر بینایی

میدان دید، همانطور که در شکل ۷.۲ مشاهده می‌کنید، از دو قسمت تشکیل شده است: منطقه دید دوچشمی که توسط هر دو چشم دریافت می‌شود و منطقه دید یک چشمی که صرفاً توسط یکی از چشم‌ها دریافت می‌شود.

وقتی یک شی در منطقه‌ی یک چشمی راست قرار بگیرد، بازتاب نور از آن به نیمه سمت بینی شبکیه چشم راست می‌رسد. اگر شی در منطقه‌ی دوچشمی میدان دید قرار داشته باشد، بازتاب نور به نیمه سمت بینی شبکیه‌ی چشم راست و همچنین منطقه‌ی نیمه گیجگاهی چشم چپ خواهد رسید [۶]. ورودی‌هایی که به نیمه سمت بینی شبکیه می‌رسند پس از تطبیق به تالاموس (مرکز پردازش داده‌های حسی) سمت مقابل رفته و سپس به قشر مغز نیم‌کره‌ی مقابل می‌روند؛ اما ورودی رسیده به منطقه نیمه گیجگاهی بدون تطبیق به تالاموس و سپس قشر نیم‌کره‌ی سمت خود می‌روند.

اگر جسمی در سمت راست میدان بینایی قرار بگیرد، به روی نیمه گیجگاهی چشم چپ و همچنین

بر روی نیمه سمت بینی چشم راست ظاهر می‌شود. فیبرهای نیمه سمت بینی شبکیه در چلیپای نوری^{۴۵} به سمت مقابل رفته و فیبرهای نیمه گیج‌گاهی شبکیه هر طرف به تالاموس خود می‌روند. بنابراین در این حالت محرک در سمت راست خط مرکزی عمودی قرار گرفته است و اطلاعات آن از طریق نیمه گیج‌گاهی چشم چپ به تالاموس چپ و از طریق نیمه سمت بینی شبکیه چشم راست (بعد از تقاطع فیبرها در چلیپای نوری) به قشر سمت چپ انتقال می‌یابد. به این ترتیب همه اطلاعات جسمی که در سمت راست میدان دید قرار گیرد در نیمکره‌ی چپ مغز و همه اطلاعات جسمی که در سمت چپ باشد در نیمکره‌ی سمت راست مغز پردازش می‌شود. همانطور که تبیین شد، سازمان‌بندی بینایی بر اساس چشم چپ و راست صورت نگرفته بلکه بر اساس میدان بینایی و دو نیمه‌ی چپ و راست آن می‌باشد که اطلاعات به نیم‌کره‌ی راست یا چپ می‌رود.

۴.۲ ساختار قشر بینایی مغز

قشر مغز^{۴۶} لایه‌ی نازک خاکستری پوشاننده‌ی سطح مغز است که از سلول‌های عصبی تشکیل شده است و ضخامتی بین ۲ تا ۴ میلی‌متر دارد. این قشر وظایف پیچیده‌تر مغز همانند حافظه، یادگیری، حل مسئله، طرح ریزی، پردازش زبان، بینایی، شنوایی و حرکت را تحت کنترل دارد. قشر مغز از لحاظ آناتومی به دو نیم‌کره و چهار لوب (شکل ۸.۲) تقسیم می‌شود:

- **لوب گیج‌گاهی^{۴۷}:** ذخیره حافظه جدید، پردازش اطلاعات حواس شنوایی، درک زبان و سازماندهی از کارکردهای این لوب از مغز هستند.
- **لوب آهیانه‌ای^{۴۸}:** حس لامسه، ادراک فضایی، ادراک دیداری، بازشناسی اندازه‌ها، رنگ و اشکال از یکدیگر و احساس درد از کارکردهای این لوب است. این قسمت همچنین در نوشتن و بخشی از جنبه‌های خواندن نیز دخیل می‌باشد.
- **لوب پیشانی^{۴۹}:** محتوای شخصیتی، چاره‌یابی، هیجانات، تمرکز، دآوری، سخن گفتن و


^{۴۵} Optic chiasm

^{۴۶} Cerebral cortex

^{۴۷} Temporal lobe

^{۴۸} Parietal lobe

^{۴۹} Frontal lobe



شکل ۸.۲: قشر مغز و لوب‌های مختلف آن

حرکات ارادی از کارکردهای لوب پیشانی محسوب می‌شوند. این بخش در ارتباط با توابع شناختی سطح بالا مانند استدلال و قضاوت است.

لوب پس‌سری^{۵۰}: این لوب عقب‌ترین بخش مغز است و قسمت کوچکی از سطح پشتی-جانبی آن را تشکیل می‌دهد. لوب پس‌سری دربرگیرنده‌ی قشر اولیه بینایی بوده و مرکز پردازش اطلاعات دیداری در پستانداران محسوب می‌شود.

شکل ۹.۲ تقسیم‌بندی بخش‌های مختلف قشر بینایی مغز را نشان می‌دهد که V1 و V2 بزرگترین بخش‌ها هستند. فیزیولوژیست‌ها با مطالعه‌ی این قشر گذرگاه‌های متفاوتی را کشف کرده‌اند. اطلاعاتی که از تالاموس به V1 می‌رسد، در دو مسیر جداگانه و به صورت مستقل پردازش می‌شود:

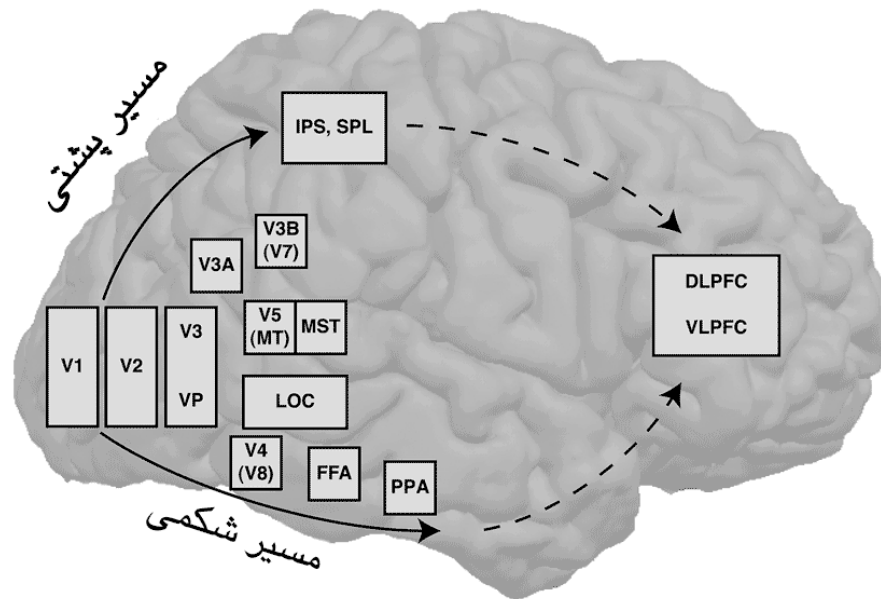
• **گذرگاه چیستی^{۵۱}:** گذرگاه چیستی اطلاعات مربوط به چیستی اشیاء مانند رنگ، شکل و بافت را پردازش می‌کند. لوب پس‌سری و گیجگاهی در این گذرگاه دخیل بوده و در مسیر V1، V2، V4، PIT و AIT قرار دارند.

گذرگاه کجایی^{۵۲}: گذرگاه کجایی اطلاعات مربوط به مشخصات فضایی شیء مانند حرکت و عمق شیء را پردازش می‌کند. لوب پس‌سری و آهیانه‌ای در این گذرگاه دخیل بوده و در مسیر V1، V2، V3، MT و MST قرار دارند.

^{۵۰} Occipital lobe

^{۵۱} What stream

^{۵۲} Where stream



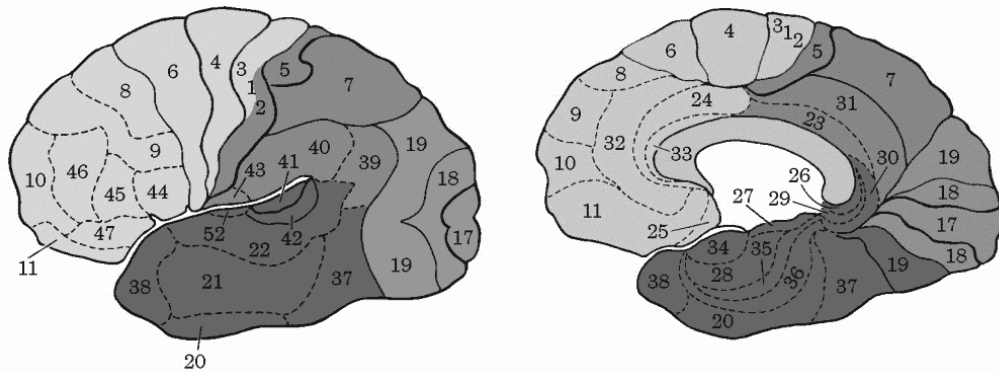
شکل ۹.۲: بخش‌های اصلی قشر بینایی: نواحی بینایی در مغز در مسیرهای پشتی (پس‌سری و گیج‌گاهی) و شکمی (پس‌سری و آهیانه‌ای) سازمان یافته‌اند. فرضیات نشان می‌دهند که هر دوی این مسیرها به قشر پیش‌پیشانی ختم می‌شوند. لازم به ذکر است که این مسیرها تنها از اتصالات پیش‌خور (روبه‌جلو) تشکیل نشده و حجم زیادی از اتصالات بازخورد وجود دارد.

به طور مثال، اگر یک فرد یک اتومبیل در حال حرکت را مشاهده کند، با کمک مسیر چپستی، اتومبیل بودن آن و به وسیله‌ی مسیر کجایی، حرکت و جهت آن تشخیص داده می‌شود. گذرگاه چپستی و گذرگاه کجایی دو مصداق پردازش موازی، به معنای توزیع همزمان اطلاعات در گذرگاه‌های عصبی مغز، هستند. علی‌رغم موازی بودن گذرگاه چپستی و کجایی، اتصال آنها منجر به ادغام اطلاعات حسی و ترسیم تصویر کاملی از دنیای بیرون می‌شود.

۱.۴.۲ ناحیه V1

پیشتر اشاره شد که شبکه تصویر را به نقاطی که میزان درخشندگی مشخصه‌ی خاصی آنها می‌باشد تجزیه می‌کند. نورون‌های قشر بینایی در مقابل می‌بایست اطلاعات تجزیه شده را بازسازی کنند. اولین قدم در بازسازی در قشر V1 (ناحیه‌ی ۱۷ در تقسیم‌بندی برادمن^{۵۳}؛ شکل ۱۰.۲) صورت می‌گیرد. این ناحیه بزرگترین قسمت از قشر بینایی مغز (حدود ۲۰٪) را تشکیل می‌دهد. سلول‌های موجود در این ناحیه به لبه‌ها و خطوط پاسخ می‌دهند. به عبارت دیگر هر سلول به امتداد جهت خاصی از محرک

^{۵۳}Brodman areas




شکل ۱۰.۲: تقسیم‌بندی برادمن: سمت چپ نمای جانبی و سمت راست نمای شکاف میانی را نشان می‌دهد. V1 ناحیه‌ی ۱۷ این تقسیم‌بندی است.

در موقعیت مشخصی از میدان بینایی پاسخ می‌دهد. به این سلول‌ها، سلول‌های گزینش‌پذیر نسبت به جهت^{۵۴} گفته می‌شود. برای بازسازی تصویر، شناسایی جهت امتداد خطوط اولین قدم است. از این رو می‌توان ادعا کرد که دستگاه بینایی ما یک دستگاه تشخیص لبه بوده و به عبارتی شناسایی شی بر اساس لبه‌های تشکیل دهنده‌ی تصویر آن صورت می‌پذیرد. در ناحیه‌ی V1 نورون‌ها دارای میدان تاثیر به نسبت کوچکی هستند. اندازه‌ی میدان تاثیر برای سلول‌های V1 در نقطه‌ی مرکزی دید حدود یک درجه (7×7 پیکسل) می‌باشد.

همانطور که پیشتر بیان شد، دو نوع سلول تشکیل دهنده‌ی V1، نورون‌های ساده و پیچیده، وظیفه‌ی شناسایی جهت محرک را انجام می‌دهند. شکل ۱۱.۲ نمونه‌ای از میدان تاثیر یک سلول ساده را بررسی می‌کند. نقاط مثبت (منفی) نمایانگر نقاط تحریکی (مهاری) هستند. به عبارت دیگر نقاط منفی فعالیت نورون را مهار کرده و نقاط مثبت فعالیت نورونی را تشدید می‌کند. مرز مشخصی که بین این نقاط در میدان تاثیر مشاهده می‌شود جهت مورد گزینش نورون را نشان می‌دهد. طبیعتاً نورونی مانند نورون شکل ۱۱.۲ که به میله‌ی عمودی بهترین پاسخ را می‌دهد به میله‌های مورب پاسخی نداده یا پاسخ ضعیفی خواهد داد.

آرایه‌ای از سلول‌ها در قشر بینایی، محرک‌های یک نقطه از شبکه را در میدان تاثیر خود در جهت‌های مختلف دریافت کرده (شکل ۱۲.۲) و بنابراین هر کدام در جهت‌های متفاوتی حساس هستند. همچنین سلول‌های ساده نواحی تحریکی و مهاری در میدان تاثیر خود دارند که البته بزرگتر از میدان تاثیر سلول‌های گانگلیون می‌باشد. می‌توان عملکرد این سلول‌ها را به این نحو تبیین کرد که


^{۵۴}Orientation selective



شکل ۱۱.۲: میدان تاثیر یک سلول ساده در V1: بیشترین پاسخ سلول را در حالتی که یک میله روشن در جهت ارجح (عمودی) قرار گرفته باشد داریم. نقاط روشن پاسخی نداشته یا باعث پاسخهای ضعیف می شوند. نقطه روشن اگر در مرکز برانگیزنده باشد صرفاً پاسخ ضعیف برانگیزنده و اگر در حاشیه‌ی مهارکننده باشد باعث پاسخ مهاری ضعیف می شود. اگر نور روی کل میدان تاثیر پخش شده و آن را بپوشاند پاسخی نخواهیم داشت. [۸]

فیلترهای لبه‌یابی هستند که با اعمال روی تصویر، لبه‌ها در جهات مختلف را شناسایی می‌کنند. تمایز سلول‌های ساده با سلول‌های پیچیده در میزان حساسیت آنها به موقعیت مکانی لبه است. نورون‌های ساده به موقعیت مکانی محرک بسیار حساس بوده و با تغییر موقعیت لبه پاسخ آنها به شدت افت می‌کند. این در حالی است که سلول‌های پیچیده، در یک محدوده‌ی مکانی مشخص و بزرگتر از میدان تاثیر سلول‌های ساده، فارغ از موقعیت لبه با جهت ارجحشان پاسخ می‌دهند. این خصوصیات هابل و ویزل را به تبیین نظریه‌ی پردازش سلسله مراتبی این سلول‌ها واداشت [۱۰، ۱۱].

نکته‌ی قابل توجه دیگر در مورد نورون‌های V1 ترتیب قرار گیری آنها در قشر اولیه بینایی بر حسب جهت‌گیری آنها است که نورون‌های با جهت‌گیری نزدیک به هم، در کنار یکدیگر قرار گرفته‌اند [۱۲]. اگر یک الکتروود ثبت نورونی را به صورت عمودی در قشر مغز فرو کنیم، میدان تاثیر اندازه‌گیری شده از سطح خارجی قشر تا رسیدن به ماده‌ی سفید مشابه خواهد بود. بنابراین قشر بینایی اولیه تحت یک سری ستون باریک که میدان تاثیر مشابه دارند بسته‌بندی شده است [۱۳]. به این خوشه‌های هم میدان تاثیر «ستون‌های قشری» گفته می‌شود [۱۴]. ستون‌های قشری از جمله اصول ساختاری هستند که در جای جای مغز به آنها برمی‌خوریم. چنین سازمان‌های ستونی در بخش‌های مختلف قشر مغز، از قشر حسی لامسه‌ای گرفته تا قشر شنوایی یافت می‌شوند. این نورون‌ها طیف گسترده‌ای از زوایای بین صفر



شکل ۱۲.۲: اتصال سلول‌های LGN به سلول‌های ساده و تشکیل میدان تاثیر: طبق نظریه‌ی هابل و ویزل، یک نورون ساده در قشر مغز، اتصالات همگرای برانگیزنده از سه یا بیشتر نورون داخل مرکز دریافت می‌کند که با هم می‌توانند نور قرار گرفته در راستای یک خط در شبکه را نمایش دهند. در نتیجه میدان تاثیر یک سلول ساده بیضوی و کشیده می‌نماید. حلقه‌ی مهاری حاشیه‌ای نیز توسط سلول‌های خارج از مرکز تامین می‌شود که میدان تاثیرشان در همسایگی سلول‌های داخل مرکز است. [۸]

تا ۱۸۰ درجه را تشخیص می‌دهند.


ستون‌های جهت‌گیری قرار گرفته در کنار هم، در جهت ارجحشان تفاوتی گسسته در حدود 10° مشاهده می‌شود. هابل و ویزل مفهوم اُبرستون^{۵۵} را معرفی کردند که مجموعه‌ای از ستون‌ها هستند که به همه‌ی جهت‌های ممکن در یک ناحیه‌ی مشخص و در هر دو چشم پاسخ می‌دهند. بنابراین یک ابرستون می‌تواند تحلیل کاملی (کامل از منظر خصوصیات تحلیل شده در V1) از یک ناحیه‌ی خاص ارائه دهد. حباب‌ها در لایه‌ی ۲ و ۳ قرار گرفته و جهت‌گیری نمی‌کنند. حباب‌ها^{۵۶} گروه‌های نورونی هستند که مستقیماً از LGN ورودی می‌گیرند و در پردازش رنگ نقش دارند.

۵.۲ سطوح بالاتر بینایی

نواحی بسیار دیگری از قشر بینایی به جز V1 وجود دارند که بیشتر یا انحصاراً در گیر بینایی هستند و تنها تعدادی از آنها به خوبی مطالعه شده‌اند و دانش ما از آنها نسبتاً کم است. ناحیه‌ی بینایی ثانویه (V2) مشابه V1 همه گروه‌های عملیاتی از نورون‌ها را دارد. نواحی دیگر V3-V5 عملکردهای خاص‌تری دارند. مهمترین اصل پردازش بینایی در نواحی بالاتر، پردازش موازی جنبه‌های مختلف بینایی در

^{۵۵} Hypercolumns

^{۵۶} Blobs




شکل ۱۳.۲: چیدمان نورون‌های V1 با جهت‌گیری‌های متفاوت [۱۳]

نواحی متفاوت و تفکیک‌شده است. همانگونه که اشاره شد، پیشنهاد شده است که بخش‌های غیر V1 (قشر فرامخطط^{۵۷}) تحت دو گذرگاه شکمی و پشتی دسته‌بندی شوند.

۱.۵.۲ ناحیه‌ی V2

دومین ناحیه از سلسله مراتب پردازش، ناحیه‌ی V2 (شامل نواحی ۱۸ و ۱۹ برادمن) است که قشر اولیه بینایی را احاطه کرده و مانند V1 یک ساختمان توپوگرافی دارد. V2 مانند V1 به نواحی خبره V3-V5 خروجی می‌دهد. V1 بخش اعظمی از اتصالاتش را به V2 می‌فرستد و V2 ورودی نقطه به نقطه از V1 دارد. V2 همچنین اتصالات بازخوردی قوی به V1 می‌فرستد. مسیرهای رنگ، شکل و حرکت که در V1 شکل می‌گیرد، در V2 امتداد می‌یابد. به جهت تفکیک این نورون‌ها می‌توان اشاره کرد که نورون‌های مسیر رنگ در V2 نسبت جهت حساس نیستند، در صورتی که نورون‌های مسیر شکل در V2 نسبت به جهت محرک حساسند. نیمی از این نورون‌ها به انتهای لبه‌ها و خطوط پاسخ می‌دهند. مسیر حرکت زمانی که تنها یک چشم تحریک می‌شود پاسخ ضعیفی نشان می‌دهد اما در صورتی که اطلاعات از هر دو چشم دریافت شود، پاسخ قوی‌تری مشاهده می‌شود.

^{۵۷} Extrastriate cortex




شکل ۱۴۰۲: قشر اولیه بینایی (به رنگ طوسی) و نواحی فرامخطط شامل V2-V5 [۱۵]

۲۰۵۰۲ ناحیه V4

ناحیه V4 در موقعیت قدامی نسبت به V2 و خلفی نسبت به PIT قرار گرفته است. V4 سومین ناحیه قشری در مسیر شکمی بوده و از V2 ورودی گرفته و اتصالات خروجی قوی به PIT دارد. همچنین اتصالات ورودی مستقیم از V1 دارد و اتصالات خروجی ضعیف‌تری بین آن و V5 وجود دارد. این ناحیه اولین ناحیه در جریان شکمی است که مدولاسیون توجهی^{۵۸} نشان می‌دهد. تحقیقات نشان داده که توجه گزینشی^{۵۹} می‌تواند نرخ آتش در V4 را تا ۲۰٪ تغییر دهد.

مشابه V2، ناحیه V4 برای جهت، فرکانس فضایی و رنگ میزان‌سازی شده است اما برخلاف آن روی ویژگی‌های شی با پیچیدگی میانی، مانند اشکال هندسی، نیز حساس است. هنوز توصیف پارامتری از فضای میدان تاثیر این ناحیه ارائه نشده است اما می‌دانیم که V4 (برخلاف IT) نسبت به اشیای پیچیده، همانند تصویر صورت، حساس نیست.

^{۵۸} Attentional modulation
^{۵۹} Selective attention



شکل ۱۵.۲: نواحی بالاتر قشر بینایی و دو گذرگاه شکمی و پستی [۸]

۳.۵.۲ قشر IT

قشر گیجگاهی تحتانی (IT)، متشکل از قشرهای PIT، CIT و AIT، بر اساس نتایج مشاهدات تجربی، به عنوان آخرین ناحیه‌ی درگیر در مسیر شکمی بینایی شناخته می‌شود. IT محرک بینایی از اشیای داخل میدان دید را پردازش کرده و در حافظه و همچنین ادراک محرکی که توسط نواحی V2، V3 و V4 در لوب پس‌سری تقویت شده‌اند نقش دارد. این ناحیه مسئول تولید «چیستی» از محرک‌های بینایی است و به عبارت دیگر بر اساس رنگ و فرم شی و مقایسه‌ی آن با اطلاعات ذخیره شده در حافظه، آن را شناسایی می‌کند.

فصل ۳

مدل‌های عصبی

۱.۳ مقدمه

از سال ۱۹۵۰ که روزنبلات^۱ تئوری پرسپترون^۲ را ارائه داد [۱۶]، مدل‌های شبکه عصبی مصنوعی مختلفی برای شبیه‌سازی ساز و کار زیستی شبکه‌های عصبی ارائه شده است. با این حال اغلب مدل‌ها بر پایه‌ی نورون‌های آنالوگ و اتصالات سیناپسی ساده‌سازی شده با اوزان قابل تنظیم هستند؛ بدون در نظر گرفتن این مهم که مبنای عملکرد نورون، ضربه بوده و سیناپس‌ها دینامیک پیچیده‌ای دارند. در حال حاضر اکثر مدل‌های ارائه شده از تفسیر زیستی مبرا و منحرف شده و بیشتر به سمت تعالی توانایی محاسباتی گرایش دارند. شبکه‌های عصبی ضربه‌ای^۳ (SNNs) به عنوان مدل‌هایی که از نظر زیستی انطباق بیشتری دارند، به علت دشواری‌های ذاتی مدل‌سازی آنها، به اندازه‌ی شبکه‌های نورونی آنالوگ در مهندسی محبوب نیستند؛ هرچند که همگان بر این نکته اتفاق نظر دارند که SNN‌ها از نظر محاسباتی توانمندتر بوده و به عنوان نسل جدید و انقلابی شبکه‌های عصبی معرفی می‌شوند [۱۷].

گرایش فزاینده‌ای به شبکه‌های عصبی ضربه‌ای، به جهت واقع‌گرایی بیشتر در این گروه از مدل‌ها، در سال‌های اخیر بوجود آمده است. در مدل‌های ضربه‌ای که به عنوان نسل سوم شبکه‌های عصبی معرفی می‌شوند، علاوه بر حالت‌های نورونی و سیناپسی، مفهوم زمان نیز به کار گرفته شده است. نورون‌های

^۱ Rosenblatt

^۲ Perceptron

^۳ Spiking Neural Networks

SNN دیگر در هر گام آتش نمی‌کند؛ برخلاف آنچه در شبکه‌هایی مانند پرسپترون چندلایه^۴ داشتیم، بلکه مشابه نورون واقعی زمانی آتش می‌کند که پتانسیل غشایی آن به یک مقدار مشخص (حد آستانه) برسد.

۲.۳ شبکه‌های عصبی ضربه‌ای

۱.۲.۳ تاریخچه مدل‌سازی نورونی

به طور کلی در تاریخچه شبیه‌سازی نورون، سه نسل از شبکه‌های عصبی معرفی شده‌اند که هر کدام بر مبنای مدل‌هایی از نورون هستند که جنبه‌ی خاصی از نورون‌ها را به فرآیند شبیه‌سازی اضافه کرده‌اند. اولین تلاش‌های منجر به شبکه‌های عصبی به سال ۱۹۴۳ میلادی برمی‌گردد؛ زمانی که مک‌کلاچ^۵ و پیتز^۶ اولین مدل نورون را ارائه کردند. در مدل آنها یک نورون دارای دو ورودی و یک خروجی بود و فعالیت نورون شبیه‌سازی شده را مشروط به گرفتن ورودی از هر دو شاخه‌ی ورودی کردند. آنها جریان ورودی و خروجی نورون را به شکل دودویی فرض کردند و به همین جهت مدل آنها به «مدار منطق^۷» معروف شد. بعدها در دهه‌ی ۵۰ میلادی، محققین در صدد استفاده از این رویکرد جدید برای طراحی شبکه‌های عصبی بهتر برآمدند. روزنبلات^۸ یکی از محققین پیشگام در این حوزه بود که در طی تحقیقات خود در مورد بینایی مگس‌ها، در سال ۱۹۵۸، پایه‌ی مدل پرسپترون را بنا کرد. پرسپترون و مدل‌های دیگر طراحی شده در آن زمان منجر به یکسری موفقیت‌های ابتدایی شد که متأسفانه به دلیل نگاه غیرواقع‌بینانه و بزرگنمایی‌های رسانه‌ای، با برآورده نشدن یکسری توقعات، باعث دلسردی و در نهایت دوره‌ای رکود در این حوزه شد که به عنوان «زمستان هوش مصنوعی» از آن یاد می‌شود. یکی از دلایل این وقفه که بیش از یک دهه به طول انجامید، کتاب «پرسپترون‌ها» از مینسکی^۹ و پاپرت^{۱۰} بود که با بررسی خود، پندار محدودیت‌های غیرقابل غلبه‌ی شبکه‌های پرسپترون

^۴ Multi Layer Perceptron

^۵ Warren McCulloch

^۶ Walter Pitts

^۷ Logic circuit

^۸ Frank Rosenblatt

^۹ Marvin Minsky

^{۱۰} Seymour Papert

که روزنبلات سعی بر زنده نگه داشتن آن داشت بین عموم رواج داد. با وجود آنکه کارهای مهمی مانند ارائه قاعده‌ی پس‌انتشار توسط وربوس همچنان انجام شد، اما سرمایه‌گذاری و حمایت‌های مالی در این دوره بسیار محدود گردید. در اواسط دهه‌ی ۸۰، این زمستان در نهایت به سرآمد و کارهای هاپفیلد^{۱۱} و روملهارت^{۱۲} شوق وسیعی را به تحقیقات شبکه‌های عصبی برگرداند. روملهارت با کشف مجدد روش پس‌انتشار نقش مهمی در احیای شبکه‌های عصبی داشت اما اشتیاق عمومی زمانی مجدداً به این سمت روانه شد که هاپفیلد مقاله‌ای در رابطه با شبکه‌های عصبی در آکادمی علوم ملی نوشت اما دیگاه هاپفیلد صرفاً محدود به مدل‌سازی نبوده و در پی تکنولوژی‌های کاربردی که به حل مسائل دنیای واقعی منجر شود بود. توجه مجدد به شبکه‌های عصبی و تعداد فزاینده‌ی کنفرانس‌ها و مجامعی که حول این حوزه تشکیل می‌شوند توفیقات فراوانی را به همراه داشته و امروزه شاهد کاربردهای وسیع شبکه‌های عصبی، از تشخیص گفتار و چهره تا درمان‌های پزشکی هستیم.

گرچه شبکه‌های پرسپترون با کمک قاعده‌ی پس‌انتشار توفیقات زیادی را کسب کرده‌اند، اما باید این را در نظر داشته باشیم که سطح مدل‌سازی آنها، با آنچه به صورت زیستی در مغز اتفاق می‌افتد بسیار متفاوت است. قانون یادگیری پس‌انتشار پشوانه‌ی زیستی نداشته و با نظریه‌ی هب که مطرح شد قرابتی ندارد. البته تلاش‌هایی در بکار بردن قانون هب برای شبکه‌های پرسپترون صورت گرفته، اما ساده‌سازی بیش حد نورون‌ها آنها را از حوزه‌ی زیستی بسیار دور کرده است. اعدادی که به عنوان ورودی و خروجی در پرسپترون در نظر گرفته می‌شود نمایانگر نرخ فعالیت (یا تعداد ضربه در یک بازه‌ی زمانی) است در حالی که فعالیت نورون‌ها از یک دینامیک خاص تبعیت کرده و با محدود کردن آن به نرخ فعالیت، ظرفیت محاسباتی پرسپترون بسیار پایینتر از نورون‌های واقعی و مدل‌های ضربه‌ای است.

۲.۲.۳ مدل‌های نورونی

همانطور که اشاره شد، مدل‌های ضربه‌ای نورون، تلاش دارند تا تفسیر دینامیک وضعیت داخلی نورون که پتانسیل آن را بر اساس ورودی‌های دریافت شده طی زمان تعیین می‌کند به نحوی ارائه دهند که سازوکار نورون واقعی را با سطح مشخصی از جزئیات مدل کند. دینامیک نورون در یک مدل با

^{۱۱} John Hopfield
^{۱۲} David Rumelhart

یکسری معادلات دیفرانسیل مشابه زیر تعیین می‌گردد:

$$\frac{\partial V}{\partial t} = F(V, I, C) \quad (۱.۳)$$

که V برداری از متغیرهای مفروض مدل، I جریان ورودی به نورون در هر لحظه و C مجموعه‌ای از پارامترهای تنظیم شده‌ی مدل است. F تابعی است که دینامیک نورون و تغییرات متغیرها بر اساس ورودی و بر حسب زمان را مشخص می‌کند. تابع F ورودی‌های خود را به فضای \mathbb{R}^n می‌برد که n بعد بردار V می‌باشد. به عبارتی دیگر، مدل ضربه‌ای از یک دستگاه معادلات دیفرانسیل از n معادله و n به اضافه‌ی قیدی که با برآورده شدن آن، نورون یک ضربه تولید می‌کند متغیر تشکیل شده است.

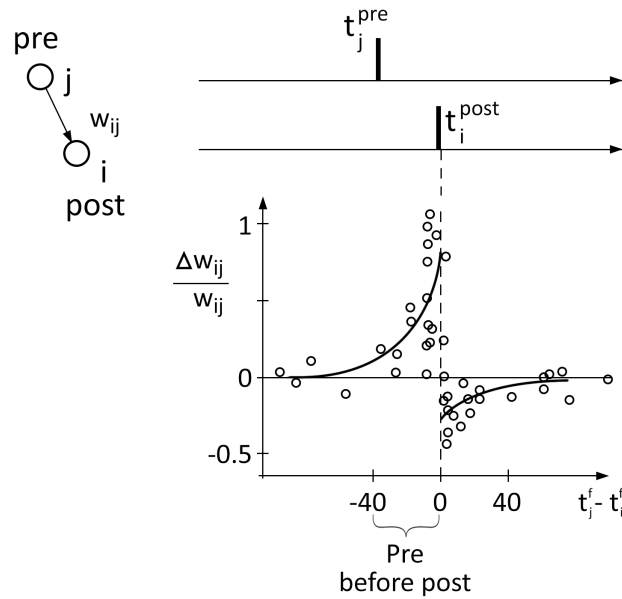
مدل‌های نورونی فراوانی ارائه شده‌اند که بسته به پیچیدگی محاسباتی و تطابق زیستی رده‌بندی می‌شوند. ما در این تحقیق از مدل تجمیع و آتش^{۱۳} (IF) و تجمیع و آتش نشی^{۱۴} (LIF) استفاده کرده‌ایم که در فصل چهارم با جزئیات بیشتری آنها را تبیین خواهیم کرد.

۳.۲.۳ یادگیری وابسته به زمان ضربه

نورون‌ها با تغییر در قدرت اتصالات سیناپسی در پاسخ به فعالیت ضربه‌ها، توانایی یادگیری و تطبیق پردازش خود بر حسب تجربه را دارند. STDP یک نمونه‌ی غیرمتقارن زمانی از قاعده‌ی یادگیری یادگیری هب است که بر اساس همبستگی ضربه‌های نورون‌های پیش و پس سیناپسی عمل می‌کند. STDP به عنوان مدلی برای شکل‌پذیری سیناپسی در مغز ارائه شده است که بر اساس ترتیب و زمان ضربه‌های پیش و پس سیناپسی عمل می‌کند. طبق STDP، ضربه‌های پیش سیناپسی اگر به طور مکرر چند میلی‌ثانیه پیش از پتانسیل عمل پس سیناپسی ظاهر شوند باعث تقویت بلند مدت (LTP) می‌شوند، در حالی که ظهور مکرر ضربه‌ی پس سیناپسی قبل از وقوع ضربه‌ی پیش سیناپسی به تضعیف بلند مدت (LTD) می‌انجامد. شکل ۱.۳ تاثیر فاصله‌ی زمانی بین ضربه‌ها بر قدرت سیناپس را که از مشاهدات تجربی [۱۸] بدست آمده است نمایش می‌دهد.

معروف‌ترین تابع که برای توجیه این داده‌ها استفاده می‌شود، تابع نمایی است. اگر بخواهیم تغییر

^{۱۳} Integrate & Fire
^{۱۴} Leaky Integrate & Fire



شکل ۱۰.۳: STDP تغییرات اتصالات سیناپسی را به صورت تابعی از زمان نسبی بین زوج ضربه‌های پیش و پس سیناپسی بیان می‌کند. (ترسیم مجدد از [۱۸])

وزن سیناپس j را محاسبه کنیم و t_j^f را زمان‌های ضربه‌های نورون پیش سیناپسی بگیریم و همچنین زمان آتش‌های نورون پس سیناپسی با t^n نمایش داده شود، آنگاه تغییرات وزنی برابر است با:

$$\Delta w_j = \sum_f \sum_n W(t^n - t_j^f) \quad (۲.۳)$$

که $W(s)$ همان تابع STDP است که تغییرات وزنی بر مبنای تفاضل زمان ضربه‌ها را تفسیر می‌کند. یک انتخاب محبوب برای این تابع به صورت زیر می‌باشد:

$$W(s) = \begin{cases} A_+ \exp(-\frac{s}{\tau_+}) & \text{if } s \geq 0 \\ -A_- \exp(-\frac{s}{\tau_-}) & \text{if } s < 0 \end{cases} \quad (۳.۳)$$


که برای برازش داده‌های تجربی [۱۹] و مدل‌سازی [۲۰] به دفعات استفاده شده است. ضریب‌های A_+ و A_- ممکن است به مقدار وزن فعلی w_j وابسته باشند. ثابت‌های زمانی τ_+ و τ_- نیز در حدود چند ده میلی ثانیه انتخاب می‌شوند. تابع STDP استفاده شده در این تحقیق در فصل چهار بیان خواهد شد.

۳.۳ یادگیری بدون نظارت ویژگی‌های بصری توسط STDP

قیده‌های زمانی که برای مدل‌های بازشناسی الگو در قشر گذاشته می‌شود یکی از چالش‌های اصلی این حوزه است. ثبت‌های صورت گرفته از قشر IT میمون نشان داده که تنها در حدود ۱۰۰ میلی‌ثانیه بعد از آغاز محرک، اطلاعات ارزشمند و دقیقی از ماهیت محرک بینایی پردازش می‌شود [۲۱]. به احتمال زیاد این نوع پردازش سریع بر توانایی دستگاه بینایی در یادگیری بازشناسی اشکال بصری آشنا، به یادگیری بدون نظارت متکی است. اینکه چگونه این یادگیری صورت می‌پذیرد از چالش‌های اصلی علوم اعصاب نظری می‌باشد. مدل بررسی شده در اینجا در سال ۲۰۰۷ توسط ماسکولیه و تورپ [۲۲] ارائه شده است و دو ویژگی اصلی دارد: اول اینکه با نمایش آنی^{۱۵} محرک بینایی، نورون‌های موجود در لایه‌های مختلف به صورت غیرهمزمان آتش می‌کنند به این صورت که نورون‌هایی که قوی‌تر فعال شده‌اند زودتر آتش می‌کنند. نشان داده شده است که این مکانیسم به صورت بهینه اطلاعات تصویر را کد می‌کند [۲۳]. دوم آنکه نورون‌های مراحل موخر، شکل‌پذیری وابسته به زمان ضربه (STDP) را پیاده می‌کنند که می‌دانیم در اثر آن وزن‌های بالای سیناپسی روی سیناپس‌های آوران Afferent که به طور قاعده‌مند زود آتش می‌کنند متمرکز می‌شود [۲۰، ۲۴].

با تکرار نمایش تصاویر به این شبکه‌ی پیش‌خور پیچشی و سلسله‌مراتبی^{۱۶}، مشاهده می‌شود که نورون‌های سطوح میانی به الگوهایی که به طور قابل اطمینان ورودی را عرضه می‌کنند گزیننده^{۱۷} می‌شوند و تاخیرشان کاهش می‌یابد که در نتیجه باعث پاسخ‌های سریع کارآمد می‌شود. این فرآیند کاملاً بدون نظارت صورت می‌گیرد و این ویژگی‌ها را می‌توان برای دسته‌بندی محرک‌ها استفاده کرد. این مدل، ساختار پیشنهادی سره، ولف و پوزیو [۲۵] که خود مدل HMAX را بسط می‌دهد الگوبرداری کرده است و در تلاش برای نمایش پیچیدگی و ناوردایی^{۱۸} فزاینده در طور مسیر شکمی، ساختاری چهار لایه (C2-S2-C1-S1) را تشکیل می‌دهد که در آن سلول‌های ساده (S) گزینندگی‌شان را از یک عملیات جمع خطی بدست می‌آورند در حالی که سلول‌های پیچیده (C) ناوردایی را با یک عملیات ادغام بیشینه^{۱۹} خطی فراهم می‌کنند.

^{۱۵} Flash^{۱۶} Hierarchical convolutional network^{۱۷} Selective^{۱۸} Invariance^{۱۹} Max pooling



شکل ۲۰۳: ساختار پیش‌خور مدل یادگیری ویژگی‌های بصری: مشابه HMAX [۲۶] در این مدل نیز به صورت تناوبی سلول‌های ساده و سلول‌های پیچیده قرار داده شده است. سلول‌های S1 لبه‌ها را تشخیص می‌دهند. C1 نقشه‌های S1 را با بیشینه کردن پاسخ در یک همسایگی مربع از آن زیرنمونه می‌گیرد. S2 نسبت به ویژگی‌های پیچیده‌ی میانی گزیننده شده و ترکیبی از لبه‌های جهت‌دار را می‌دهند. سپس C2 بیشینه‌ی پاسخ سلول‌های S2 در تمام موقعیت‌ها و مقیاس‌ها را منتقل می‌کند. [۲۲]

در هر گام، زمان اولین ضربه نسبت به آغاز محرک (مرتبه ۲۰ اولین ضربه) اصلی‌ترین متغیری هست که اطلاعات را در خورد جای داده و بر اساس ساختار مدل به نورون‌های پایین دست منتقل می‌شود. با نمایش یک محرک، سلول‌های S1 لایه‌ی اول، لبه‌ها را در چهار جهت اصلی (مشابه V1 در قشر بینایی) شناسایی می‌کند به این صورت که هر چه قوی‌تر فعال شود، زودتر آتش خواهد کرد. تبدیل شدت-تاخیر^{۲۱} با سازوکاری که در ثبت‌های صورت گرفته از V1 مشاهده شده، که کاهش تاخیر را با کاهش کنتراست [۲۷] و نزدیکی جهت محرک با جهت گزینندگی نشان می‌دهد [۲۸]، منطبق است. تعداد ضربه‌ها در S1 از طریق مکانیسم رقابتی one-winner-take-all محدود شده و تنها ضربه متناظر با بهترین جهت در هر مکان منتقل می‌شود که در نتیجه تعداد ضربه‌ها را به یک چهارم کاهش می‌دهد. در چارچوب جاری، عملیات max متناظر است با انتشار اولین ضربه‌ی واصله از یک گروه آوران. چنین کاری را می‌توان با یک نورون تجمع و آتش با حد آستانه‌ی پایین که اتصال از تمام

Rank^{۲۰}Intensity-latency conversion^{۲۱}

گروه نورونی دارد انجام داد.

فعالیت نورونی با محدود کردن یک ضربه به ازای هر نورون محدود شده است و در نتیجه تنها موج اولیه‌ی ضربه‌ها انتقال می‌یابد. از هر تصویر ورودی، چند مقیاس مختلف (پنج مقیاس در [۲۲]) پردازش می‌شود و به ازای هر مقیاس یک مسیر $S_1-S_2-C_1$ وجود داشته و بنابراین اندازه‌ی میدان‌های تاثیر سلول‌های S_2 متفاوت است. سپس سلول‌های C_2 پاسخ بیشینه (اولین ضربه) را در میان سلول‌های S_2 از میان همه‌ی موقعیت‌ها و مقیاس‌ها می‌گیرند که در نتیجه پاسخ‌ها نسبت به موقعیت و مقیاس ناوردا خواهند شد.

معادل سلول‌های S_1 را در ناحیه‌ی V_1 مغز و C_1 را در نواحی V_1-V_2 مغز می‌توان پیدا کرد. سلول‌های S_2 شبیه سلول‌های $PIT-V_4$ و C_2 مشابه AIT است. در نهایت ماژول طبقه‌بند عملاً وظایف PFC را انجام می‌دهد. مشاهدات نشان می‌دهد که یادگیری وزن‌های اتصالات S_2-C_1 به کمک STDP منجر به ویژگی‌های بصری با پیچیدگی میانی می‌شود که مشابه آن در مغز نیز مشاهده شده است. نورون‌های لایه‌ی S_2 میدان تاثیر محدودی دارند. به عبارت دیگر، سلول‌های S_2 ، ضربه‌ها را از یک میدان تاثیر به ابعاد $s \times s$ از یک نقشه‌ی C_1 متناظر با یک مقیاس تجمع می‌کنند. علاوه بر آن از مکانیسم اشتراک وزن برای سلول‌های S_2 استفاده شده است.

۴.۳ ماشین حالت مایع

شبکه‌های عصبی ضربه‌ای نقش قابل توجهی در فهم ما از ساز و کار مغز در علوم اعصاب داشته‌اند. با این حال تقریباً تمام مدل‌های ساخته شده از اتصالات یا پارامترهای تصادفی^{۲۲} بهره می‌برند. دلیل آن این است که ساخت یک شبکه‌ی مدل که مدارات^{۲۳} یکسان با مغز، و یا حتی یک کشت یاخته عصبی، داشته باشد غیر ممکن می‌نماید. در کشت یاخته، نورون‌ها قبل از تمایز سلولی^{۲۴}، ابتدا داخل ظروف پتری^{۲۵} قرار می‌گیرند تا رشد و داخل ظرف تشکیل شبکه دهند. اتصالات کشت‌های سلولی به صورت تصادفی ساخته می‌شوند. همچنین در مغز، در طول دوره‌ی رشد، «تصادفی بودن»^{۲۶} در

^{۲۲} Stochastic

^{۲۳} Circuitry

^{۲۴} Cell Differentiation

^{۲۵} Petri dishes

^{۲۶} Randomness

تشکیل تعداد بالای اتصالات سیناپسی نقش دارد. مدعای واضح این امر این است که پیچیدگی نجومی ساختار مغز امکان ندارد که صرفاً توسط ژنوم کد شده باشد؛ با این حال هر ارگانیسم مستقل، پس از یادگیری مناسب در محیط طبیعی و بهینه‌سازی توپولوژی و قدرت اتصالات سیناپسی، امکان فعالیت و بقا در محیط طبیعی را دارد. شبکه‌های عصبی مصنوعی نیز مانند مغز از این اصل پیروی می‌کنند: شبکه‌ی عصبی با اتصالات تصادفی ساخته شده و سپس با الگوریتم‌های یادگیری، وزن‌ها یا توپولوژی سیناپسی را اصلاح و بهینه می‌کند. به عبارت دیگر، تقریباً همه‌ی شبکه‌های عصبی، چه درون‌جاندازی^{۲۷}، چه درون‌کشتگاهی^{۲۸} یا درون‌رایانه‌ای^{۲۹}، ذات تصادفی دارند. این امر علوم اعصاب را به سوالات بسیاری رهنمون می‌کند: با توجه به اینکه هدف غایی در علوم اعصاب فهم ساز و کار مغز است، چگونه با در بر داشتن این میزان بالا از عدم قطعیت و تصادفی بودن، مغز می‌تواند به طور عادی عمل کند؟ آیا این تصادفی بودن در نحوه‌ی عملکرد نقش مثبتی دارد یا به آن لطمه وارد می‌کند؟ یا به طور بنیادی‌تر، آیا یک شبکه‌ی عصبی تصادفی امکان پردازش اطلاعات زمانی فضایی^{۳۰} را بدون یادگیری دارد؟ و با در نظر گرفتن چنین حالتی، آیا مغز از این توانمندی شبکه‌های تصادفی منفعتی می‌برد؟

۱.۴.۳ پیش‌زمینه

تقریباً تمام محرک‌های حسی به پاسخ‌های فضایی مکانی به فرم پتانسیل‌های عمل^{۳۱} منجر شده و به دستگاه عصبی مرکزی منتقل می‌شوند. دنباله‌های سلسله‌ی پتانسیل‌های عمل را معمولاً دنباله‌ی ضربه^{۳۲} می‌نامند که می‌توان آنها را فرایندهای نقطه‌ای^{۳۳} دانست که در آن هر داده نمایانگر زمان وقوع یک پتانسیل عمل است. نورون‌ها از طریق پتانسیل‌های عمل ارتباط برقرار می‌کنند؛ با این حال شکل هر پتانسیل عمل در انتقال اطلاعات نقش چندانی ندارد و از این روی است که پردازش زمان دنباله‌ی ضربه از اهمیت فراوانی در دستگاه اعصاب برخوردار است. با این حال، اکثر فهم فعلی ما از مغز

^{۲۷} in vivo

^{۲۸} in vitro

^{۲۹} in silico

^{۳۰} Spatiotemporal

^{۳۱} Action Potentials

^{۳۲} Spike train

^{۳۳} Point processes

متوجه پردازش اطلاعات فضایی^{۳۴} می‌باشد و نحوه‌ی عملکرد مغز در مواجهه با الگوهای زمانی^{۳۵} یا الگوهای پیچیده‌ی زمانی فضایی هنوز درک نشده است.

در پردازش سیگنال، تبدیل فوریه^{۳۶} برای تبدیل سیگنال از فضای زمان به فضای فرکانس معرفی می‌شود. به طور مشابه، حلزون گوش در گوش میانی نیز سیگنال صوتی را با یک نگاشت فرکانسی- مکانی کد می‌کند و به این نحو، بخش‌های مختلف حلزون، به فرکانس‌های مختلف پاسخ می‌دهند. تجزیه‌ی سیگنال‌های زمانی به نمایش فضا-فرکانس در سامانه‌ی شنوایی اهمیت بسیاری دارد. اما مغز چگونه زمان را بیان کرده و سیگنال‌های زمانی فضایی را پردازش می‌کند؟ در شبکه‌های عصبی مصنوعی پیش‌خور^{۳۷} سنتی، یکی از راه‌های نمایش زمان که اغلب کاربرد دارد «فضاسازی زمان^{۳۸}» است که به معنی اضافه کردن زمان به عنوان یک بعد اضافی در فضا می‌باشد. اما این به وضوح خلاف اتفاقی است که در مغز می‌افتد. یک چارچوب نظری که تحت عنوان «محاسبات وابسته به وضعیت^{۳۹}» معرفی شده است [۲۹] این گونه تبیین می‌کند که زمان به طور ذاتی در شبکه‌های عصبی زیستی نهفته شده است و اطلاعات فضایی زمانی با تکامل خط سیرهای عصبی^{۴۰} کد می‌شود. این ایده مشابه مفهوم فضا-حالت در نظریه‌ی کنترل است که در آن هر نقطه در حالت-فضای سیستم، نمایانگر یک وضعیت سیستم بوده و یک خط سیر فضا-حالت نحوه‌ی تغییر سیستم در طول زمان در پاسخ به یک ورودی خارجی زمان-متغیر^{۴۱} را نشان می‌دهد. وضعیت سیستم در هر نقطه از زمان نتیجه‌ی تاریخچه‌ی ورودی است. بنابراین، محرک‌های زمانی فضایی مختلف می‌توانند به خط سیرهای عصبی گوناگون بیانجامند. پس با مشاهده‌ی خط سیرها، یا تغییر وضعیت شبکه در طول زمان، می‌توان به اطلاعاتی در مورد محرک ورودی، از جمله ماهیت آن، پی برد.

نظریه‌ی محاسبات وابسته به وضعیت، عموماً تحت عنوان «محاسبات انباره‌ای^{۴۲}» شناخته شده و مبتنی بر شبکه‌های عصبی بازگشتی^{۴۳} می‌باشد. ماشین حالت مایع^{۴۴} (LSM) [۳۰] و شبکه‌ی انعکاس

Spatial^{۳۴}Temporal^{۳۵}Fourier Transformation^{۳۶}Feed-forward^{۳۷}Time Spatialization^{۳۸}State-Dependent Computation^{۳۹}Neural Trajectories^{۴۰}Time-varying^{۴۱}Reservoir Computing^{۴۲}Recurrent Neural Networks^{۴۳}Liquid State Machine^{۴۴}

حالت^{۴۵} (ESN) [۳۱] دو رسته‌ی اصلی از خانواده‌ی محاسبات انباره‌ای هستند. این دو مدل با وجود شباهت‌های زیاد، تفاوت‌های بنیادین در پیاده‌سازی دارند. در حالی که شبکه‌ی انعکاس حالت از شبکه‌های بازگشتی آنالوگ ساخته شده و تحلیل‌های ریاضیاتی را به کار می‌برد، ماشین حالت مایع بر مبنای شبکه‌های عصبی ضربه‌ای بوده و تلاش بر انطباق زیستی ساختار شبکه و پارامترهایش از خصوصیات آن است. با این حال کاربرد اصلی هر دوی اینها در پردازش الگوهای زمانی فضایی به صورت بلادرنگ^{۴۶} برشمرده می‌شود.

از منظر ماشین‌های کرنل، مشابه روش‌های کرنل در ماشین بردار پشتیبان^{۴۷} (SVM)، محاسبات انباره‌ای به یک رسانه‌ی برانگیختنی^{۴۸} به عنوان کرنل (یا در اینجا انباره) نیاز دارد تا به صورت غیرخطی ورودی را به فضای ویژگی با ابعاد بالا تبدیل کند. نتیجه‌ی این تبدیل، خط سیرهایی در فضای حالت با ابعاد بالا خواهد بود. نام گذاری این روش منشا جالبی دارد. فرض کنید یک سنگ، داخل یک استخر آب پرتاب شده است و شما تنها امواج تشکیل شده در سطح آب را مشاهده می‌کنید. ادعای مطرح شده این است که صرف این مشاهده می‌توان خصوصیات سنگ، مانند شکل یا سرعت ورود آن به آب، را محاسبه کرد. «ماشین حالت مایع» یا «محاسبات انباره‌ای» بخاطر این تمثیل نام‌گذاری شده‌اند. انباره به عنوان آب در نظر گرفته شده و محرک خارجی همانند سنگ است. انباره‌ی LSM یک ریزمدار قشری^{۴۹} است که از نورون‌های ضربه‌ای به عنوان واحدهای سازنده استفاده کرده و اتصالات سیناپسی آن اغلب از شکل‌پذیری کوتاه مدت^{۵۰} استفاده می‌کنند. توان محاسباتی جهان شمول^{۵۱} LSM نیز مورد مطالعه قرار گرفته است.

۲.۴.۳ معماری

یک ماشین حالت مایع از سه بخش تشکیل شده است:

• یک لایه‌ی ورودی

^{۴۵} Echo State Network

^{۴۶} Real-time

^{۴۷} Support Vector Machine

^{۴۸} Excitable

^{۴۹} Cortical Microcircuit

^{۵۰} Short-term Plasticity

^{۵۱} Universal Computational Power

• یک فیلتر مایع (انباره)

• یک یا چند نورون خطی و بدون حافظه تحت عنوان لایه‌ی قرائت^{۵۲}

(شکل از LSM نمونه)

نورون‌های ورودی محرک‌ها را در قالب دنباله‌های ضربه دریافت کرده و جریان الکتریکی به ریزمدار قشری (فیلتر مایع) تزریق می‌کنند. این سیناپس‌های ورودی، محرک را نه به همه‌ی نورون‌ها، بلکه به تعداد منتخبی از آنها، انتشار می‌دهند. از جهت مدارها و توپولوژی اتصالات در انباره، الزامات خاصی تعیین نشده است و صرفاً یک شبکه‌ی تصادفی کافی می‌باشد. این امر به ما اجازه می‌دهد که هم به صورت شبیه‌سازی‌های درون‌رایانه‌ای و هم به صورت درون‌کشتگاهی بتوانیم فیلتر مایع را پیاده‌سازی کنیم. در حالت درون‌رایانه‌ای، فیلتر مایع از صدها نورون ضربه‌ای تشکیل می‌شود که با هزاران اتصال سیناپسی به صورت تصادفی به هم متصل هستند. بخاطر محدودیت‌ها از نظر قدرت محاسباتی، اندازه‌ی فیلتر مایع نمی‌تواند به اندازه‌ی کشت‌های نورونی متشکل از چند صد هزار نورون و چند میلیون سیناپس باشند. از آنجایی که هر نورون، دینامیک غیرخطی و اتصالات سیناپسی خود را داشته و اتصالات بازگشتی بین نورون‌ها برقرار است، هر نورون پاسخ متفاوتی به ورودی خارجی نشان می‌دهد. بنابراین فیلتر مایع به عنوان یک تصویر غیرخطی از محرک ورودی در یک فضای ویژگی با ابعاد بالاتر عمل می‌کند. ابعاد فضای تصویر شده، تعداد نورون‌ها در فیلتر مایع خواهد بود. همچنین یک لایه‌ی قرائت، همه (یا بخشی از) پاسخ‌ها را دریافت کرده و می‌تواند به نحوی آموزش داده شود که یک ابرصفحه در فضای حالت برای جداسازی محرک‌ها رسم کند. روش‌های آموزش مختلفی می‌توان برای لایه‌ی قرائت به کار برد؛ از جمله آنالیز افتراقی خطی^{۵۳} (LDA)، ماشین بردار پشتیبانی (SVM) یا حتی رگرسیون ساده‌ی خطی. از آنجایی که قرائت به صورت خطی و بدون حافظه است، همه‌ی پردازش غیرخطی و زمانی بر عهده‌ی انباره می‌باشد. بنابراین، عملکرد LSM به دینامیک آن و حافظه‌ی محشونده‌اش^{۵۴} در انباره بستگی دارد. تنها بخشی از LSM که نیاز به آموزش دارد لایه‌ی قرائت است و فیلتر مایع از این مورد بی‌نیاز است. به همین جهت پیاده‌سازی کل LSM حتی با کشت نورونی زنده امکان‌پذیر بوده و تلاش‌هایی هم در این راستا صورت گرفته است. با این حال هنوز

^{۵۲} Readout Layer

^{۵۳} Linear Discriminant Analysis

^{۵۴} Fading Memory

اینکه آیا شبکه‌های عصبی زنده به عنوان انباره مناسب هستند محل سوال و تحقیق است اما چیزی که می‌توان امروزه ادعا کرد این است که استفاده از ماشین حالت مایع به عنوان یک طبقه‌بند می‌تواند کاربردهای متعددی در مهندسی داشته باشد.

۳.۴.۳ شبکه‌های عصبی درون‌رایانه‌ای

رشد سریع و اعجاب‌آور توان محاسباتی کامپیوترها به ما این امکان را داده است که بتوانیم به ارزیابی مدل‌های محاسباتی از شبکه‌های عصبی که منطبق بر زیست‌شناسی و فیزیولوژی هستند بپردازیم. در حال حاضر تعداد انگشت شماری پروژه روی شبکه‌های مصنوعی با ابعاد بالای چند میلیون نرون و با درجات متفاوتی از دقت شبیه‌سازی و انطباق زیستی وجود دارند [۳۲، ۳۳]. مزیت شبیه‌سازی‌های رایانه‌ای در مقایسه با آزمایش‌های زیستی روی کشت‌های سلولی، کنترل کامل روی همه‌ی ابعاد و امکان تنظیم و ثبت تمام پارامترهای شبکه است. این به ما اجازه می‌دهد که از سطح مولکولی به سطح شبکه و در نهایت به سطح رفتاری ارتباطاتی را ترسیم کنیم که ما را به سمت فهم بهتر از عملکرد مغز سوق دهد. شبیه‌سازی LSM به ما امکان مطالعه‌ی چنین ارتباطاتی را می‌دهد: اثر دینامیک نرونی و سیناپسی روی رفتار شبکه و عملکرد ماشین حالت مایع، توانایی شبکه‌های تصادفی در پردازش الگوهای زمانی فضایی، اثر شکل‌پذیری در عملیات شبکه و...

طرح اولیه و صحت ماشین حالت اولیه از شبیه‌سازی رایانه‌ای بدست آمده است و چارچوب این مفهوم با هدف درک بهتری از عملکرد مغز ارائه شده است. ادعا شده است که امکان مدل‌سازی مخچه توسط ساختار LSM وجود داشته [۳۴] و از طرفی هیپوکمپوس^{۵۵} مشابه SVM جداسازی الگوها را انجام می‌دهد [۳۵، ۳۶]. همانطور که گفتیم SVM اساساً شباهت‌های بسیاری با LSM دارد و البته LSM در قیاس با SVM از نظر زیستی بیشتر قابل پذیرش است؛ زیرا سازوکار آن مبتنی بر پتانسیل‌های عمل بوده و کرنل با مدارات نرونی پیاده‌سازی می‌شود.

در کاربردهای مهندسی، توان LSM در انجام وظایف مختلف در زمان بلادرنگ، از جمله بازشناسی گفتار [۳۷]، بازشناسی کلمه [۳۸] و رباتیک [۳۹] نشان داده شده و ادعا می‌شود عملکرد آن با سیستم‌های مدرن بازشناسی الگو قابل قیاس است. لازم به ذکر است که تلاش‌هایی نیز در جهت

فائق آمدن بر محدودیت‌های محاسباتی شبیه‌سازی با کامپیوترهای عادی صورت گرفته و بعضی از مطالعات به سمت مدارات مجتمع دیجیتال برنامه‌پذیر^{۵۶} (FPGA) گرایش پیدا کرده‌اند.

۴.۴.۳ شبکه‌های عصبی درون‌کشتگاهی

ساخت شبکه‌های عصبی درون‌رایانه‌ای که تمام جنبه‌های شبکه‌های عصبی زیستی را در خود بگنجانند ممکن است امکان‌پذیر نباشد. علت آن این است که تکنولوژی ثبت سلولی حاضر، تنها اجازه‌ی اندازه‌گیری بخش کوچک و محدودی از دینامیک نورونی و سیناپسی را می‌دهد. با این حال عامل‌های ناشناخته‌ی فراوانی مانند دینامیک‌های مولکولی، ترجمه و رونویسی ژنی وجود دارد که می‌توانند در یادگیری و حافظه دخیل باشند. برای نمونه تقویت بلند مدت^{۵۷} و تضعیف بلند مدت^{۵۸} (LTP/LTD) در نتیجه‌ی فعال شدن گیرنده‌های NMDA^{۵۹} یا تحکیم حافظه که بیان ژن‌ها در آن دخیل است از جمله‌ی این عوامل هستند. به عنوان مثال، در شبکه‌های زیستی، فاکتورهای زیادی، مانند سیگنال‌های کلسیمی، در تشکیل حافظه نقش دارند. حافظه‌ی کوتاه مدت لازمه‌ی پردازش اطلاعات زمانی است. تقویت و تضعیف سیناپس‌ها، طنین^{۶۰} سیگنال به موجب اتصالات بازگشتی و ثابت زمانی غشایی در یک نورون، منابع اصلی حافظه در شبکه‌های شبیه‌سازی شده‌ی درون‌رایانه‌ای هستند؛ با این حال فاکتورهای دیگری مانند سیگنال‌های کلسیمی به طور عادی در تحقیقاتی که از شبیه‌سازی بهره می‌برند مطالعه نشده و در نظر گرفته نمی‌شود.

به علاوه‌ی اینها، قدرت محاسباتی فعلی برای مدل‌سازی در این سطح دقت و جزئیات کافی نیست. در مقایسه با شبکه‌های زیستی که پردازش ورودی به صورت موازی و بلادرنگ صورت می‌گیرد، شبیه‌سازی‌های کامپیوتری بخاطر محدودیت‌هایی که دارند به طرز غیر قابل قبولی کند هستند. شبکه‌های درون‌کشتگاهی توانایی غلبه بر این مشکلات را دارند ولی قابلیت مشاهده و کنترل بسیار محدود روی این شبکه‌های نورونی عوامل بازدارنده‌ی مهمی هستند. دستگاه‌های MEA^{۶۱} به جهت ثبت سیگنال نورونی توسط یکسری الکترود کاربرد دارند. به طور عادی، یک ظرف MEA شامل

^{۵۶} Field-Programmable Gate Array

^{۵۷} Long-term potentiation

^{۵۸} Long-term depression

^{۵۹} N-Methyl-D-aspartic

^{۶۰} Reverberation

^{۶۱} Multielectrode array

۶۰ یا ۲۵۲ الکتروستات که می‌توانند برای ثبت پتانسیل‌های عمل از نورون‌ها یا تحریک الکتریکی آنها استفاده شوند. البته با وجود اینکه تنها صدها نورون از میان میلیون‌ها نورون یک کشت سلولی قابل ثبت هستند، تلاش‌های موثری در استفاده از شبکه‌های درون‌کشتگاهی برای انجام عملیات‌های مختلف صورت گرفته است.

۵.۳ مسئله‌ی تشخیص اشیا

عموم فعالیت‌های روزانه‌ی ما بستگی به تعیین ماهیت دقیق و سریع اشیا محیط اطرافمان دارد. شاید این موضوع که ما به آسانی توانایی تشخیص و بازشناسی اشیا را داریم باعث نادیده گرفتن عظمت و دشواری این کار شود. ما می‌توانیم اشیا را با وجود تغییرات متنوعی در ظاهرشان، از میان دهها هزار دسته‌ی^{۶۲} شی‌ای که از پیش می‌شناسیم و تنها ظرف کسری از ثانیه شناسایی کنیم. فهم کامل ساز و کارهای مغزی دخیل در این توانایی خارق‌العاده پیشرفت عظیمی در علم اعصاب به حساب خواهد آمد. مهمترین علت دشواری تشخیص اشیا از نظر محاسباتی این است که هر شی خاص، به دلیل تغییر در موقعیت، حالت و نورپردازی و نیز حضور اشیای دیگر در مجاورت آن می‌تواند مجموعه‌ای نامتناهی از تصاویر مختلف که امکان پدیدار شدن روی شبکه‌ی چشم ما را دارند تشکیل دهد. به عبارت دیگر، با اینکه امکان دارد یک شی را بارها مشاهده کرده باشیم، اما هرگز دو تصاویر کاملاً مشابه از آن شی در شبکه‌ی چشم ما تشکیل نمی‌شود. مغز ما علاوه بر اینکه این هزاران ورودی تصویری را به عنوان یک شی شناسایی می‌کند، تصویر شی دیگری را که حتی ممکن است تا حدی با تصاویر شی اول همبستگی داشته باشد را به عنوان شی‌ای مجزا شناسایی می‌کند. بنابراین تشخیص اشیا عبارت است از تمایز قائل شدن دقیق برای هر شی (تعیین هویت) و یا دسته‌ای از اشیا (طبقه‌بندی) در میان تمام اشیا دیگر. این تمایز باید نسبت به مجموعه‌ای از تغییرات روی تصویر شبکه‌ای آن شی (تغییراتی روی موقعیت، ابعاد و روشنایی شی) ناوردا باشد.

^{۶۲} تعداد دسته‌های بصری، حدود ۳۰۰۰ عدد تخمین زده شده‌اند. [۴۰] یعنی یک کودک ۶ ساله باید هر روز به طور متوسط حدود ۱۴ شی در روز یاد بگیرد. یا یک شی به ازای هر ساعت بیدار بودن.

۱.۵.۳ فرآیند محاسباتی تشخیص اشیا

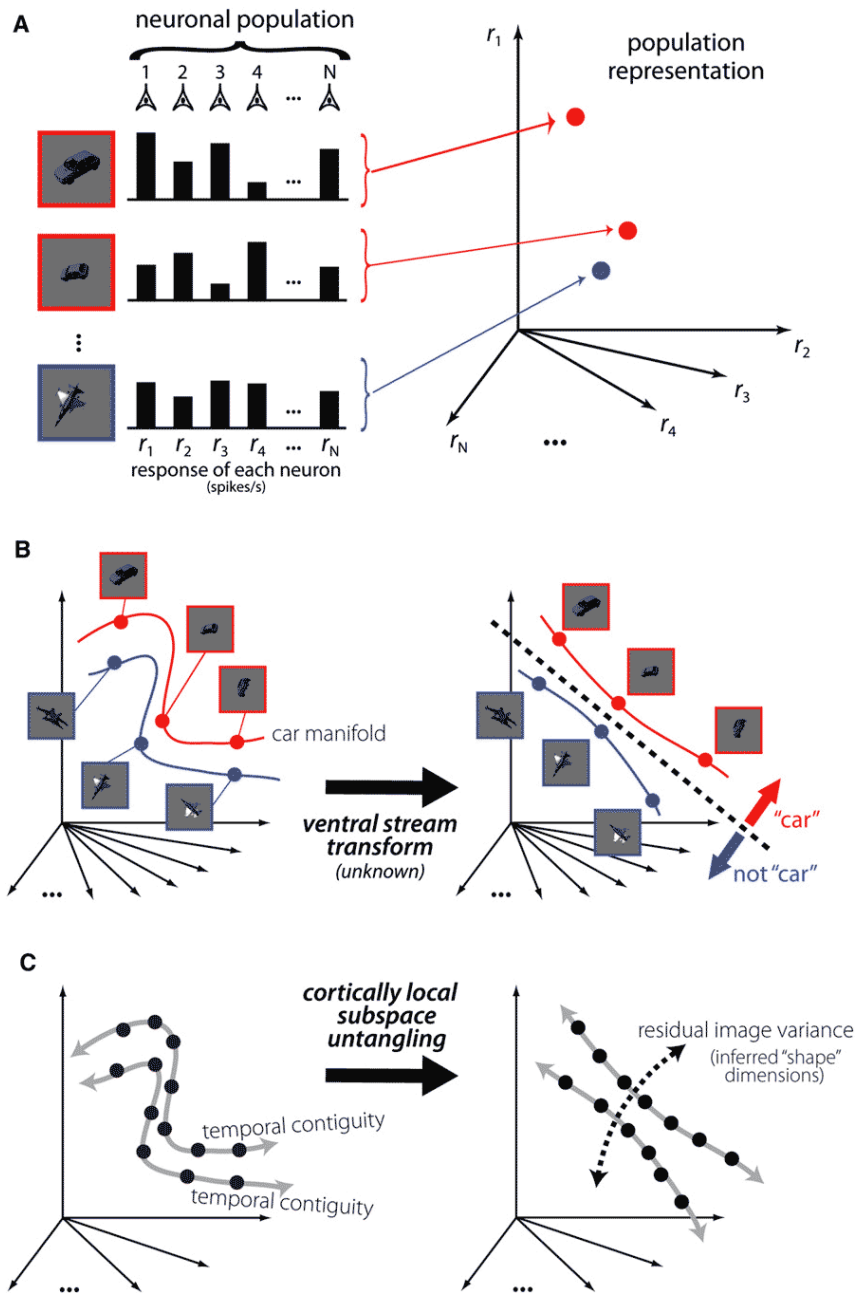
جهت انجام یک عمل تشخیصی، یک نمایش نورونی از صحنه‌ی بینایی (الگوی فعالیت جمعیتی نورونی) استفاده می‌شود تا یک تصمیم‌گیری (برای مثال حضور یک شی در تصویر) صورت پذیرد. از نظر محاسباتی مغز می‌بایست یک تابع تصمیم را به کار گیرد تا فضای نمایش نورونی را به وجود یا عدم وجود شی نگاشت دهد.

اعمال این تابع تصمیم توسط نورون‌ها صورت می‌گیرد. درباره‌ی مکان و نحوه‌ی کد کردن و همچنین تعداد نورون‌هایی که در فرآیند تصمیم‌گیری وارد می‌شوند فرضیه‌های بسیاری مطرح است. اما مسئله‌ای که از نظر محاسباتی اهمیت بسزایی دارد این است که ساختار نمایش ورودی چه بوده و نوع توابع تصمیم‌گیری روی این نمایش چیست. یعنی می‌توان مسئله تشخیص اشیا را به صورت اعمال یک تابع غیرخطی پیچیده روی یک نمایش ابتدایی (مانند خروجی سلول‌های گانگلیون) در نظر گرفت یا در مقابل می‌توان عملگرهایی را یافت که این نمایش اولیه را مرحله به مرحله به نمایش‌های بهتری تبدیل کرده و برای یک تابع تصمیم‌گیرنده، به سادگی یک طبقه‌بند خطی، آماده کند.

واقعیت این است که از نظر محاسباتی تفاوتی بین این دو روش وجود ندارد اما روش دوم بیشتر به نحوه‌ی حل مسئله توسط مسیر شکمی دستگاه بینایی قرابت دارد. با توجه به اینکه استفاده از طبقه‌بندی غیرخطی و پیچیده از نظر عملکرد تغییر چندانی بوجود نمی‌آورد، استفاده از چنین رهیافتی (طبقه‌بندی خطی روی پاسخ جمعیتی نورون‌های IT) کاملاً موجه می‌نماید.

با توجه به آنچه گفته شد، می‌توان دلیل دشواری تشخیص اشیا از نظر محاسباتی را ساخت صور مناسب نمایش‌دهنده‌ی اشیا دانست. در یک دید جمعیتی از کد شدن اطلاعات، می‌توان هر تصویر را به صورت نقطه‌ای در فضایی با ابعاد برابر با جمعیت نورونی دانست. از این رو، مجموعه‌ی تمام نقاط نمایانگر تصاویر ممکن از یک شی در فضای نمایش سلولی یک مرحله، سطح پر پیچ و خمی را می‌سازند که به آن خمینه^{۶۳} گفته می‌شود. دستگاه بینایی بر مبنای یک ساختار سلسله‌مراتبی، به نحوی فضای نمایش را تغییر می‌دهد که خمینه‌های اشیای مختلف از درهم‌تنیدگی خارج گردند [۴۱] (شکل ۳.۳).

از آنجایی که تعداد مولفه‌های فضای نمایش نورونی با پیشروی در مسیر شکمی تغییر می‌کند،



شکل ۳.۳: از هم باز کردن نمایش شی: (A) الگوی پاسخ جمعیت نورون‌های بینایی (برای مثال سلول‌های گانگلیون) برای هر تصویر، نقطه‌ای در یک فضا با ابعاد بسیار است که در آن هر محور، سطح پاسخ هر نورون می‌باشد (B) همه‌ی تبدیل‌های حافظه‌ی هویت از یک شی، یک خمینه با ابعاد پایین از نقاط را در فضای بردار جمعیت نمایش می‌دهند. جمعیت‌های نورونی در نواحی اولیه‌ی بینایی (سلول‌های گانگلیون، LGN و V1) شامل خمینه‌های هویت شی هستند که انحنای بسیاری داشته و در هم تنیده هستند (خمینه‌های قرمز و آبی) راه‌حل مسئله‌ی بازشناسی به نحو مفهومی، به صورت یکسری بازنمایش متوالی در طول مسیر شکمی (فلش مشکی) به یک نمایش جمعیتی جدید (IT) تبیین می‌شود که امکان جداسازی و تمایز ساده بین خمینه‌های یک شی (خمینه قرمز برای خودرو) را با اشیای دیگر (خمینه آبی) را بدهد. از لحاظ هندسی این معادل آن است که به طوری نگاشت مجدد انجام شود که بتوان با یک جمع وزن‌دار ساده جداسازی صورت داد (یک ابرصفحه مانند خط مشکی منقطع) ت (C) اکثر تصاویری که به صورت طبیعی تجربه می‌شوند برچسب (مانند «ماشین» یا «هواپیما») ندارند و مشابه شکل صرفاً با یکسری نقاط در فضا مشخص شده‌اند. با این حال تصاویر با منشا یکسان (لبه یا شی) از لحاظ زمانی (فلش‌های طوسی) به هم نزدیک هستند. مشاهدات مبنی بر اهمیت این مجاورت برای IT است. [۴۱]

می‌توان این تغییرات را نوعی مقیاس‌بندی چند بعدی در نظر گرفت که در نهایت منجر به صاف شدن^{۶۴} خمینه‌ی اشیا می‌شود.

۶.۳ مدل‌های ارائه شده برای مسیر اصلی دستگاه بینایی


با در نظر گرفتن نحوه‌ی عملکرد سلول‌های عصبی، مشخصا در نواحی فراتر از V1، مدل‌هایی برای عملکرد سلول‌های جریان شکمی ارائه شده است که می‌توان آنها را در سه دسته‌ی کلی که در ادامه می‌آید طبقه‌بندی کرد.

۱.۶.۳ مدل‌های عصب‌زیست‌شناختی

بسیاری از مدل‌های حاضر جهت تشخیص اشیا بر پایه‌ی یافته‌های هوشمندانه‌ی هابل و ویزل از سلول‌های ساده و پیچیده‌ی قشر اصلی بینایی ارائه شده‌اند. هابل و ویزل با کشف سلول‌های ساده و پیچیده، بر اساس رفتار این سلول‌ها و با اطلاعاتی که از مسیر جریان اطلاعات بدست آوردند مدلی عصب‌زیست‌شناختی^{۶۵} ارائه کردند. بر اساس این مدل، سلول‌های ساده به علت نوع ورودی‌شان از سلول‌های LGN که مراکز میدان تاثیرشان در راستای یک خط با جهت‌گیری مشخص است، این نوع پاسخ جهت‌گیری در یک راستا را تولید می‌کنند. در این مدل فرض بر آن است که سلول‌های پیچیده منحصراتنها از سلول‌های ساده ورودی دریافت کرده و حاصل جمع خروجی‌های سلول‌های ساده با جهت ارجح یکسان ولی با میدان تاثیر متفاوت در یک همسایگی (موقعیت‌های مجاور یکدیگر) منجر به تولید میدان تاثیر سلول‌های پیچیده می‌شود.

۲.۶.۳ مدل‌های الهام گرفته از مسیر بینایی

مدل هابل و ویزل را می‌توان اینگونه خلاصه کرد که از سلسله مراتبی از سلول‌ها تشکیل می‌شود که در ابتدای آن، سلول‌هایی با تقارن مدور وجود دارند که همانند سلول‌های LGN به نقاط کوچک نورانی قوی‌ترین پاسخ را می‌دهند. سپس سلول‌های ساده هستند که به نقاط نورانی پاسخ نمی‌دهند، بلکه به



شکل ۴.۳: ساختار لایه‌ای Neocognitron [۴۲]


محرك‌های میله‌ای یا لبه‌ای در یک جهت و موقعیت خاص و با فاز معین پاسخ می‌دهند. در مرحله‌ی بعد سلول‌های پیچیده را داریم که آنها هم نسبت به میله‌های نورانی با یک جهت خاص گزینندگی دارند ولی نسبت به مکان و فاز محرك در میدان تاثیرشان حساس نیستند. در بالای این ساختار سلسله مراتبی سلول‌های فوق‌پیچیده^{۶۶} نه تنها به مانند سلول‌های پیچیده به موقعیت و فاز میله‌های نورانی پاسخ ناوردا داشته، بلکه پاسخ آنها نسبت به طول میله‌ی نورانی نیز حساس است.

هابل و ویزل پیشنهاد دادند که چنین نمایش‌های به تدریج ناوردا و پیچیده‌ای می‌تواند از جمع ورودی‌های همگرا از سطوح پایین‌تر بدست آمده باشد.

بسیاری از مدل‌های تشخیص اشیا از این ساختار سلسله‌مراتبی و همچنین ناوردایی و پیچیدگی فزاینده‌ی گزینندگی در طول آن، ایده گرفته‌اند. از اولین مدل‌هایی که چنین رویکردی را در پیش گرفت و ناوردایی به تغییرات مکان را در تصویر نشان می‌دهد، مدل Neocognitron بود. این مدل در سال ۱۹۸۰ توسط کانیهیکو فوکوشیما ارائه شد [۴۲] که البته از نسخه‌ی ابتدایی آن تا کنون تغییرات بسیاری در ساختار و قواعد حاکم بر آن مطرح شده است.

این ساختار از یک لایه‌ی ورودی، متناظر با پیکسل‌های تصویر ورودی، تشکیل شده و بعد از آن به صورت یکی در میان، لایه‌های S و C (متناظر با سلول‌های ساده و پیچیده) قرار دارند. واحدهای

^{۶۶} Hypercomplex cells یا End-stopped cells



شکل ۵.۳: اشتراک وزنی

S ویژگی‌های مشخصی از ورودی را استخراج و با پیشروی در طول مسیر پیچیده‌تر می‌شود و واحدهای C نیز منجر به ناوردایی به تغییرات مکانی خواهند شد (شکل ۴.۳).

میدان تاثیر سلول‌های S نشان دهنده‌ی ویژگی‌های استخراج شده است و با هدف بهینه کردن عمل بازشناسی در طی فرآیند یادگیری صرفاً اوزان اتصالات آوران به واحدهای S میزان‌سازی می‌شود. در هر کدام از مراحل، دو لایه‌ی متوالی، به ترتیب از واحدهای S و C قرار دارند و U_{sl} نمایانگر لایه‌ای از سلول‌های S در مرحله‌ی l ام است. اتصالات ما بین دو لایه‌ی متوالی خاصیت رتینوتوپیک^{۶۷} دارند؛ به این معنی که مجاورت مکانی بین ویژگی‌ها را حفظ می‌کنند. همچنین در این مدل از قابلیت اشتراک وزنی^{۶۸} استفاده می‌شود و از این روی ضرایب اتصالات ورودی و اندازه‌ی میدان تاثیر سلول‌های یک لایه با یکدیگر برابر بوده ولی موقعیت‌های مختلفی را پوشش می‌دهند (شکل ۵.۳).

مدل‌های متعدد دیگری با ایده گرفتن از ساختار سلسله مراتبی مسیر اصلی دستگاه بینایی توسعه یافته‌اند. مدل Neocognitron الهام‌بخش شبکه‌های عصبی پیچشی است که امروزه تحقیقات زیادی روی آنها متمرکز شده است. با وجود موفقیت نسبی این مدل‌ها در ماشین‌های تشخیص اشیا، هیچ کدام از آنها هنوز مدل کاملی برای مسیر اصلی بینایی ارائه نکرده‌اند.

^{۶۷} Retinotopic
^{۶۸} Weight sharing

۳.۶.۳ مدل‌های دارای انطباق زیستی

مدل‌هایی که پیشتر معرفی شدند، اغلب بخاطر اینکه ایده اصلی‌شان را از ساختار زیستی مسیر بینایی الهام گرفته‌اند تا حدی قابل قبول‌اند؛ با این حال هیچکدام دارای سازوکارهای نورونی سازگار با یک سیستم زیستی نیستند. همانطور که بیان شد، ممکن است این نکته از نظرها پنهان بماند که دستگاه بینایی با چه چالش عظیمی در بازشناسی الگو از جمله تغییرات مکانی، زاویه‌ی دید و میزان روشنایی مواجه است. نقطه‌ی قوت دستگاه بینایی این است که با وجود دریافت محرک‌های متفاوت از یک شی، هنوز امکان تشخیص آن را دارد. پس دستگاه بینایی باید بتواند تغییرات در زاویه‌ی دید، موقعیت، اندازه و میزان نور را نادیده بگیرد. پس برای تعیین هویت اشیایی که از نظر فیزیکی مشابه‌اند باید بتوان آنها را تفکیک کرد ولی در مقابل برای طبقه‌بندی و دسته‌بندی اشیا باید بین اشیایی که از نظر فیزیکی متفاوتند تعمیم‌پذیری قائل شد.

به طور کلی برای شناخت، تعیین هویت و یا طبقه‌بندی یک شی باید نمایش بینایی آن با نمایشی که در حافظه قرار گرفته است مقایسه گردد. این چالش ما را به این سوال اساسی می‌رساند که اشیا چگونه در دستگاه بینایی نمایش داده می‌شوند.

دو دیدگاه مختلف از پس این پرسش برآمده است: دیدگاه اول بر این فرض استوار است که نتیجه‌ی تمام فعالیت‌های نورونی در مسیر اصلی بینایی، پدیدار کردن نمایشی است که در آن اشیا به صورت مجموعه‌ای از ویژگی‌های مشخص برای زاویه‌ی دید، نمایش یابند. به عبارت دیگر، در این دسته از مدل‌ها عمل تشخیص و بازشناسی به صورت تابعی از زوایای دید که از قبل تجربه شده‌اند می‌باشد. در مقابل آن، دیدگاه دوم که شامل مدل‌های توصیف ساختاری^{۶۹} است را داریم. نظریه‌ی تشخیص با مولفه‌ها^{۷۰} (RBC) در سال ۱۹۸۷ توسط بیدرمن ارائه شده [۴۰] و در آن فرآیند تشخیص شامل استخراج توصیفی ساختاری و ناوردان نسبت به زاویه‌ی دید از شی، بر حسب رابطه‌های فضایی میان مولفه‌های حجمی شی (تحت عنوان geon) و سپس مقایسه آن با توصیف‌های ذخیره شده، می‌باشد. با این حال داده‌های بدست آمده از آزمایش‌های فیزیولوژی و روان‌فیزیکی^{۷۱} ناوردان بودن نمایش نهایی اشیا در مسیر بینایی نسبت به زاویه‌ی دید را رد کرده است و دیدگاه دوم از این منظر غیرقابل قبول

^{۶۹} Structural descriptions

^{۷۰} Recognition-by-components

^{۷۱} Psychophysical

است. ما نیز در ادامه دیدگاه اول را می‌پذیریم.

فصل ۴

مدل پیشنهادی و کارهای صورت گرفته

در این فصل به تبیین ساز و کار ارائه شده پرداخته می‌شود. در ابتدای فصل، دادگان انتخاب شده برای آزمایش‌های صورت گرفته روی مدل‌های محاسباتی معرفی می‌شود. در بخش بعدی، جزئیات و پارامترهای شبکه‌ی سلسله مراتبی که در فصل پیش معرفی شد بیان می‌شود. پس از آن مکانیسم‌های برقراری اتصالات سیناپسی در ماشین‌های حالت مایع مورد بررسی قرار می‌گیرد. این بخش همچنین مدل نورونی و مدل سیناپسی را به همراه نحوه‌ی شکل‌پذیری سیناپسی بیان می‌کند. در نهایت با معرفی معیار میزان تفکیک‌پذیری و همچنین به کار بردن دو طبقه‌بند، نحوه‌ی عملکرد ماشین حالت مایع تحت پارامترهای مختلف عرضه می‌گردد.

۱.۴ دادگان استفاده شده

جهت ارزیابی کارایی معماری عرضه شده از دو مجموعه‌ی داده‌ی CALTECH^۱ با عناوین Motor-2001 cycles و Faces 1999 استفاده شده است. هر مجموعه‌ی داده به دو مجموعه‌ی آموزشی (جهت استفاده در گام یادگیری شبکه) و آزمون (جهت ارزیابی شبکه در گام آزمون) افزاشده است. ابعاد تصاویر با هم فرق داشته و از این جهت با ثابت گرفتن ارتفاع تصویر روی ۳۰۰ پیکسل، با حفظ نسبت ابعاد^۲، مقیاس‌بندی مجدد شده‌اند. علاوه بر آن، از آنجایی که تحقیق جاری بر روی نقش

^۱ قابل بارگذاری از <http://www.vision.caltech.edu/>

^۲ Aspect ratio

جدول ۱۰۴: تعداد نمونه‌های ورودی

تعداد نمونه	بخش	کلاس
۲۱۸	Train	صورت
۲۱۷	Test	
۴۰۰	Train	موتورسیکلت
۴۰۰	Test	



شکل ۱۰۴: نمونه تصاویر ورودی (متشکل از تصاویر موتورسیکلت و صورت انسان) که برای آموزش و ارزیابی کارایی استفاده شده‌اند.

رنگ‌ها در بازشناسی تمرکز ندارد، تصاویر به طیف رنگ خاکستری تبدیل شده‌اند. نمونه‌ی تصاویر استفاده شده را می‌توان در شکل ۱۰۴ مشاهده نمود. به طور خلاصه برای ارزیابی کارایی مدل‌ها، در گام آموزش و آزمون به ترتیب ۱۵۰ و ۲۸۵ نمونه استفاده شده است. لازم به ذکر است که از ۱۵۰ تصویر به کار رفته، صرفاً تعداد ۱۰۰ تصویر جهت آموزش شبکه‌ی سلسله مراتبی استفاده می‌شود که به موجب آن توانایی تعمیم‌پذیری بیشتری طبق آزمایش‌ها حاصل شده است.

در ادامه به دو مولفه‌ی اصلی تشکیل‌دهنده‌ی مدل ارائه شده می‌پردازیم و به تفصیل هر کدام را با جزئیات معرفی خواهیم کرد.

۲.۴ شبکه سلسله مراتبی

دادگان ورودی در ابتدا وارد شبکه‌ی سلسله مراتبی می‌شوند. مدل سلسله مراتبی از سلول‌های ساده و پیچیده تشکیل می‌شوند. طی عملیات سلول‌های ساده، گزینندگی مناسب نورون شکل می‌پذیرد در حالی که در نتیجه‌ی عملیات سلول‌های پیچیده، مدل نسبت به مقیاس و موقعیت مقاوم می‌شود.

۱.۲.۴ لایه‌های شبکه‌ی سلسله مراتبی

چهار لایه نورون در این مدل به شرح ذیل هستند:

- **سلول‌های S1**، با اعمال یک همگشت یا پیچش^۳ روی تصویر ورودی، لبه‌ها را شناسایی می‌کنند. ما برای این لایه، از ساز و کار نورونی (که پیشتر نحوه‌ی تشکیل و عملکردشان تبیین شده است) استفاده نکرده و صرفاً از اعمال فیلترهای 5×5 گابور^۴ بدست می‌آید که طول موج ۵، عرض موثر ۲ و چهار جهت ارجح $(\pi/8, \pi/4 + \pi/8, \pi/2 + \pi/8, 3\pi/4 + \pi/8)$ دارند. فیلترها روی پنج مقیاس از تصویر ورودی، یعنی ۱۰۰٪ (تصویر اصلی)، ۷۰٪، ۵۰٪، ۳۶٪ و ۲۵٪، اعمال می‌گردند. پس با در نظر گرفتن پنج مقیاس و چهار زاویه‌ی جهت‌گیری، شبکه شامل ۲۰ نقشه‌ی S1 است. سلول‌های S1 ضربه‌هایی با تاخیر متناسب با معکوس شدت پاسخ فیلتر تولید می‌کنند. به عبارت دیگر، هر چه محرک با جهت‌گیری نورون انطباق بیشتری داشته باشد، سریعتر ضربه پاسخ آن تولید می‌شود. فعالیت نورونی همچنین در این لایه محدود می‌شود و در هر مقیاس و موقعیت تنها ضربه‌ی بهترین جهت مورد انطباق انتقال می‌یابد.
- **سلول‌های C1** اولین ضربه‌های دریافت شده از سلول‌های S1 قرار گرفته در یک میدان تاثیر مربعی 7×7 از یک نقشه‌ی S1 را پردازش می‌کنند. هر نقشه‌ی S1 متناظر با یک جهت و یک مقیاس است. دو سلول C1 که در یک نقشه‌ی C1 کنار هم قرار گرفته‌اند متناظر با دو میدان تاثیر مربعی 7×7 از سلول‌های S1 هستند که به اندازه‌ی ۶ واحد S1 از هم فاصله داشته و به اندازه‌ی یک نورون S1 همپوشانی دارند. پس با در نظر نگرفتن گوشه‌ها، سلول‌های C1 چیزی در حدود $36 = 6 \times 6$ بار کمتر از سلول‌های S1 هستند. عملگر ادغام بیشینه که نسبت به تغییر موقعیت، ناوردایی ایجاد می‌کند از لحاظ زیستی قابل پذیرش است [۲۶]. علاوه بر زیرنمونه گرفتن در این لایه، مکانیسم منکوب جانبی^۵ به کار برده شده است که در نتیجه‌ی آن اگر یک ناحیه به وضوح برای یک جهت غالب باشد، سلول‌های دیگر را با افزایش تاخیر آنها مهار کرده و در نتیجه‌ی STDP تقویت بیشتری می‌یابد. مکانیسم مهار جانبی به این نحو است که به موجب یک ضربه‌ی C1، تاخیر همسایگانش در همسایگی 11×11 از نقشه با همان مقیاس و جهت

^۳ Convolution

^۴ Gabor

^۵ Lateral inhibition

افزایش می یابد.

• **سلول های S2** از لحاظ پیچیدگی ویژگی های بصری در سطح بالاتری قرار می گیرند. در تحقیق جاری ما تنها از چهار عدد سلول نمونه ی S2، به جهت تمرکز و تبیین بهتر عملکرد ماشین حالت مایع که در بخش بعد توضیح داده خواهد شد استفاده کرده ایم. در واقع به ازای هر سلول نمونه، پنج نورون با پنج نقشه (به ازای هر مقیاس) وجود دارد که با مکانیسم اشتراک وزنی^۶ کار می کنند. در هر نقشه، سلول S2 تنها می تواند ضربه های چهار نقشه ی C1 در جهت های مختلف متناظر با مقیاس مورد پردازش را جمع کند. میدان تاثیر به اندازه ی 16×16 سلول C1 و 96×96 سلول S1 خواهد بود. همچنین اتصالات سیناپسی از C1 به S2 با به کارگیری STDP میزان سازی می شوند.

لازم به ذکر است که فعالیت نورونی نیز محدود می شود. با استفاده از یک مکانیسم k-winner-take-all، حداکثر دو نورون به ازای هر مقیاس پردازشی می توانند آتش کنند. این مکانیسم که تنها در گام یادگیری استفاده می گردد به یادگیری الگوها در اندازه ها و مقیاس های مختلف کمک می کند. بدون این مکانیسم، گرایش به یادگیری الگوهای کوچکتر (مقیاس های بزرگتر) وجود داشته و بخاطر بزرگتر بودن نقشه های متناظر، احتمال ضربه با وزن تصادفی در ابتدای فرآیند STDP بالا می بود.

• **سلول های C2** برای هر نمونه بیشترین پاسخ (یعنی اولین ضربه) از سلول های S2 متناظر را در همه ی موقعیت ها و مقیاس ها گرفته و در نتیجه چهار نورون با ناوردایی نسبت به موقعیت و مقیاس خواهیم داشت.

^۶Weight sharing

۲.۲.۴ مدل STDP برای شبکه‌ی سلسله مراتبی

مدل STDP از یک قاعده‌ی ساده بهره می‌برد:

$$\begin{cases} \Delta w_{ij} = a^+ w_{ij} (1 - w_{ij}) & \text{if } t_j - t_i > 0 \\ \Delta w_{ij} = a^- w_{ij} (1 - w_{ij}) & \text{if } t_j - t_i \leq 0 \end{cases} \quad (1.4)$$

که i و j به ترتیب نمایانگر نورون‌های پیش و پس سیناپسی هستند که زمان ضربه‌ی آنها با t_i و t_j نمایش داده شده است. Δw_{ij} تغییر وزن سیناپس متصل کننده‌ی i به j را نشان می‌دهد و a^+ و a^- دو پارامتری هستند که میزان تغییرات را تعیین می‌کنند. همانطور که از معادله‌ی بالا بر می‌آید، تغییرات وزنی بر میزان $t_i - t_j$ وابسته نبوده بلکه صرفاً به علامت آن که نشان‌دهنده‌ی ترتیب دو ضربه نسبت به یکدیگر است وابسته می‌باشند. مورد دیگر این است که پنجره‌ی زمانی برای STDP نامحدود در نظر گرفته شده است.


۳.۲.۴ مدل نورونی و سیناپسی

مدل نورونی مورد استفاده برای سلول‌های S2 در مدل سلسله مراتبی از نوع تجمیع و آتش^۷ (IF) است. این نورون‌ها نیازی به نشستی^۸ ندارند. در مغز با استفاده از نشستی، از تداخل موج ضربه‌های پشت سر هم جلوگیری می‌شود که در مدل سلسله مراتبی نیاز به آن نیست زیرا پیش از ارائه‌ی تصویر هر محرک ورودی، همه‌ی پتانسیل‌ها مقداره‌ی مجدد می‌شوند. مدل سیناپسی نیز از نوع مبتنی بر جریان^۹ (CUBA) می‌باشد به این معنی که ساده‌سازی شده و خاصیت خازنی ندارد.

۴.۲.۴ پارامترها و عملکرد شبکه‌ی سلسله مراتبی

پارامترهای استفاده شده در شبیه‌سازی در جدول ۲.۴ آورده شده‌اند. عملکرد شبکه‌ی سلسله مراتبی با پارامترهای جدول ۲.۴، بسته به نوع طبقه‌بند استفاده شده، چیزی حدود ۸۳٪ می‌باشد. لازم به

Integrate-and-Fire^۷
Leakage^۸
Current Based^۹



شکل ۲.۴: نمونه میدان‌های تأثیر شبکه‌ی سلسله مراتبی

ذکر است که در صورتی که تعداد ویژگی‌ها (تعداد نورون‌های خروجی این شبکه) را افزایش دهیم، عملکرد بسیار بهبود می‌یابد اما بدلیل اینکه هدف ارزیابی تأثیرگذاری ماشین حالت مایع بوده است، تعداد ویژگی‌ها بسیار محدود شده و مشخصاً چهار نورون تعیین شده است. اغلب پارامترهای استفاده شده بر اساس مقاله‌ی ماسکولیه و تورپ [۲۲] تعیین شده است؛ با این حال سه پارامتر Epochs، SRF و Threshold طی گستره‌ای از مقادیر ممکن بررسی شده و مقادیری که منتج به بهترین نتیجه (با تعداد چهار ویژگی) شده مورد استفاده قرار گرفته است. شبکه‌ی سلسله‌مراتبی ابتدا به زبان پایتون پیاده‌سازی و امکان‌سنجی شد اما در انتها به جهت زمان‌بر بودن اجرا، مجدداً به زبان C++ بازنویسی شد که جزئیات آن در پیوست آ ذکر شده است.

جدول ۲۰۴: پارامترهای شبکه‌ی سلسله مراتبی و مقادیر انتخاب شده

پارامتر	مقدار	توضیحات
GaborRF	۵	عرض و طول میدان تاثیر سلول‌های S1
GaborCRF	۷	عرض و طول میدان تاثیر سلول‌های C1
C \ InhibRFsize	۵	اندازه‌ی همسایگی در مهار جانبی
C \ InhibPercentClose	۰/۱۵	حداکثر میزان مهار جانبی (برای نزدیکترین همسایگان)
C \ InhibPercentFar	۰/۰۵	حداقل میزان مهار جانبی (برای دورترین همسایگان)
Threshold	۳۰	آستانه‌ی آتش سلول‌های ساده
meanWeight	۰/۸	میانگین توزیع تصادفی نرمال برای وزن‌های سیناپسی
stdDevWeight	۰/۰۵	انحراف معیار توزیع تصادفی نرمال برای وزن‌های سیناپسی
SRF	۱۷	عرض و طول میدان تاثیر سلول‌های S2
CRF	۳	عرض و طول میدان تاثیر سلول‌های C2
CSTRIDE	۲	میزان پرش از همسایگی برای محاسبه‌ی ادغام بیشینه
kWTA	۲	تعداد برنده‌ی نخستین
Epochs	۵	تعداد دفعات ارائه‌ی نمونه‌ها
Features	۴	تعداد سلول‌های C2
Ap	۱/۶۴	مقدار اولیه‌ی اندازه‌ی LTP
An	$-3/4 \times Ap$	مقدار اولیه‌ی اندازه‌ی LTD
ApLimit	۰/۲۵	حداکثر میزان اندازه‌ی LTP (و به تبع آن LTD)

جدول ۳۰۴: مقادیر سه پارامتر مورد آزمایش برای شبکه‌ی سلسله مراتبی

پارامتر	مقادیر
SRF	۱۵، ۱۷
Threshold	۱۰۰، ۸۰، ۶۵، ۳۰، ۱۰
Epochs	۲۰، ۱۰، ۵

۳.۴ ماشین حالت مایع

برای پیاده‌سازی ماشین حالت مایع، از شبیه‌سازهای Annarchy [۴۳] و Brian [۴۴] استفاده شده است.

۱.۳.۴ مدل نوروני

برای ساخت فیلتر مایع، از نورون‌های تجمیع و آتش نشستی^{۱۰} یا به اختصار LIF استفاده شده است.

نورون‌ها در فیلتر مایع در یک نقاط صحیح از یک فضای سه بعدی قرار می‌گیرند. ۲۰٪ نورون‌ها

^{۱۰} Leaky Integrate-and-Fire

مهارى^{۱۱} و ۸۰٪ باقى آنها تحريكى^{۱۲} هستند. نورون‌هاى LIF با وجود سادگى‌شان در شبیه‌سازى هاى فراوانى استفاده مى‌شوند [۴۵]. در اینجا ما از مدل استاندارد LIF استفاده کرده‌ايم که توصیف دینامیک آن با معادله‌ی دیفرانسیل ۲.۴ مى‌باشد.

$$\tau_m \frac{dV_m}{dt} = -(V_m - v_{rest}) + R_m(I_{syn} + I_{inject} + I_{noise}) \quad (2.4)$$

که در آن ثابت زمانی غشا $\tau_m = 30ms$ ، مقاومت غشایی $R_m = 1M\Omega$ ، جریان ثابت ورودی I_{inject} و از نویز تصادفی I_{noise} هم صرف نظر شده است. در گام اول شبیه‌سازى، پتانسیل غشایی V_m به مقداری تصادفی بین $13.5mV$ و $15mV$ تنظیم می‌شود. اگر V_m مقداری بیش از ولتاژ آستانه‌ی $15mV$ اختیار کند، آتش کرده و به مقدار $13.5mV$ باز می‌گردد. با آتش یک نورون، به مدت انکسار^{۱۳} نورون از آتش کردن پرهیز می‌کند که این مقدار برای نورون‌های تحریکی برابر ۳ میلی‌ثانیه و برای نورون‌های مهارى برابر ۲ میلی‌ثانیه می‌باشد [۴۶]. نورون‌های ورودی محرک را دریافت کرده و از طریق سیناپس‌های ایستا در فیلتر مایع تزریق می‌کنند. هر نورون ورودی که نمایانگر خروجی شبکه‌ی سلسله مراتبی می‌باشد به یک نورون تحریکی تصادفی در فیلتر مایع متصل است.

۲.۳.۴ سیناپس‌های دینامیک

تمام اتصالات برقرار شده میان نورون‌های انباره از نوع سیناپس‌های دینامیک هستند. سیناپس‌های دینامیک مکانیسم‌های تسهیل کوتاه مدت^{۱۴} و تضعیف کوتاه مدت^{۱۵} را به کار می‌گیرند [۴۷]:

$$A_k = w.u.R_k$$

$$u_k = U + u_{k-1}(1 - U)\exp(-\Delta_{k-1}/F) \quad (3.4)$$

$$R_k = 1 + (R_{k-1} - u_{k-1}R_{k-1} - 1)\exp(-\Delta_{k-1}/F)$$

Inhibitory^{۱۱}

Excitatory^{۱۲}

Refractory period^{۱۳}

Short-term facilitation^{۱۴}

Short-term depression^{۱۵}

که در آن w وزن سیناپس، A_k بزرگی^{۱۶} جریان پس سیناپسی است که توسط k امین ضربه افزایش یافته و Δ_{k-1} بازه‌ی زمانی بین $k-1$ امین و k امین ضربه است. u_k اثر تسهیل^{۱۷} را مدل کرده و R_k اثر تضعیف^{۱۸} را مدل می‌کند. D و F به ترتیب ثابت‌های زمانی برای تضعیف و تسهیل هستند و U متوسط احتمال رهاسازی پیام‌رسان عصبی را نشان می‌دهد. مقادیر اولیه‌ی u و R ، که ضربه‌ی نخستین را توصیف می‌کنند، برابر $u_1 = U$ و $R_1 = 1$ قرار داده شده‌اند.

بسته به تحریکی یا مهارى بودن نورون‌های پیش و پس سیناپسی، مقادیر U ، D و F از توزیع‌های گوسی استخراج می‌شوند که بر اساس یافته‌های ارائه شده [۴۶] میانگین U ، D و F به ترتیب ۰/۵، ۱/۱ و ۰/۵ برای اتصالات تحریکی به تحریکی، (EE) ۰/۰۵، ۰/۱۲۵ و ۱/۲ برای اتصالات تحریکی به مهارى، (EI) ۰/۲۵، ۰/۷ و ۰/۰۲ برای مهارى به تحریکی و ۰/۳۲، ۰/۱۴۴ و ۰/۰۶ برای مهارى به مهارى تعیین شده است. انحراف معیاری هر کدام از این پارامترها، نصف مقدار مذکور برای میانگین قرار گرفته است.

وزن‌های اتصالات سیناپسی، درون فیلتر مایع، همانطور که اشاره شد ایستا بوده و تغییر نمی‌کنند. وزن‌های اولیه به صورت $W \times W_{scale}$ مشخص می‌شود که W_{scale} ضریب وزن سیناپسی است که به ازای مختلف آن را بررسی خواهیم کرد. W به صورت تصادفی از یک توزیع با میانگین $10^{-8} \times 3$ برای EE، $10^{-8} \times 6$ برای EI و $10^{-8} \times 1/9$ برای II و IE انتخاب می‌شود [۳۰]. انحراف معیار برای انتخاب وزن‌های تصادفی نصف مقدار میانگین تعیین شده‌اند؛ به عبارت دیگر ضریب تغییر برابر ۰/۵ است.

۳.۳.۴ لایه‌ی قرائت

برای لایه‌ی قرائت از دو طبقه‌بند خطی، یعنی آنالیز افتراق خطی (LDA) و ماشین بردار پشتیبان (SVM) به عنوان لایه‌ی نهایی برای بازشناسی الگو استفاده شده است تا با مقایسه‌ی آن دو قدرت ماشین حالت مایع تبیین شود. هر دو ثانیه یک تصویر به شبکه‌ی سلسله مراتبی ارائه می‌شود و به ازای ارائه‌ی هر تصویر، طبقه‌بند در لایه‌ی قرائت، حالت فیلتر مایع را دریافت می‌کنند. برخی از کارهای منتشر شده

^{۱۶} Amplitude^{۱۷} Facilitation^{۱۸} Depression

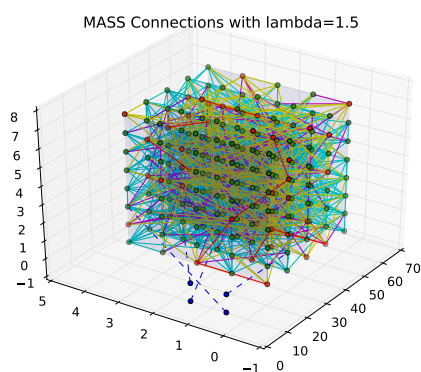
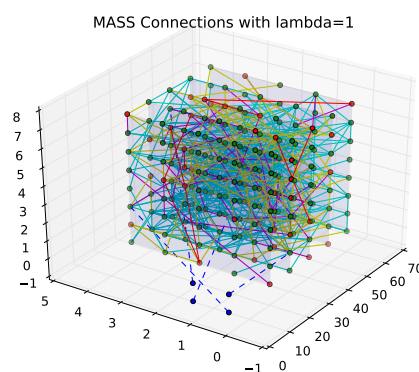
در زمینه‌ی ماشین‌های حالت مایع، از پتانسیل غشایی نورون‌های فیلتر مایع برای نمایش حالت نورون استفاده می‌کنند. با این حال در اینجا از زمان آتش ضربه‌های نورون‌های فیلتر مایع استفاده شده است. بخاطر طولانی بودن بازه‌ی ارائه‌ی هر تصویر، صرفاً اتکا بر شمارش تعداد ضربه‌های نورون‌ها می‌تواند بخش زیادی از اطلاعات (زمانبندی دقیق ضربه‌ها) را از بین برده و کیفیت عملکرد را کاهش دهد. در مقابل برخی در بازه‌های زمانی کوتاه‌تر تعداد ضربه‌ها (یا مقدار پتانسیل غشایی) را گزارش می‌دهند که با وجود بهبود تمایز بین نمونه‌ها، ابعاد ویژگی را افزایش داده و کار را برای طبقه‌بند دشوار می‌کند. به این جهت رابطه‌ی ۴.۴ در این پژوهش ارائه شده است که با پایین نگه‌داشتن ابعاد ویژگی (یک عدد به ازای هر نورون و دنباله‌ی ضربه)، زمان و ترتیب ضربه‌ها را نیز تا حدودی، علاوه بر تعداد ضربه‌ها، در حالت فیلتر مایع تعریف شده دخیل می‌کند. مقدار وضعیت نهایی نورون i ام، $s_m^f(i)$ ، در فیلتر مایع با محرک ورودی m بر اساس ضربه‌هایی که آتش کرده است به صورت ذیل محاسبه می‌گردد:

$$s_m^f(i) = \sum_n \exp\left(-\frac{t_i^n}{\tau}\right) \quad (۴.۴)$$

که در آن τ ثابت زمانی است که برابر ۵۰ میلی‌ثانیه می‌باشد. t_i^n زمان n امین ضربه برای هر محرک ورودی می‌باشد. طبق این رابطه و بر اساس نحوه‌ی عملکرد شبکه‌ی سلسله‌مراتبی، به ضربه‌هایی که زودتر برسند ارزش بیشتری داده می‌شود. هر چه ثابت زمانی τ بزرگتر گرفته شود، این رابطه بیشتر شبیه شمارش ساده‌ی تعداد ضربه‌ها می‌شود.

۴.۳.۴ توپولوژی اتصالات

اتصالات در کرنل به صورت تصادفی مقداردهی اولیه می‌شوند و هیچگاه در طول آموزش تغییر نمی‌کنند. به این جهت مسئله‌ی اتصال سیناپسی از اهمیت بسیاری برخوردار است که به این گونه بیان می‌شود: چگونه ساختار کرنل را طراحی کنیم تا امکان کسب تابع مورد نظر فراهم گردد. LSM یک مدل منطبق بر زیست‌شناسی است؛ بنابراین در نظر گرفتن ساختار اتصالات در مغز می‌تواند به ما کمک کند. ما در اینجا چندین مدل اتصال را بررسی کرده‌ایم، از جمله مدل شعاعی ارائه شده توسط Maas، توپولوژی‌های دنیای کوچک^{۱۹} و یک مدل رشد جهت‌دار آکسون.

(ب) توپولوژی Maas با $\lambda = 1.5$ (آ) توپولوژی Maas با $\lambda = 1$ شکل ۳.۴: اتصالات در توپولوژی Maas: با افزایش λ تعداد و تراکم اتصالات افزایش می یابد

با توجه به ابعاد پایین نورون های ورودی (چهار نورون خروجی در شبکه ی سلسله مراتبی)، تعداد ۲۰۰ نورون برای فیلتر مایع در نظر گرفته شد. با وجود تصادفی بودن ماهیت ماشین های حالت مایع، می توان با در نظر گرفتن مکانیسم های مختلف به شبکه هایی پایدارتر و قابل اعتمادتر رسید. در ادامه دو روش اتصال مختلف بررسی می گردد.

روش اتصال Maas

در شبکه های عصبی، احتمال پیدا کردن یک اتصال بین دو نورون، با افزایش فاصله ی آنها به صورت نمایی کاهش می یابد. یک توضیح محتمل برای این واقعه این است که آکسون ها گرایش رشد در راستای تمرکز بیشتر مولکول های راهنمای آکسون دارند. میزان مولکول های راهنما با افزایش فاصله به صورت نمایی کاهش یافته و در نتیجه نورون های نزدیکتر به منشا مولکول ها، احتمال بیشتری برای اتصال به یکدیگر دارند [۴۸، ۴۹]. در مقاله ای که برای اولین بار توسط Maas عرضه شد [۳۰] اتصالات سیناپسی بر اساس فاصله ی اقلیدسی بین نورون های پیش و پس سیناپسی مشخص می گردد. طبق این روش، احتمال اتصال دو نورون به صورت زیر محاسبه می شود:

$$p = C \cdot \exp\left[-\left(\frac{D(a,b)}{\lambda}\right)^2\right] \quad (۵.۴)$$

که در آن λ پارامتر اتصال و $D(a,b)$ فاصله ی اقلیدسی بین دو نورون a و b است. C بسته به نوع

نورون پیش و پس سیناپسی مشخص می‌شود و ما اینجا مقادیر مشابه مقاله‌ی Maas [۳۰] را استفاده کرده‌ایم که بر مبنای اندازه‌گیری‌ها و مشاهدات سیناپسی روی قشر مغز یافت شده است [۵۰]: C برای اتصال تحریکی به تحریکی (EE) برابر 0.3 ، تحریکی به مهاري (EI) برابر 0.2 ، مهاري به تحریکی (IE) برابر 0.4 و مهاري به مهاري (II) برابر 0.1 قرار می‌گیرد. در این حالت اتصال، شکل فضایی اتصالات کروی و به صورت شعاعی صورت گرفته و از این رو جهت مطرح نیست. شکل ۳.۴ افزایش تراکم اتصالات با افزایش λ را به تصویر می‌کشد. طبق این مدل، اتصالات در یک شعاع مدور از نورون پیش سیناپسی قرار می‌گیرند و ارجحیت به یک جهت خاص وجود ندارد. در اینجا عملکرد این روش اتصال بر مبنای مقادیر مختلف تراکم اتصالات λ و ضریب وزن W_{scale} مورد بررسی قرار گرفته است.

شبکه‌های دنیای کوچک

یک شبکه‌ی دنیای کوچک [۵۱] نوعی گراف است که دو خصوصیت دارد: (۱) گره‌ها (نورون‌ها) نسبت به یک گراف تصادفی بسیار خوشه‌بندی شده‌اند و (۲) بین هر دو گره در شبکه، مسیری با طول کوتاه وجود دارد. نشان داده شده است که بسیاری از شبکه‌های جهان واقعی نه کاملاً نظم و ترتیب داشته و نه صرفاً تصادفی هستند، بلکه خصوصیات دنیای کوچک را از خود نشان می‌دهند. یک شبکه‌ی دنیای کوچک را می‌توان با سیم‌کشی مجدد اتصالات یک شبکه با ساختار مشبک 2^0 به دست آورد. روش‌های سیم‌کشی مجدد مختلفی وجود دارند که خصوصیات دنیای کوچک را از خود نشان می‌دهند.


متوسط طول کوتاه‌ترین مسیر نمایانگر متوسط تعداد یال‌هایی است که باید برای رفتن از یک گره به گره‌ی دیگر پیموده شود (خاصیت سراسری^{۲۱}). همچنین متوسط ضریب خوشه‌گرایی میزان همبندی موجود در شبکه را اندازه‌گیری می‌کند (خاصیت محلی^{۲۲}).

طول کوتاه‌ترین مسیر بین هر دو گره در فیلتر مایع با محاسبه‌ی حداقل تعداد سیناپس‌هایی که باید برای رفتن از یک نورون به نورونی دیگر طی شود بدست می‌آید. متوسط طول کوتاه‌ترین مسیر با

^{۲۰} Lattice

^{۲۱} Global property



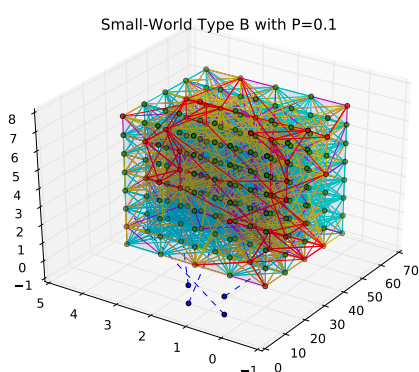
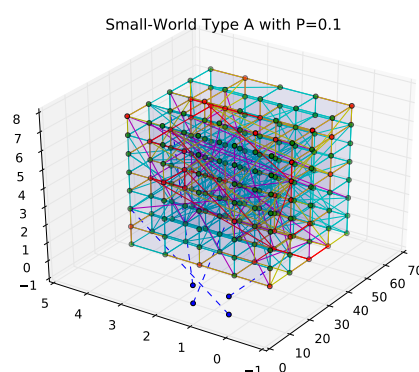
^{۲۲} Local property



شکل ۴.۴: مشبک‌های استفاده شده برای ساخت شبکه‌های دنیای کوچک. در مشبک (A) برای راس میانی ۶ اتصال خروجی و ۶ اتصال ورودی وجود دارد. ضریب خوشه‌گرایی آن صفر است زیرا اتصالاتی بین همسایه‌های گره‌ها وجود ندارد. مشبک (B) برای راس میانی ۲۶ اتصال ورودی و خروجی دارد.

میانگین گرفتن طول کوتاهترین مسیر برای هر زوج نورون در کل شبکه‌ی فیلتر مایع محاسبه می‌گردد. ضریب خوشه‌گرایی برای هر نورون، تعداد اتصالات با همسایه‌هایش (به جز خودش)، تقسیم بر تعداد کل سیناپس‌های ممکن است. متوسط ضریب خوشه‌گرایی با میانگین گرفتن ضرایب خوشه‌گرایی برای همه‌ی نورون‌های شبکه به دست می‌آید.

فیلتر مایع در اینجا شامل ۲۰۰ نورون LIF است که در یک مشبک با ابعاد $5 \times 5 \times 8$ قرار گرفته‌اند. ما دو نوع ساختار اتصال مشبک را بررسی کرده‌ایم (شکل ۴.۴). اتصالات بین نورون‌ها در ابتدا بر اساس یکی از دو مشبک ساخته می‌شوند. پس از ساخت فیلتر مایع مشبک، هر سیناپس با احتمال P به صورت تصادفی به نورونی دیگر سیم‌کشی جایگزین می‌شود؛ با این قید که حلقه و اتصالات موازی (چند اتصال با نورون پیش و پس سیناپسی یکسان) مجاز نمی‌باشد. دقت کنید که عملیات سیم‌کشی مجدد مجموع تعداد سیناپس‌ها در فیلتر مایع را تغییر نمی‌دهد. مشبک (A) تعداد ۹۸۹ سیناپس (۶۳۹ اتصال EE، ۱۵۵ اتصال EI، ۱۵۵ اتصال IE و ۴۰ اتصال II) و مشبک (B) تعداد ۳۴۹۴ سیناپس (۲۲۷۱ اتصال EE، ۵۴۱ اتصال EI، ۵۴۶ اتصال IE و ۱۳۷ اتصال II) برقرار می‌کند (شکل ۵.۴). با افزایش احتمال سیم‌کشی مجدد P ، ارتباطات سیناپسی با برد طولانی‌تر ایجاد شده و متوسط طول کوتاهترین مسیر به شدت کاهش می‌یابد. اگر P برابر یک قرار گیرد، فیلتر مایع به یک شبکه‌ی کاملاً تصادفی تغییر ماهیت می‌دهد. در ادامه عملکرد این مدل را بر حسب مقادیر مختلف احتمال P و ضریب وزنی W_{scale} برای دو مشبک اتصال مذکور مورد بررسی قرار خواهیم داد.

(ب) توپولوژی SW نوع B با $P = 0$ (آ) توپولوژی SW نوع A با $P = 0$ (د) توپولوژی SW نوع B با $P = 0.1$ (ج) توپولوژی SW نوع A با $P = 0.1$

شکل ۵.۴: اتصالات در توپولوژی دنیای کوچک: با افزایش P تعداد کل اتصالات ثابت باقی می ماند اما مشبک از حالت منظم خارج شده و اتصالات کوتاه تصادفی بین نوره ها جایگزین می شود.

۴.۴ نتایج

۱.۴.۴ میزان تفکیک پذیری

پیش از آنکه به بررسی طبقه بندی های مختلف برای لایه ی قرائت پرداخته شود، به ارائه ی معیاری تحت عنوان میزان تفکیک پذیری^{۲۳} می پردازیم. اشکال استفاده از عملکرد لایه ی قرائت برای ارزیابی شبکه این است که می تواند از لحاظ محاسباتی زمان بر باشد. علاوه بر آن استفاده از عملکرد لایه ی قرائت روشی غیر مستقیم برای اندازه گیری عملکرد فیلتر مایع است زیرا به واقع عملکرد لایه ی قرائت، و نه

^{۲۳} Separation measure

فیلتر مایع، را مورد سنجش قرار می‌دهد و از این روی قدرت و ضعف ساز و کار استفاده شده در لایه‌ی قرائت می‌تواند به برداشت نادرستی از توان فیلتر مایع بیانجامد. به همین جهت از خاصیت تفکیک‌پذیری استفاده می‌شود که می‌تواند دید خوبی از توانایی جداسازی الگوهای مختلف توسط شبکه به ما دهد. استفاده از یک معیار مناسب که بتواند با استفاده از میانگین‌ها و پراش‌های داده‌ها قدرت تفکیک‌پذیری شبکه را ترسیم کند بسیار مهم است. عموم کارهای منتشر شده در ارتباط با ماشین حالت مایع از نرخ افتراقی فیشرفر^{۲۴} (FDR) [۵۲] به عنوان معیار میزان تفکیک‌پذیری استفاده می‌کنند [۵۳، ۵۴] که شرح آن در ادامه می‌آید. برای روش FDR، دو ماتریس پراکندگی بین کلاسی و پراکندگی میان‌کلاسی را به ترتیب طبق فرمول‌های ۶.۴ و ۷.۴ محاسبه می‌کنیم.

$$S_b = \sum_{i=1}^M P_i (\mu_i - \mu_o) (\mu_i - \mu_o)^T \quad (۶.۴)$$

$$S_w = \sum_{i=1}^M P_i \Sigma_i \quad (۷.۴)$$

که در آنها $\mu_o = \sum_{i=1}^M P_i \mu_i$ میانگین سراسری برای همه M کلاس (۲ کلاس در اینجا)، P_i احتمال پیشین کلاس ω_i (در اینجا ۰/۵) و μ_i میانگین حالت‌های مایع^{۲۵} متناظر با کلاس ω_i است. همچنین Σ_i ماتریس همبستگی حالت‌های مایع کلاس ω_i است.

سپس ماتریس همبستگی S_m به صورت زیر تشکیل می‌گردد:

$$S_m = S_w + S_b \quad (۸.۴)$$

اثر^{۲۶} ماتریس S_m می‌تواند مجموع پراش^{۲۷} ویژگی‌ها را حول میانگین سراسری حساب کند در حالی که اثر S_w مجموع پراش ویژگی‌ها برای همه‌ی کلاس‌ها می‌باشد. در نتیجه میزان تفکیک‌پذیری بین کلاس‌ها را می‌توان بر حسب کمیت تعریف شده در ۹.۴ بیان کرد:

$$FDR = trace \{ S_w^{-1} S_m \} \quad (۹.۴)$$

^{۲۴} Fisher Discriminant Ratio

^{۲۵} Liquid States

^{۲۶} Trace

^{۲۷} Variance

با این حال در این تحقیق از این معیار استفاده نشده است. بدلیل هم‌خطی^{۲۸} بودن عملکرد برخی از نورون‌ها تحت حالات خاص از شرایطی که اینجا بررسی می‌شود، ماتریس S_w ممکن است تکین^{۲۹} شده و در نتیجه ماتریس وارون‌پذیر^{۳۰} نباشد. برای فائق آمدن بر این حالت می‌توان یک مقدار کوچک و قابل چشم‌پوشی به قطر ماتریس اضافه کرده و یا اینکه از شبه وارون^{۳۱} استفاده نمود. با این حال، با وجود اینکه از این روش‌ها می‌توان برای کاربردهایی مانند استفاده به عنوان برازش ماشین حالت مایع استفاده کرد، اما در اینجا بخاطر اهمیت مرتبه‌ی میزان تفکیک‌پذیری در ترسیم عملکرد شبکه بر حسب پارامترهای مختلف، از نرخ افتراقی فیشر استفاده نشده است.

معیارهای میزان تفکیک دیگری که بعضاً در ادبیات موضوع استفاده شده است اغلب بر حسب توابع فاصله در ریاضیات مانند فاصله‌ی اقلیدسی^{۳۲} [۵۵، ۵۶] یا فاصله‌ی بری-کرتیس^{۳۳} [۵۷] می‌باشند. بر اساس مدل‌های پیشین و یافته‌های مربوط، ما معیار زیر را جهت نمایش میزان تفکیک‌پذیری ارائه کرده‌ایم:

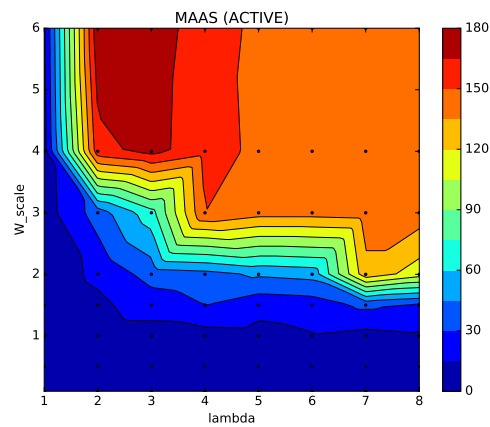
$$D_b = \frac{\sum_{i=1}^M \sum_{j=1}^M \|\mu_i - \mu_j\|_2}{M^2}, \quad (10.4)$$

که D_b بر حسب تفاضل میانگین وضعیت نورون هر کلاس، μ_i ، امکان تمایز بین آنها را می‌سنجد و مشابه آن در برخی از کارها [۵۶] به عنوان معیار میزان تفکیک‌پذیری استفاده شده است. با حال این معیار در بررسی‌های صورت گرفته عملکرد خوبی نداشت و ما را به اضافه کردن فاکتور دیگری که نمایانگر نزدیکی حالات نمونه‌های متناظر با یک کلاس بود سوق داد:

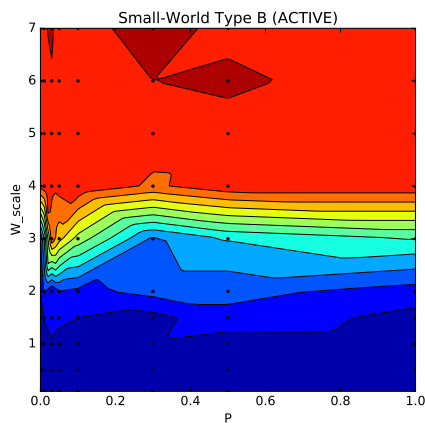
$$D_w = \sum_{i=1}^M \sum_{j=1}^N \delta_{i,j}, \quad (11.4)$$

که در آن D_w با محاسبه‌ی مجموع پراش نمونه‌های هر کلاس در میان خود، قرابت حالات ماشین حالت مایع را در مواجهه با نمونه‌های یکسان و عدم حساسیت آن به تغییرات جزئی و کوچک را نشان


Collinear^{۲۸}Singular^{۲۹}Invertible^{۳۰}Pseudoinverse^{۳۱}Euclidean distance^{۳۲}Bray-Curtis dissimilarity^{۳۳}



Maas مدل (آ)



SW-B مدل (ج)



SW-A مدل (ب)

شکل ۴.۶: تعداد نورون‌های فعال برای مدل اتصال (آ) Maas، (ب) دنیای کوچک نوع A و (ج) دنیای کوچک نوع B

می‌دهد. در نهایت میزان تفکیک‌پذیری به صورت زیر تعریف می‌شود:

$$Separation = \frac{D_b}{D_w + 1} \quad (۱۲.۴)$$

که عدد یک در مخرج برای حالات معدودی هست که ممکن است واریانس بین نمونه‌ها وجود نداشته یا صرفاً یک نمونه از یک کلاس وجود داشته باشد. طبق معیار ارائه شده اگر فاصله‌ی بین‌کلاسی بیش از فاصله‌ی میان‌کلاسی باشد، انتظار می‌رود یک طبقه‌بند خطی به نحو بهتری بتواند بین نمونه‌های ورودی تمایز قائل شود.

۵.۴ نتایج

جهت اینکه صرفاً به ارزیابی توان محاسباتی فیلتر مایع پرداخته باشیم، نوروهای که مستقیماً ورودی را از شبکه‌ی سلسله مراتبی دریافت می‌کنند از ماتریس حالت فیلتر مایع حذف شده‌اند و در نتیجه بردار حالت LSM از ۱۹۶ عنصر (به جای ۲۰۰ عنصر) تشکیل شده است. در این بخش به بررسی عملکرد ماشین حالت مایع برای سه نوع اتصال سیناپسی (مدل Maas و مدل دنیای کوچک A و B) تحت معیار میزان تفکیک‌پذیری و همچنین طبقه‌بندهای خطی می‌پردازیم. برای نتایج گزارش شده، شبکه به ازای هر مجموعه پارامتر، شش بار اجرا شده و میانگین نتایج برآمده از این اجراها به عنوان نتیجه گزارش شده است. در بخش‌های زیادی از شبیه‌سازی (همانند وزن‌های اولیه و اتصالات سیناپسی) از اعداد تصادفی بدست آمده توسط یک تابع مولد اعداد شبه‌تصادفی^{۳۴} استفاده شده است که با تنظیم بذر^{۳۵} روی شش مقدار مختلف، امکان تولید شبکه‌های مختلف به ازای یک پارامتر که امکان بازتولید نیز داشته باشند فراهم شده است.

ضریب وزن سیناپسی W_{scale} مدل Maas به ازای مقادیر ۰/۵، ۱، ۱/۵، ۲، ۳، ۴ و ۶ و پارامتر تراکم اتصالات λ به ازای مقادیر ۱، ۲، ۳، ۴، ۵، ۶، ۷ و ۸ مورد بررسی قرار گرفته است. برای مدل اتصال دنیای کوچک، ضریب وزن به ازای مقادیر ۰/۱، ۰/۵، ۱، ۱/۵، ۲، ۳، ۴، ۵، ۶ و ۷ و همچنین پارامتر احتمال سیم‌کشی مجدد P به ازای مقادیر ۰، ۰/۱، ۰/۳، ۰/۵، ۰/۷، ۱ مورد بررسی قرار گرفته است. شکل‌های ۶.۴، ۷.۴، ۸.۴ و ۹.۴ با درونیابی^{۳۶} نقاط موجود ترسیم شده‌اند.


۱.۵.۴ میزان تفکیک‌پذیری

شکل ۷.۴ عملکرد ماشین‌های حالت مایع را براساس معیاری که پیشتر تحت عنوان میزان تفکیک‌پذیری ارائه شد نمایش می‌دهد. پارامتر W_{scale} میزان انتقال سیگنال درون شبکه را می‌تواند تعیین کند. از جهت زمانی اگر مقدار بزرگی برای آن تعیین گردد، نوروهای بیشتری آتش می‌کنند و اگر مقدار کوچکی برای آن تعیین گردد ممکن است هیچ کدام از نوروها (به جز نوروهای متصل به خروجی شبکه‌ی سلسله مراتبی) آتش نکنند.


^{۳۴} Pseudorandom number generator

^{۳۵} Seed


^{۳۶} Interpolation



مدل (آ) Maas



مدل (ج) SW-B




مدل (ب) SW-A

شکل ۴.۷: معیار میزان تفکیک پذیری برای مدل اتصال (آ) Maas، (ب) دنیای کوچک نوع A و (ج) دنیای کوچک نوع B


اتصالات سیناپسی، کانال‌های ارتباطی بین نورون‌ها هستند. با افزایش تعداد کانال‌های ارتباطی، نورون‌ها مسیرهای بیشتری برای ارتباط با یکدیگر دارند و در نتیجه میانگین طول کوتاهترین مسیر کاهش می‌یابد.

۲.۵.۴ آنالیز افتراقی خطی


شکل ۸.۴ عملکرد ماشین‌های حالت مایع را براساس توانایی تمایز نمونه‌های دو کلاس توسط طبقه‌بند LDA نمایش می‌دهد. آنالیز افتراقی خطی حاصل تعمیم روش افتراق خطی فیشر است که به موجب آن ترکیبی خطی از ویژگی‌ها حاصل می‌شود که قرار است به بهترین نحو نمونه‌های دو کلاس را از یکدیگر جدا کند. همانطور که در تصویر ۸.۴ مشاهده می‌شود، برای برخی پارامترهای خاص مقداری گزارش



Maas مدل (آ)



SW-B مدل (ج)




SW-A مدل (ب)

شکل ۸.۴: عملکرد طبقه‌بند LDA برای مدل اتصال (آ) Maas، (ب) دنیای کوچک نوع A و (ج) دنیای کوچک نوع B


نشده است. این امر از آن جهت است که بخاطر هم‌خطی بودن ستون‌های ویژگی که در شرایط خاصی مانند فقدان فعالیت نورونی (هنگامی که وزن‌های سیناپسی کوچک باشد) بوجود می‌آید، امکان اعمال آنالیز افتراقی خطی وجود ندارد.

۳.۵.۴ ماشین بردار پشتیبان


شکل ۹.۴ عملکرد ماشین‌های حالت مایع را براساس توانایی تمایز نمونه‌های دو کلاس توسط طبقه‌بند ماشین بردار پشتیبان نمایش می‌دهد. مبنای کار طبقه‌بند SVM، تقسیم خطی داده‌ها با پیدا کردن خط، صفحه یا ابرصفحه‌ای است که بتواند حاشیه‌ی اطمینان بیشتری داشته باشد. SVM برخلاف شبکه‌های عصبی کلاسیک همانند MLP در بیشینه‌های محلی گیر نمی‌افتد و برای داده‌های با ابعاد بالا، مانند



Maas مدل (آ)



SW-B مدل (ج)



SW-A مدل (ب)

شکل ۹.۴: عملکرد طبقه‌بند SVM برای مدل اتصال (آ) Maas، (ب) دنیای کوچک نوع A و (ج) دنیای کوچک نوع B

آنچه در اینجا داریم، گزینه‌ی بسیار مناسبی است.

نواحی به رنگ قرمز در شکل‌های ۷.۴، ۸.۴ و ۹.۴ نواحی رضایت‌بخش‌تری هستند. در شکل ۶.۴ تعداد نورون‌های فعال تحت پارامترهای مختلف نمایش یافته است. نورونی که در کل طول فرآیند حداقل یک بار آتش کرده باشد را نورون «فعال» می‌خوانیم. مشاهده می‌شود که تفکیک‌پذیری یا عملکرد طبقه‌بندی قابل قبول زمانی بدست آمده است که نه خیلی از نورون‌ها فعال بوده و نه تعداد خیلی کمی از آنها فعال شده‌اند. به عبارت دیگر، تعداد خیلی کم یا خیلی زیاد نورون‌های انبار (فیلتر مایع) منجر به عملکرد خوبی نمی‌شود و برای عملکرد قابل قبول، می‌بایست تعداد بینایی از نورون‌ها فعال شوند. شکل‌های ۷.۴ ب و ۷.۴ ج همانطور که انتظار می‌رود نشان می‌دهند که چون در مدل دنیای کوچک مجموع تعداد سیناپس‌ها ثابت می‌ماند، تعداد نورون‌های فعال مشخصاً توسط W_{scale}

جدول ۴.۴: بهترین عملکرد مدل‌های اتصال

مدل اتصال	معیار تفکیک‌پذیری	LDA	SVM
Maas	۱/۳۴	۹۲/۵	۹۱/۸
SW-A	۱/۴۱	۹۲/۶	۹۲
SW-B	۱/۳۶	۹۲/۴	۹۱/۶

تعیین شده و احتمال سیم‌کشی مجدد P تنها زمانی خود را نشان می‌دهد که ضریب وزن بسیار بزرگ انتخاب شده باشد.

جدول ۴.۴ بهترین عملکرد هر مدل اتصال را به ازای همه‌ی مقادیر پارامترهای بررسی شده نشان می‌دهد. همانگونه که مشاهده می‌شود، مدل دنیای کوچک نوع A بهترین عملکرد را هم با طبقه‌بند LDA و هم با طبقه‌بند SVM داشته است. مورد قابل توجه دیگر این است که ترتیب عملکرد خوب این مدل‌ها از پیش توسط معیار تفکیک‌پذیری قابل پیش‌بینی بوده است. هر چند که ماشین‌های حالت مایع بررسی شده، به ازای بهترین پارامترهایشان نتایج به نسبت مشابه با تفاوت قابل اغماض را نتیجه داده‌اند، اما دلیل اصلی انتخاب مدل اتصال دنیای کوچک نوع A این است که به ازای گستره‌ی وسیع‌تری از پارامترها عملکرد قابل قبول نشان می‌دهد و از این جهت قابل اطمینان‌تر می‌باشد.

۴.۵.۴ نتیجه‌گیری

با وجود اینکه بخاطر ساختار غیرخطی و بازگشتی ماشین حالت مایع، تحلیل ریاضیاتی آن بسیار دشوار یا ناممکن است با این حال این امری شناخته شده است که ساختار و به خصوص تعداد سیناپس‌های فیلتر مایع تاثیر بسیاری زیادی بر عملکرد آن دارد و می‌توان با بهره‌وری از یکسری قواعد تجربی به طراحی بهتری از ماشین حالت مایع دست پیدا کرد. در آزمایش‌های صورت گرفته، روش‌های مختلف برقراری اتصال سیناپسی مورد بررسی صورت گرفت و هم از منظر توپولوژی و هم از نظر وزن‌های سیناپسی، مدل‌های اتصال سیناپسی با تراکم و توزیع اتصالات مختلف بررسی شد. ماشین‌های حالت مایع اخیر توجه کاربردهای مهندسی را نیز به خود جلب کرده‌اند و ماشین حالت مایع ارائه شده همراه با روش نمایش حالت مایع معرفی شده که بر اساس سازوکار شبکه‌ی سلسله مراتبی، با جلوگیری از افزایش ابعاد مسئله زمانبندی دنباله‌ی ضربه را نیز در نظر می‌گیرد، بر این گرایش صحه می‌گذارد.

فصل ۵

نتیجه‌گیری و پیشنهاد کارهای آینده

ماشین‌های حالت مایع تلاش بر ارائه‌ی مدلی برای شبیه‌سازی ریزدارات قشری مغز دارند که توانایی طبقه‌بندی سیگنال‌های محرک پیچیده‌ی فضایی‌زمانی را با دقت قابل قبول داشته باشد. علاوه بر عناوینی که به آن پرداخته شد، موارد بسیاری در این حوزه وجود دارد که بعضاً با وجود آنکه تا حدی به آنها در ادبیات موضوع پرداخته شده است، اما هنوز برداشت صحیح و کاملی وجود ندارد:

- از ایده‌هایی که می‌توان برای بهبود عملکرد ماشین حالت مایع استفاده کرد، استفاده از چند فیلتر مایع به طور موازی است که هر کدام نمایش مختلفی از محرک ورودی را نتیجه بدهند. همچنین می‌توان به طور موازی چند لایه‌ی قرائت تعریف کرد که هر کدام تنها از بخشی از حالت مایع سراسری را در بر گرفته و به عبارتی هر کدام صرفاً به بخشی از فضای مسئله دسترسی داشته باشند. این حوزه شباهت بسیاری به ایده‌ی ترکیب خبره‌ها داشته و امکان بهره بردن از ایده‌های این حوزه برای بهبود عملکرد ماشین حالت مایع وجود دارد.
- الگوهای اتصال بسیار بیشتری وجود دارد که می‌توان عملکرد آنها را تحت چارچوب ماشین‌های حالت مایع بررسی کرد. یک مرجع مناسب، مدل‌های معرفی شده در [۵۸] توسط Kaiser است که به بررسی مدل‌های گوناگون، از جمله دنیای کوچک و مستقل از مقیاس^۱، پرداخته است.
- معمولاً یادگیری توسط سیناپس‌های داخل ماشین حالت مایع صورت نمی‌پذیرد؛ هر چند که مدل‌هایی ارائه شده است که از تکنیک STDP به این منظور استفاده کرده‌اند اما عموماً با توجه

^۱ Scale-free

به پیچیدگی محاسباتی تحمیل شده، بهبود قابل توجهی حاصل نشده است. روش دیگری که می‌توان به کار گرفت پازش^۲ شبکه در طول زمان با حذف و اضافی اتصالات نورونی است که کار قابل توجهی هنوز در این زمینه صورت نگرفته است.

- تا جایی که نویسنده مطلع است کاری در زمینه‌ی طبقه‌بندی سیگنال ویدئویی توسط ماشین‌های حالت مایع صورت نگرفته است. با این حال ماشین حالت مایع بدلیل اینکه از زیرساخت عصبی ضربه‌ای تشکیل شده است، توانایی خوبی در انتقال محرک بر اساس زمان وقوع آن داشته و با وجود اینکه در اینجا نیز هر تصویر توسط یک سیگنال فضایی مکانی نمایش داده شده است، LSM برای کاربردهای مرتبط با حرکت^۳ می‌تواند پتانسیل بسیاری داشته باشد.
- در اینجا بدلیل محدودیت‌های محاسباتی از مدل نورونی تجمیع و آتش نشستی استفاده شد. مدل‌های نورونی بسیار متنوعی با سطوح مختلف انطباق زیستی وجود دارد که می‌توان عملکرد آنها را بررسی و در نتیجه مدل را به واقعیت زیستی نزدیک‌تر ساخت. نویسنده در ابتدا قصد داشت تا سازوکار ماشین حالت مایع را بر اساس مدل‌های نورونی دقیق‌تری همانند مدل نورونی Izhikevich پیاده‌سازی کند که با توجه به نتایج نامناسب از ادامه‌ی کار صرف نظر شد. در [۵۵] مطالعه‌ی مختصری روی مدل‌های نورونی مختلف به عنوان بلوک‌های سازنده‌ی LSM صورت گرفته است. مشکل مشهود برای مدل نورونی Izhikevich موج‌های دوره‌ای خودبه‌خودی است که در فازهای مختلف اجرا از خود نشان می‌دهد و باعث کم اثر شدن محرک در حالت فیلتر مایع می‌گردد. با این حال پدیده‌ی Polychronization [۵۹] انگیزش زیادی برای تحقیق در این حوزه ایجاد می‌کند.

کتابنامه

- [1] Hebb, Donald Olding. *The organization of behavior: A neuropsychological approach*. John Wiley & Sons, 1949.
- [2] Bliss, Tim VP and Gardner-Medwin, AR. Long-lasting potentiation of synaptic transmission in the dentate area of the unanaesthetized rabbit following stimulation of the perforant path. *The Journal of physiology*, 232(2):357, 1973.
- [3] Levy, WB and Steward, O. Temporal contiguity requirements for long-term associative potentiation/depression in the hippocampus. *Neuroscience*, 8(4):791–797, 1983.
- [4] Markram, Henry, Lübke, Joachim, Frotscher, Michael, and Sakmann, Bert. Regulation of synaptic efficacy by coincidence of postsynaptic apss and epsps. *Science*, 275(5297):213–215, 1997.
- [5] Bell, Curtis C, Han, Victor Z, Sugawara, Yoshiko, and Grant, Kirsty. Synaptic plasticity in a cerebellum-like structure depends on temporal order. *Nature*, 387(6630):278–281, 1997.
- [6] Webvision—the organization of the vertebrate retina. electronic publication. 2000.
- [7] Coren, Stanley, Ward Lawrence and James, Emms. Sensation and perception, 1994.
- [8] Kandel, Eric R, Schwartz, James H, Jessell, Thomas M, Siegelbaum, Steven A, and Hudspeth, AJ. *Principles of neural science*, vol. 4. McGraw-hill New York, 2000.
- [9] Hartline, H Keffer. The response of single optic nerve fibers of the vertebrate eye to illumination of the retina. *American Journal of Physiology–Legacy Content*, 121(2):400–415, 1938.
- [10] Hubel, David H and Wiesel, Torsten N. Receptive fields, binocular interaction and functional architecture in the cat’s visual cortex. *The Journal of Physiology*, 160(1):106–154, 1962.
- [11] Hubel, David H and Wiesel, Torsten N. Receptive fields and functional architecture of monkey striate cortex. *The Journal of physiology*, 195(1):215–243, 1968.
- [12] Hubel, David H and Wiesel, Torsten N. Anatomical demonstration of columns in the monkey striate cortex. *Nature*, 221(5182):747–750, 1969.
- [13] Goebel, Rainer, Muckli, Lars, and Kim, DS. Visual system. *The Human Nervous System Elsevier, San Diego*, pp. 1280–1305, 2004.
- [14] Hubel, David H and Wiesel, Torsten N. Ferrier lecture: Functional architecture of macaque monkey visual cortex. *Proceedings of the Royal Society of London B: Biological*

Sciences, 198(1130):1–59, 1977.

- [15] Zeki, Semir. *A Vision of the Brain*. Oxford Univ Press, 1993.
- [16] Rosenblatt, Frank. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review*, 65(6):386, 1958.
- [17] Ghosh-Dastidar, Samanwoy and Adeli, Hojjat. Spiking neural networks. *International journal of neural systems*, 19(04):295–308, 2009.
- [18] Bi, Guo-qiang and Poo, Mu-ming. Synaptic modifications in cultured hippocampal neurons: dependence on spike timing, synaptic strength, and postsynaptic cell type. *The Journal of neuroscience*, 18(24):10464–10472, 1998.
- [19] Zhang, Li I, Tao, Huizhong W, Holt, Christine E, Harris, William A, and Poo, Mu-ming. A critical window for cooperation and competition among developing retino-tectal synapses. *Nature*, 395(6697):37–44, 1998.
- [20] Song, Sen, Miller, Kenneth D, and Abbott, Larry F. Competitive hebbian learning through spike-timing-dependent synaptic plasticity. *Nature neuroscience*, 3(9):919–926, sep 2000.
- [21] Hung, Chou P, Kreiman, Gabriel, Poggio, Tomaso, and DiCarlo, James J. Fast readout of object identity from macaque inferior temporal cortex. *Science*, 310(5749):863–866, 2005.
- [22] Masquelier, Timothée and Thorpe, Simon J. Unsupervised learning of visual features through spike timing dependent plasticity. *PLoS Comput Biol*, 3(2):e31, 2007.
- [23] Rullen, Rufin Van and Thorpe, Simon J. Rate coding versus temporal order coding: What the retinal ganglion cells tell the visual cortex. *Neural Computation*, 13(6):1255–1283, jun 2001.
- [24] Guyonneau, Rudy, VanRullen, Rufin, and Thorpe, Simon J. Neurons tune to the earliest spikes through stdp. *Neural Computation*, 17(4):859–879, 2005.
- [25] Serre, Thomas, Wolf, Lior, and Poggio, Tomaso. Object recognition with features inspired by visual cortex. in *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)*, vol. 2, pp. 994–1000. IEEE, 2005.
- [26] Riesenhuber, Maximilian and Poggio, Tomaso. Hierarchical models of object recognition in cortex. *Nature neuroscience*, 2(11):1019–1025, 1999.
- [27] Albrecht, Duane G, Geisler, Wilson S, Frazor, Robert A, and Crane, Alison M. Visual cortex neurons of monkeys and cats: Temporal dynamics of the contrast response function. *Journal of Neurophysiology*, 88(2):888–913, 2002.
- [28] Celebrini, Simona, Thorpe, Simon, Trotter, Yves, and Imbert, Michel. Dynamics of orientation coding in area v1 of the awake primate. *Visual neuroscience*, 10(05):811–825, sep 1993.
- [29] Buonomano, Dean V and Maass, Wolfgang. State-dependent computations: spatiotemporal processing in cortical networks. *Nature Reviews Neuroscience*, 10(2):113–125, 2009.

- [30] Maass, Wolfgang, Natschläger, Thomas, and Markram, Henry. Real-time computing without stable states: A new framework for neural computation based on perturbations. *Neural computation*, 14(11):2531–2560, 2002.
- [31] Jaeger, Herbert. The “echo state” approach to analysing and training recurrent neural networks-with an erratum note. *Bonn, Germany: German National Research Center for Information Technology GMD Technical Report*, 148:34, 2001.
- [32] Eliasmith, Chris, Stewart, Terrence C, Choo, Xuan, Bekolay, Trevor, DeWolf, Travis, Tang, Yichuan, and Rasmussen, Daniel. A large-scale model of the functioning brain. *science*, 338(6111):1202–1205, 2012.
- [33] Markram, Henry. The blue brain project. *Nature Reviews Neuroscience*, 7(2):153–160, 2006.
- [34] Yamazaki, Tadashi and Tanaka, Shigeru. The cerebellum as a liquid state machine. *Neural Networks*, 20(3):290–297, 2007.
- [35] Baker, John L. Is there a support vector machine hiding in the dentate gyrus? *Neurocomputing*, 52:199–207, 2003.
- [36] Bakker, Arnold, Kirwan, C Brock, Miller, Michael, and Stark, Craig EL. Pattern separation in the human hippocampal ca3 and dentate gyrus. *Science*, 319(5870):1640–1642, 2008.
- [37] Schrauwen, Benjamin, D’Haene, Michiel, Verstraeten, David, and Van Campenhout, Jan. Compact hardware liquid state machines on fpga for real-time speech recognition. *Neural Networks*, 21(2):511–523, 2008.
- [38] Verstraeten, David, Schrauwen, Benjamin, Stroobandt, Dirk, and Van Campenhout, Jan. Isolated word recognition with the liquid state machine: a case study. *Information Processing Letters*, 95(6):521–528, 2005.
- [39] Joshi, Prashant and Maass, Wolfgang. Movement generation and control with generic neural microcircuits. in *International Workshop on Biologically Inspired Approaches to Advanced Information Technology*, pp. 258–273. Springer, 2004.
- [40] Biederman, Irving. Recognition-by-components: a theory of human image understanding. *Psychological review*, 94(2):115, 1987.
- [41] DiCarlo, James J, Zoccolan, Davide, and Rust, Nicole C. How does the brain solve visual object recognition? *Neuron*, 73(3):415–434, 2012.
- [42] Fukushima, Kunihiko. Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position. *Biological cybernetics*, 36(4):193–202, 1980.
- [43] Vitay, Julien, Dinkelbach, Helge Ü, and Hamker, Fred H. Annarchy: a code generation approach to neural simulations on parallel hardware. *Frontiers in neuroinformatics*, 9, 2015.
- [44] Goodman, Dan FM and Brette, Romain. The brian simulator. *Frontiers in neuroscience*, 3:26, 2009.

- [45] Eliasmith, Chris and Anderson, Charles H. *Neural engineering: Computation, representation, and dynamics in neurobiological systems*. MIT press, 2004.
- [46] Joshi, Prashant. From memory-based decisions to decision-based movements: A model of interval discrimination followed by action selection. *Neural networks*, 20(3):298–311, 2007.
- [47] Legenstein, Robert and Maass, Wolfgang. Edge of chaos and prediction of computational performance for neural circuit models. *Neural Networks*, 20(3):323–334, 2007.
- [48] Yamamoto, Nobuhiko, Tamada, Atsushi, and Murakami, Fujio. Wiring of the brain by a range of guidance cues. *Progress in neurobiology*, 68(6):393–407, 2002.
- [49] Kaiser, Marcus, Hilgetag, Claus C, and Van Ooyen, Arjen. A simple rule for axon outgrowth and synaptic competition generates realistic connection lengths and filling fractions. *Cerebral Cortex*, 19(12):3001–3010, 2009.
- [50] Gupta, Anirudh, Wang, Yun, and Markram, Henry. Organizing principles for a diversity of gabaergic interneurons and synapses in the neocortex. *Science*, 287(5451):273–278, 2000.
- [51] Watts, Duncan J and Strogatz, Steven H. Collective dynamics of ‘small-world’ networks. *nature*, 393(6684):440–442, 1998.
- [52] Fisher, Ronald A. The use of multiple measurements in taxonomic problems. *Annals of eugenics*, 7(2):179–188, 1936.
- [53] Hourdakos, Emmanouil and Trahanias, Panos. Improving the classification performance of liquid state machines based on the separation property. in *Engineering Applications of Neural Networks*, pp. 52–62. Springer, 2011.
- [54] Ju, Han, Xu, Jian-Xin, Chong, Edmund, and VanDongen, Antonius MJ. Effects of synaptic connectivity on liquid state machine performance. *Neural Networks*, 38:39–51, 2013.
- [55] Grzyb, Beata J, Chinellato, Eris, Wojcik, Grzegorz M, and Kaminski, Wieslaw A. Which model to use for the liquid state machine? in *2009 International Joint Conference on Neural Networks*, pp. 1018–1024. IEEE, 2009.
- [56] Norton, David and Ventura, Dan A. Preparing more effective liquid state machines using hebbian learning. 2006.
- [57] Wojcik, Grzegorz M and Wazny, Marcin. Bray-curtis metrics as measure of liquid state machine separation ability in function of connections density. *Procedia Computer Science*, 51:2979–2983, 2015.
- [58] Kaiser, Marcus. A tutorial in connectome analysis: topological and spatial features of brain networks. *Neuroimage*, 57(3):892–907, 2011.
- [59] Izhikevich, Eugene M. Polychronization: computation with spikes. *Neural computation*, 18(2):245–282, 2006.

واژه‌نامه فارسی به انگلیسی

آ

Axon	آکسون
Amygdala	آمیگدال
Linear Discriminant Analysis	آنالیز افتراقی خطی
Hypercolumns	آبرستون
Rectifying Junctions	اتصالات یکسوساز
Weight sharing	اشتراک وزنی
Oligodendrocyte	اولیگودندرگلیا

ب

Excitation	برانگیختن
Excitable	برانگیختنی
Excitatory	برانگیزنده
Real-time	بلادرنگ
Computer Vision	بینایی ماشین

پ

Action Potentials	پتانسیل‌های عمل
Perceptron	پرسترون
Evolutionary Process	پروسه‌ی فرگشت
Perikaryon	پریکاریون

Neurotransmitter پیام رسان عصبی

Feed-forward پیش خور

ت

Obscured تار شده

Thalamus تالاموس

Intensity-latency conversion تبدیل شدت-تاخیر

Fourier Transformation تبدیل فوریه

Integrate & Fire تجميع و آتش

Leaky Integrate & Fire تجميع و آتش نشتی

Recognition-by-components تشخیص با مولفه ها

Formation of receptive fields تشکیل میدان های تاثیر

Stochastic تصادفی

Randomness تصادفی بودن

Long-term depression تضعیف بلند مدت

Long-term potentiation تقویت بلند مدت

Neural Trajectories تکامل خط سیر های عصبی

Unipolar تک قطبی

Cell Differentiation تمایز سلولی

Universal Computational Power توان محاسباتی جهان شمول

Selective attention توجه گزینشی

Structural descriptions توصیف ساختاری

ج

Soma جسم یاخته ای

Small-world جهان کوچک

چ

Optic chiasm چلیپای نوری

Multipolar چندقطبی

ح

Fading Memory حافظه‌ی محو شونده

Blob حباب

خ

Global property خاصیت سراسری

Local property خاصیت محلی

What pathway خط‌سیر چیستی

Where pathway خط‌سیر کجایی

Manifold خمینه

د

Dendrite دارینه

Ligand-gated درگاه شیمیایی

in vivo درون‌جاندازی

in silico درون‌رایانه‌ای

in vitro درون‌کشتگاهی

Introspection درون‌نگری

Peripheral Nervous System دستگاه اعصاب پیرامون

Central Nervous System دستگاه اعصاب مرکزی

Nervous System دستگاه عصبی

Golgi Apparatus دستگاه گلژی

Spike train دنباله ضربه

Bipolar دوقطبی

Photopic دید در روز

دید در شب Scotopic

د

رتینوتوپیک Retinotopic

رد عصبی Engram

رشد میزان سازی جهت Development of orientation tuning

روان فیزیک Psychophysics

روان فیزیکی Psychophysical

ریزمدار قشری Cortical Microcircuit

ز

زمان متغیر Time-varying

زمانی Temporal

زمانی فضایی Spatiotemporal

زیرمیدان Subfields

س

ساختار متضاد مرکز- اطراف Antagonistic center-surround organization

سلول استوانه ای Rod cell

سلول مخروطی Cone cell

سلول های آماکرین Amacrine cells

سلول های اپیتلیوم رنگدانه دار Pigment epithelial cells

سلول های افقی Horizontal cells

سلول های دوقطبی Bipolar cells

سلول های شوآن Schwann Cells

سلول های فوق پیچیده Hypercomplex cells

سلول های گانگلیون Ganglion cells

سلول های مکان Place cells

Cytoplasm سیتوپلاسم

Synapse سیناپس

ش

Nyctalopia شب‌کوری

Recurrent Neural Networks شبکه‌های عصبی بازگشتی

Spiking Neural Networks شبکه‌های عصبی ضربه‌ای

Endoplasmic Reticulum شبکه‌ی آندوپلاسمی

Echo State Network شبکه‌ی انعکاس حالت

Hierarchical convolutional network شبکه‌ی پیچشی سلسله مراتبی

Retina شبکیه

Plasticity شکل‌پذیری

Neuroplasticity شکل‌پذیری عصبی

Short-term Plasticity شکل‌پذیری کوتاه مدت

ص

Flattening صاف شدن

ض

Spike ضربه

ط

Reverberation طنین

ظ

Petri dishes ظروف پتری

ع

Lens عدسی

Optic nerve عصب باصره

ف

Point process..... فرآیند نقطه‌ای

Evolution..... فرگشت

Time Spatialization فضاسازی زمان

Spatial فضایی

ق

Cornea..... قرنیه

Primary visual cortex قشر بینایی اولیه

Extrastriate cortex..... قشر فرامخطط

Cerebral cortex قشر مغز

ک

Caenorhabditis elegans کرم الگانس

Synaptic Vesicles..... کیسه‌های سیناپسی

گ

Nodes of Ranvier گره‌های رانویه

Orientation selective گزینش‌پذیر نسبت به جهت

Direction selectivity گزینندگی مسیر

Selective گزیننده

Fovea گودی مرکزی

Photoreceptors..... گیرنده‌های نوری

ل

Readout Layer..... لایه‌ی قرائت

Macula..... لکه‌ی زرد

Parietal lobe..... لوب آهیانه‌ای

Occipital lobe لوب پس‌سری

Frontal lobe لوب پیشانی

Temporal lobe لوب گیج‌گاهی

Lysosome لیزوزوم

م

Support Vector Machine ماشین بردار پشتیبان

Liquid State Machine ماشین حالت مایع

Vitreous body مایع زجاجیه

Reservoir Computing محاسبات انبارهای

State-Dependent Computation محاسبات وابسته به وضعیت

Axis of orientation محور جهت

Logic circuit مدار منطق

Field-Programmable Gate Array مدارات مجتمع دیجیتال برنامه‌پذیر

Refractory period مدت انکسار

Computational Modeling مدل‌سازی محاسباتی

Circularity مدور بودن

Attentional modulation مدولاسیون توجهی

Rank مرتبه

Occluded مسدود شده

Dorsal stream مسیر پشتی

Ventral stream مسیر شکمی

Lattice مشبک

Gratings مشبک میله‌ای

Inhibition مهار کردن

Mitochondria میتوکندری

Receptive field میدان تاثیر

Bar میله

میلین Myelin

ن

ناوردا Invariant

ناوردایی Invariance

نئوریت Neurite

نئوقشر Neocortex

نسبت اندازه Aspect ratio

نشتی Leakage

نظریه‌ی هب Hebbian theory

نقطه تعادل Equilibrium Point

نقطه‌ی کور Blind spot

نواحی برادمن Brodmann areas

نوروپلاسم Neuroplasm

نورون Neuron

نورون‌های بینابینی Interneurons

و

وادارنده Inhibitory

ه

هسته Nucleus

هسته‌ی پشتی حلزونی Dorsal cochlear nucleus

هسته‌ی زانویی جانبی Lateral geniculate nucleus

همزمان‌سازی Synchronization

همگشت Convolution

هیپوکمپوس Hippocampus

ی

Learning	یادگیری
Spike-timing dependent plasticity	یادگیری وابسته به زمان ضربه

پیوست آ

پیاده‌سازی

در این پیوست به توضیح کدهای پیاده‌سازی شده برای شبیه‌سازی‌های صورت گرفته می‌پردازیم.

۱. آ استخراج ویژگی‌های بصری با STDP

با توجه به محاسبات بسیار زیاد صورت گرفته در این قسمت از کد، تصمیم بر پیاده‌سازی آن به زبان C++ گرفته شد که به موجب آن زمان شبیه‌سازی چند ده برابر از پیاده‌سازی پایتون که پیشتر انجام شده بود سرعت بیشتری پیدا کرد. برای نوشتن این کد از کتابخانه‌ها و ابزارهای ذیل استفاده شده است:

• **Eigen^۱**: برای ذخیره‌ی بردارها و ماتریس‌های وزن‌ها، پتانسیل‌های نرونی و محرک‌های

ورودی به صورت بهینه و همچنین بهره‌وری از مجموعه دستورات SSE^۲.

• **LodePNG^۳**: جهت بارگذاری تصاویر PNG که محرک‌های ورودی را تشکیل می‌دهند.

• **cereal^۴**: برای سریال کردن^۵ ساختمان‌های داده‌ی C++ و ذخیره و بازیابی وزن‌های شبکه و

تصاویری که فیلتر گابور روی آنها اعمال شده است.

^۱<http://eigen.tuxfamily.org/>

^۲Streaming SIMD Extensions

^۳<http://lodev.org/lodepng/>

^۴<http://uscilab.github.io/cereal/>

^۵Serialization

۱.۱.آ کلاس Gabor

ویژگی‌ها:

```
std::vector<float> Scales;
std::vector<float> Orientations;
int RFSIZE;
float Div;
std::vector<Eigen::MatrixXf, Eigen::aligned_allocator<Eigen::
    ↳ MatrixXf>> gaborFilters;
```

متدها:

```
Gabor::Gabor(std::vector<float> scales, std::vector<float>
    ↳ orientations, int rfSize, float div)
```

سازنده‌ی کلاس می‌باشد که با استفاده از مقادیر پارامترها، ویژگی‌های کلاس را مقداردهی اولیه کرده و با فراخوانی `Gabor::GenerateGaborFilters()` فیلترهای گابور خواسته شده را ایجاد می‌نماید.

```
void Gabor::GenerateGaborFilters()
```

یک متد private که توسط constructor کلاس فراخوانی شده و برای زوایای Orientation ماتریس‌های $RFSIZE \times RFSIZE$ تولید کرده و `gaborFilters` را پر می‌کند.

```
SpikeVec4D Gabor::GetGaboredTimes(std::string imageAddress)
```

این متد توسط کلاس `GaborLayer` فراخوانی می‌شود. این متد آدرس تصویر را گرفته، توسط متد `ReadImageGrayScale` از `Utility`، آن را `load` و `scale` می‌کند. سپس عناصر `gaboredImages` را پر می‌کند که یک بردار از یک ماتریس دوبعدی است. اندیس اول و دوم به ترتیب `scale` و `orientation` است. عناصر آن با ضرب کردن فیلتر `gabor` در همسایگی آن عنصر در تصویر بارگذاری شده و تقسیم بر تصویر نرمال شده بدست می‌آید.

خروجی این تابع برای تصویر مذکور، `spike4D` (از نوع ۴ بردار nested) است که اندیس اول شماره‌ی `scale`، اندیس دوم شماره‌ی `orientation` و دو اندیس بعدی موقعیت تصویر است. اگر مقدار پیکسل متناظر در `gaboredImages` بزرگتر از ۰/۰۱ باشد، در آن المان از `spike4D` یک نمونه از کلاس `SpikeData` قرار می‌گیرد که `time` آن معکوس مقدار پیکسل است. بنابراین هر چه پیکسل روشن‌تر

زمان اسپایک زودتر (حداقل ۱ میلی‌ثانیه) و هر چه تصویر تیره‌تر زمان اسپایک دیرتر (حداکثر ۱۰۰ میلی‌ثانیه) خواهد بود.

آ.۲.۱ کلاس **GaborLayer**

ویژگی‌ها:

```
int ImageIdx;
std::vector<std::string> FileNames;
int NumberOfScales;
SpikeVec2D OrderedData;
SpikeVec5D SpikeData2D;
std::shared_ptr<Gabor> gabor;
Eigen::VectorXd inhibitionPercents;
```

متدها:

```
GaborLayer::GaborLayer(std::string folderAddress, std::vector<float>
    ↪ scales, std::vector<float> orientations, int rfSize, int div
    ↪ , int cRF, int C1InhibRFsize, float C1InhibPercentClose,
    ↪ float C1InhibPercentFar)
```

```
SpikeVec1D GaborLayer::GetGaboredTimes(std::string imageAddress,
    ↪ SpikeVec4D& spike4D0riPooled, int complexField)
```

```
SpikeVec4D GaborLayer::GetPooledInhibitedTimes(int complexField,
    ↪ const SpikeVec4D& spike4D)
```

آ.۳.۱ کلاس **Kernel**

ویژگی‌ها:

```
public:
    std::string Name;
    int NumberOfFeature;
    std::vector<std::vector<Eigen::MatrixXf>> Weights;
    int CRF;
    int SRF;
    int centerRow;
    int centerCol;
    int CStride;
    float Threshold;
```

```

std::vector<float> InhibitionsPercent;
int KWTa;
float Ap;
float An;

private:
    int sOffset;
    int cOffset;
    int iOffset;

```

متدها:

```

Kernel::Kernel(std::string name, int numberOfFeatures, int
    ↪ numberOfPreKernelFeatures, int srf, int crf, int cStride, std
    ↪ ::vector<float> inhibitionsPercent, float threshold, int kwtA
    ↪ , float ap, float an, float meanWeight, float stdDevWeight)

```

سازنده‌ی کلاس که بعد از مقدار دهی ها property با پارامترهای دریافتی، مارتیس وزن برای نورون‌های کرنل را ایجاد و با یک توزیع تصادفی نرمال مقداردهی اولیه می‌کند. در واقع باید به ازای هر map (هر scale) یک نورون و یک وزن داشته باشیم ولی چون از weight sharing استفاده می‌کنند تنها یک مارتیس وزن (از اندازه‌ی $\text{SRF} \times \text{SRF}$) به ازای هر نورون ذخیره می‌کنیم.

```

void Kernel::TrainKernel(SpikeVec1D& spikes, SpikeVec4D& spikes4D)

```

```

SpikeVec1D Kernel::TestKernel(SpikeVec1D& spikes, SpikeVec4D&
    ↪ spikes4DIn, SpikeVec4D& spikes4DPooledOut, bool applyPooling)

```

```

SpikeVec4D Kernel::GetPooledInhibitedTimes(const SpikeVec4D&
    ↪ spikes4D)

```

```

inline void Kernel::increaseWeight(int f, int r, int c, int pref)

```

```

inline void Kernel::decreaseWeight(int f, int r, int c, int pref)

```

دو متد بالا به ترتیب افزایش و کاهش وزن در یک مختصات خاص را انجام می‌دهند.

```

void Kernel::ApplySTDP(int f, int r, int c, SpikeVec3D& spikes3D,
    ↪ std::shared_ptr<SpikeData> currentSpike)

```

تابع STDP را محاسبه کرده و بر حسب آن وز سیناپس را کاهش یا افزایش می‌دهد.

آ.۴.۱ کلاس Network

```
public:
    std::vector<Kernel> Kernels;
    std::vector<float> Scales;
    std::vector<float> Orientations;
    int GaborRFSIZE;
    float GaborDiv;
    int GaborCRF;
    int C1InhibRFSIZE;
    float C1InhibPercentClose;
    float C1InhibPercentFar;
    std::shared_ptr<GaborLayer> gaborLayer;
private:
    SpikeVec2D OrderedSpikes;
    SpikeVec5D Spikes5D;
```

```
Network::Network(std::vector<float> scales, std::vector<float>
    → orientations, int gaborRFSIZE, float gaborDiv, int gaborCRF,
    → int c1InhibRFSIZE, float c1InhibPercentClose, float
    → c1InhibPercentFar)
```

سازنده‌ی کلاس Network است که لیستی از scales (مقیاس‌های تصویر)، orientations (جهت‌ها) و مقادیر gaborRFSIZE (اندازه‌ی میدان تاثیر گابور و اندازه و میزان منکوب جانبی را تعیین می‌کند).

```
std::shared_ptr<GaborLayer> Network::ApplyGabor(std::string
    → imageFolder, std::vector<float> scales, std::vector<float>
    → orientations, int rfSize, float div, int cRF)
```

فیلتر گابور را با پارامترهای قید شده روی تصاویر قرار گرفته در پوشه‌ی imageFolder اعمال می‌کند.

```
std::vector<std::vector<std::vector<float>>> Network::
    → TestNetworkSpikeTiming(std::string imageFolder)
```

این متد آدرس یک پوشه را گرفته و با اعمال فیلترها و لایه‌های مختلف، زمان ضربه‌های خروجی را برمی‌گرداند.

```
Eigen::MatrixXi Network::TestNetwork(std::string imageFolder)
```

این متد آدرس یک پوشه را گرفته و با اعمال فیلترها و لایه‌های مختلف، شمار ضربه‌های خروجی را برمی‌گرداند.

```
void Network::TrainNewKernel(std::string imageFolder, Kernel& kernel
    → , int numberOfEpoch, int numberOfImageRepeat, float apLimit)
```

آدرس یک پوشه شامل تصاویر آموزشی برای شبکه را دریافت کرده و با تعداد مراحل آموزش `numberOfEpoch` و با تکرار هر تصویر به تعداد `numberOfImageRepeat` و بیشینه‌ی کاهش نرخ آموزش `apLimit`، وزن‌های شبکه را طی فرآیند آموزش و با متد `STDP` تنظیم می‌کند.

```
void Network::SaveKernelMergedWeights(Kernel ker, int epoch)
```

وزن‌های کرنل مشخص شده را در قالب فایل‌های اسکریپت که توسط `Gnuplot` قابل رسم است ذخیره می‌کند.

Abstract

Brain's extraordinary capability to process this tremendous amount of information in a parallel fashion and its sophisticated structure has indeed made it the most complex organ in the universe. Although with no doubt there are distinct regions of brain in terms of anatomy, physiology and behaviourism, and considering the modular function of the brain, a considerable amount of local circuitry in cortex are realized randomly. The inability of genome to contain this massive description of synaptic connections is an evidence for this necessary involvement of randomness and motivates more attention from the academia. This study aims to investigate the potentials of Reservoir Computing for visual pattern recognition. Liquid State Machines, as a form Reservoir Computing based on neural building blocks, have recently gained a lot of attention and is already suggested for some engineering applications. LSMs basically map the input to a space of higher dimensions and therefore make distinguishing spatiotemporal patterns more feasible; much like what is achieved by kernels in Support Vector Machines, except LSMs are more biologically plausible to this end. Here, various approaches are incorporated to help us investigate the role of network topology on the performance of an LSM. Moreover, a new method for representation of LSMs' internal states which helps to achieve a better discrimination among samples is proposed. We also suggest a new criterion to assess the separation property of an LSM.

Keywords:

Reservoir Computing – Liquid State Machines – Spiking Neural Networks – Visual Pattern Recognition



University of Tehran

School of Mathematics, Statistics and Computer Science

Master of Science
Computer Science

Using Spiking Neural Networks for Pattern Recognition

By

Nima Mohammadi

Supervisor

Dr. Mohammad Ganjtabesh

Summer 2016